

FAST: 面向视觉-语言-动作模型的高效动作分词


Karl Pertsch^{*,1,2,3}, Kyle Stachowicz^{*,2},

Brian Ichter¹, Danny Driess¹, Suraj Nair¹, Quan Vuong¹, Oier Mees², Chelsea Finn^{1,3}, Sergey Levine^{1,2}

¹ 物理智能, ² 加州大学伯克利分校, ³ 斯坦福大学

<https://pi.website/research/fast>

摘要——自回归序列模型, 如基于变换器的视觉-语言-动作 (VLA) 策略, 在捕捉复杂且可泛化的机器人行为方面极为有效。然而, 此类模型要求我们为连续动作信号选择一种分词方式, 该方式决定了模型预测的离散符号如何映射到连续机器人动作。我们发现, 当前基于简单逐维度、逐时间步分箱方案的机器人动作分词方法, 在从高频机器人数据学习灵巧技能时通常表现不佳。为应对这一挑战, 我们提出一种基于离散余弦变换的新型压缩式机器人动作分词方案。我们的分词方法, 即频域动作序列分词 (FAST), 使我们能够为标准离散化方法完全失效的高灵巧度和高频任务训练自回归 VLA。基于 FAST, 我们发布了 FAST+, 一个通用机器人动作分词器, 在 100 万条真实机器人动作轨迹上训练而成。它可作为黑盒分词器, 用于具有多样动作空间和控制频率的广泛机器人动作序列。最后, 我们证明, 当与 π_0 VLA 结合时, 我们的方法能够扩展到在 1 万小时机器人数据上训练, 并达到扩散 VLA 的性能, 同时将训练时间最多减少 5 倍。



1. 引言

大型高容量变换器模型在从头开始捕捉复杂且可泛化的机器人行为方面极为有效 [8, 69, 51, 6, 20, 62], 也可利用在互联网规模图像-文本语料上预训练用于下一词元预测的模型 [10, 39, 63, 7, 65]。然而, 这些模型要求为连续动作信号选择一种分词方式, 该方式决定了模型预测的离散符号如何映射到连续机器人动作 [64, 34, 41, 12]。众所周知, 良好的分词选择对序列模型的性能至关重要 [55, 57]。此前此类机器人策略通常采用基于逐维度、逐时间步分箱方案的朴素分词策略 [9, 10, 39]。我们发现, 此类方法在学习具有高频控制的灵巧技能时表现不佳 (见图 2 右)。我们观察到, 在预测序列时, 时间步之间的相关性是朴素分词策略面临的主要挑战



图 1: 本文提出 FAST, 一种通过时间序列压缩对机器人动作轨迹进行分词的高效方法。FAST 使自回归视觉语言动作模型能够解决复杂的灵巧操作任务, 并广泛泛化到新场景。我们利用它训练 π_0 -FAST, 这是一种通用机器人策略, 在灵巧和长程操作任务上达到最先进的 π_0 扩散视觉语言动作模型的性能, 同时训练速度快 5 倍 (顶部)。

*: 核心贡献者

通讯地址: research@physicalintelligence.company

未来动作，即动作“块”，在高频控制中十分常见。高度相关的动作标记削弱了自回归视觉语言动作模型中使用的下一标记预测目标的有效性。直观而言，在此类情况下，低标记预测损失往往可以通过简单复制最近动作标记的平凡映射来实现，使模型陷入较差的局部最优。本文从第一性原理出发，提出一种新的分词策略。我们的核心洞见是，机器人动作信号需要在训练前进行压缩，以减少连续标记之间的相关性。我们受到基于压缩的分词策略的启发，例如语言模型常用的字节对编码方法 [27, 57]。然而，由于机器人动作是连续的，相应的压缩策略也应相应选择。因此，我们的方法基于离散余弦变换编码，该编码广泛用于压缩图像等连续信号（例如 JPEG 压缩）。我们发现，由此产生的分词方法——频域动作序列分词，使我们能够通过简单的下一标记预测来训练自回归视觉语言动作模型策略（见图 2 左），适用于高度灵巧和高频任务，而标准离散化方法在这些任务中完全失效。此外，频域动作序列分词首次实现了在最近引入的大规模多任务“野外”机器人操作数据集 DROID [38] 上进行高效的视觉语言动作模型训练。由此产生的策略是第一个语言条件化的通用操作策略，能够通过自然语言提示在未见环境中成功进行零样本评估。基于频域动作序列分词，我们开发了 **FAST+**，一种通用机器人动作分词器，在 100 万条真实机器人动作轨迹上训练，覆盖了多种机器人形态、动作空间和控制频率。我们证明，**FAST+** 分词器能有效对从单臂到双臂和移动机器人的各种机器人动作序列进行分词，并且是训练自回归视觉语言动作模型的良好现成分词器。当与 π_0 视觉语言动作模型集成时，基于频域动作序列分词的自回归视觉语言动作模型可扩展到在 1 万小时机器人数据上进行训练，并在各种任务上达到与基于扩散的视觉语言动作模型相当的性能，同时将训练时间减少多达 5 倍（见图 1）。

II. 相关工作

语言、文本和音频的分词。分词是现代基于变换器的自回归序列模型训练流程中的关键组成部分，分词方法的选择会对模型训练和下游性能产生显著影响 [55]。尽管有多项工作探索了直接对位流进行操作的“无分词”语言模型的训练 [28, 53]，但如今大多数语言模型在训练前仍依赖文本分词阶段。一种常见的方法是字节对编码 [27, 55]，它通过将频繁出现的词元序列合并为新词元来压缩输入文本。对于图像，学习到的压缩方案提供了一种有效的方法




图 2：左：FAST 分词通过简单的下一词元预测，实现了用于灵巧机器人控制的自回归变换器训练。右：FAST 优于常用的分箱分词方案，例如 OpenVLA 中使用的方案 [39]，尤其对于高频机器人数据。

方法：输入图像可以表示为预训练视觉编码器产生的“软词元” [44]，并且可以通过向量量化自编码器实现完整的自回归图像输入输出 [22, 59]。类似的方法可以扩展到视频领域 [66]。在音频生成和语音合成中，它们与动作预测具有相同的时间序列结构，最先进的模型通常使用频域频谱图图像 [29] 或学习到的向量量化器 [68] 来编码时间序列音频数据。

视觉-语言-动作模型。近期，多项工作已开发出通用机器人策略 [9, 51, 6, 10, 20, 39, 62, 11]，这些策略在日益庞大的机器人学习数据集 [52, 38, 60, 24, 47, 35] 上进行训练。训练通用策略的一种有前景的方法是视觉-语言-动作模型（VLA；[10, 17, 39, 67, 7, 63, 73, 71, 13, 11]）。VLA 对在互联网规模的图像和文本数据上预训练的视觉-语言模型进行微调，以用于机器人控制。这带来了多重益处：使用具有数十亿参数的大型视觉-语言模型骨干，为策略提供了拟合大型机器人数据集所需的表达能力。重用互联网规模数据上预训练的权重，也提升了 VLA 遵循多样化语言指令和泛化的能力，例如泛化到新物体和场景背景 [10, 39, 67, 63, 36]。目前大多数 VLA 模型局限于相当简单、低频的控制任务，尤其是采用最常见的自回归 VLA 设计的模型 [10, 39]。我们表明，这是这些模型所采用的动作分词方案直接导致的结果，该方案使得在灵巧任务上的训练变得困难。我们引入了一种新的动作分词方法

该方法使我们能够在灵巧且高频的机器人数据上训练首个自回归视觉-语言-动作模型（VLA）。

视觉-语言-动作模型训练中的动作表示。 先前的工作探索了训练机器人策略的各种动作参数化方法，包括视觉语言动作模型（VLA）。一类工作使用“语义”动作表示，如语言子任务 [21, 2, 4] 或关键点 [50, 32, 25, 19]。这类方法通常能从少量示例中学习，甚至在没有机器人示例的情况下零样本执行任务 [50, 32, 25]，但需要手工设计的底层控制器来执行任务，限制了其通用性。另一种方法直接训练视觉语言动作模型，在给定图像和语言指令输入的情况下输出底层机器人控制命令。最常见的设计直接将动作嵌入到离散标记中，这些标记可以用标准的自回归序列模型生成，就像任何流行的视觉语言模型一样。现有方法使用简单的逐维、逐时间步分箱方案将连续机器人动作映射到离散动作标记 [9, 10, 39]。我们发现这种方案难以扩展到高频机器人控制任务。我们提出了一种基于时间序列压缩技术的机器人动作新分词方案，使我们能够在高频数据上训练自回归视觉语言动作模型。许多工作也提出了分词之外的替代方案，例如使用回归头或引入新权重进行扩散解码 [20, 7, 41, 63]。相比之下，我们的方法不需要修改底层预训练变换器模型，可以轻松应用于任何预训练的自回归变换器模型，并在许多任务上达到与最先进的基于扩散的视觉语言动作模型 [7] 相竞争的性能，同时训练计算效率显著更高。另一组相关工作探索了向量量化动作表示 [41, 3, 49]。这类方法训练一个向量量化编码器-解码器网络，其重建质量可能对超参数选择和结构敏感 [66]。我们发现这些方法在粗粒度、低保真重建任务上表现良好，但在需要细粒度控制的高频任务上失败。相比之下，我们的快速分词方案超参数少，能够高精度重建动作，同时提供强大的压缩特性。

III. 预备知识

问题表述。 我们的目标是训练策略 $\pi(a_{1:H}|o)$ ，将观测 o 映射到未来机器人动作序列 $a_{1:H}$ 。我们假设策略输出一个“动作块”[69, 40]，即 H 个动作的序列 [15, 7, 69]，这有助于产生时间上一致的动作并减少累积误差。动作分词的目标是定义一个映射 $\mathcal{T}_a: a_{1:H} \rightarrow [T_1, \dots, T_n]$ ，将维度为 $|A|$ 的 a 的连续动作序列 $a_{1:H}$ 映射为词汇表大小为 $|\mathcal{V}|$ 的 n 个离散标记序列 $T \in \mathcal{V}$ 。注意，标记数量 n 在不同动作序列之间可能不同，就像相同长度的句子可能被分词为数量可变的文本标记一样。




图 3：采样率对预测性能的影响。 我们在一个教学性插值任务上训练一个小型自回归变换器模型，该任务要求网络根据四个圆圈预测黑色虚线曲线。我们发现，采用先前视觉语言动作模型（VLA）中使用的分箱分词方法 [10, 39] 训练的模型，随着底层信号采样频率的增加，预测质量逐渐变差，原因在于高频下连续分词之间存在强相关性。我们提出的基于离散余弦变换（DCT）的 FAST 分词方法解决了这一问题，并在所有采样率下均能实现高质量预测。

基于分箱的动作分词。 最常用的动作分词方法是简单的分箱离散化方案 [8, 10, 39, 72, 56]。对于给定的动作 a ，该方法独立地离散化每个维度，将训练数据集中的值范围划分为 N 个均匀的箱，最常用的是 $N = 256$ 。对于 D 维动作序列 $a_{1:H}$ ，该分词方案将应用于每个时间步，最终得到分词序列 $= [T_{1,1}, \dots, T_{1,D}, \dots, T_{H,1}, \dots, T_{H,D}]$ 。对于高频机器人数据，这种分词方案并非最优：它很容易为每个动作块 $\mathcal{T}_a(a_{1:H})$ 产生数百个分词，这使得训练具有挑战性并导致推理速度缓慢。

四、案例研究：分词如何产生影响

视觉语言动作训练？

为说明当前动作分词方法在训练自回归策略时面临的挑战，本文首先

通过一个简单的教学示例来说明。我们创建了一个合成时间序列数据集，目标是预测一条三次样条曲线，该曲线插值四个随机生成的点（见图 3 底部）。这个玩具问题反映了在高频动作块上训练的策略所面临的挑战，即必须根据某些条件信息预测一系列连续动作。我们使用先前视觉语言动作策略中采用的朴素分词方案对目标序列进行分词，该方案将序列中的每个元素分别离散化为 256 个区间之一（见第三节）。然后，我们训练一个小型自回归变换器策略，根据条件点预测分词后的信号。我们在目标信号的不同采样率下重复此实验，从每个序列 25 个时间步到 800 个时间步，而不改变底层数据集。这模拟了在不同频率收集的动作数据上训练自回归策略。在不同频率下训练的自回归模型的平均预测均方误差如图 3 顶部所示（“朴素”）。我们观察到，采用分箱分词方案的模型在低采样率下取得了良好的预测性能（即低均方误差）。但随着采样率的增加，预测误差急剧上升，最终模型只是简单地复制第一个动作，如图 3 左下角的定性可视化所示。请注意，这个问题不能归因于数据本身：底层数据分布的复杂度没有改变，我们期望具有相同容量、训练相同步数的模型在所有采样率下都能达到可比的性能。那么发生了什么？要理解分词方案如何影响学习性能，我们需要审视学习目标本身。从根本上说，自回归模型被训练为在给定所有先前分词的情况下预测下一个分词。因此，它们的学习信号与 T_i 在给定 $T_{1:i-1}$ 时的边际信息量成正比。关键在于，当使用朴素的逐时间步分词方案时，随着训练信号控制频率的增加，这种边际信息趋近于零：对于平滑信号，随着时间步变短，每个时间步的变化量成比例地减小。这大大减慢了训练过程中的收敛速度，并可能使拟合复杂的高频数据集变得困难。事实上，先前的工作中已经观察到了此类挑战。例如，OpenVLA 在低频的 BridgeV2 和 RT-1 数据集上表现良好，但在拟合更高频的 DROID 数据集时遇到了困难 [39]。我们的案例研究结果强调了为机器人动作设计更好的分词方案的重要性。

五、基于时间序列压缩的高效动作分词方法

上一节中，我们观察到高频动作轨迹中的冗余会导致每个动作标记的边际信息量较低，进而影响训练性能。为解决这一问题，我们需要一种分词方法，将高度冗余的动作信号压缩为数量更少但信息量更高的标记。本节中，

我们将首先描述一种用于压缩连续时间序列的简单方法（第五-A 节），随后利用该方法设计一种动作分词算法（第五-B 节），最后阐述如何训练一个通用的机器人动作分词器（第五-C 节）。

A. 基于离散余弦变换的时间序列压缩

关于有效压缩连续时间序列的研究成果丰富，既有在将信号变换至频域后进行压缩的方法 [18, 1, 61]，也有基于向量量化等学习式压缩方法 [59, 48]。本研究的一个关键结论是：任何足够有效的压缩方法，只要应用于动作目标，都有助于提升视觉-语言-动作模型的训练速度。在实际应用中，仍有一些因素可能促使我们偏好某些压缩算法，例如分词器的训练复杂度，以及动作分词与反分词的效率。本文采用基于离散余弦变换（Discrete Cosine Transform, DCT）的压缩算法 [1]。DCT 是一种频域变换，将连续信号表示为不同频率余弦分量之和。低频分量捕捉信号的整体形状，而高频分量反映急剧跳变。DCT 因其简单性和计算效率，以及对实际图像的强压缩特性，被广泛用于压缩算法，例如 JPEG 图像压缩 [61]：由于像素通常平滑变化，DCT 往往仅用少量系数即可表示输入信号的大部分信息。通过省略权重较低的频率分量即可实现信号压缩。与基于向量量化的学习式压缩方法相比，基于 DCT 的压缩是一种解析方法，因此极为简单且快速。

B. FAST 分词算法

我们利用离散余弦变换设计了 FAST，一种快速且有效的机器人动作分词方法。我们在图 4 中详细展示了从原始机器人动作到动作标记的步骤。首先对输入动作进行归一化，使训练数据集中每个动作维度的第 1 和第 99 百分位数值映射到范围 $[-1, \dots, 1]$ 。这一初始归一化步骤有助于将数据引入指定范围，并使具有不同动作尺度的跨具身数据集的分词更加容易。我们使用百分位数是为了对大型机器人数据集中偶尔出现的异常动作具有鲁棒性。数据归一化后，我们对每个动作维度分别应用离散余弦变换。为了压缩 DCT 转换后的信号，我们可以简单地省略不重要的系数，这通过缩放和舍入操作实现，其中缩放系数是一个超参数，用于在分词操作的有损性和压缩率之间进行权衡。舍入操作后，DCT 系数矩阵通常是稀疏的，大多数条目为零，每个动作维度仅保留少数重要系数。为了实现实际压缩，我们必须将这个稀疏




图 4: FAST 动作分词流程概览。给定归一化的动作块，我们应用离散余弦变换（DCT）将信号转换到频域。然后对 DCT 系数量化，并使用字节对编码（BPE）将每个维度 DCT 系数的扁平化序列压缩为最终的动作标记序列。详细描述见第 V-B 节。

矩阵转换为密集令牌序列。我们将矩阵展平为一维整数向量，按动作维度交错排列，优先包含所有低频分量，并训练字节对编码（BPE）分词器 [27] 将其无损压缩为密集动作令牌。BPE 步骤“压缩”零值分量，并合并跨动作维度频繁出现的系数组合。我们选择 BPE 来压缩 DCT 矩阵，因为已有许多高效实现，且它能生成固定大小的输出词汇表，可轻松集成到视觉语言模型的现有词汇表中用于 VLA 训练。其他无损压缩算法如哈夫曼编码 [33] 或 Lempel-Ziv 方法 [75]（gzip 压缩方法所基于的算法）也可替代使用，但我们将此留待未来工作研究。注意，在 BPE 编码之前展平 $|A| \times H$ DCT 系数矩阵的顺序可能对策略训练产生显著影响。有两种选择：列优先展平，即先连接每个维度的最低频分量；或行优先展平，即先连接单个动作维度的所有频率分量。我们选择前者，因为我们发现，在自回归预测期间首先预测表征输出序列整体形状的低频分量，能带来更稳定的策略展开。我们分词流程中的所有操作都易于逆变换，从而能快速解码预测动作。该分词器仅有两个超参数：舍入前应用于 DCT 系数的缩放因子，以及 BPE 压缩步骤的词汇表大小。我们发现这两个参数都不太敏感，并在所有单数据集分词实验中使用相同值（舍入缩放因子 10，BPE 词汇表大小 1024）。这与依赖向量量化的端到端学习压缩模块形成对比。

Algorithm 1 FAST Tokenizer

Require: scale γ , (for inference) BPE dictionary Φ

procedure FASTTOKENIZER($a_{1:H}$)

$C_j^i \leftarrow \text{DCT}(a_{1:H}^i)$ $\triangleright$ Compute DCT coefficients

$\bar{C}_j^i \leftarrow \text{round}(\gamma \cdot C_j^i)$ $\triangleright$ Quantize coefficients

$[T_k] \leftarrow [\bar{C}_1^1, \bar{C}_1^2, \dots, \bar{C}_2^1, \dots, \bar{C}_H^n]$ $\triangleright$ Flatten tokens

BPE Training:

$\phi \leftarrow \text{TrainBPE}(\mathcal{D} := \{[T_k]\})$

Tokenization:

$[\bar{T}_1, \dots, \bar{T}_k] \leftarrow \text{BPE}([T_1, \dots, T_k], \phi)$

return action_tokens

化 [59]。此类网络通常训练繁琐，且需要针对特定数据集仔细选择超参数才能实现良好的重建 [66, 48]。我们的实验表明，基于离散余弦变换的分词方法训练出的策略性能优于基于向量量化的方法，同时显著更简单且更易调优。我们在第四节的玩具示例中实证展示了基于离散余弦变换的分词方法的优势。图 3 显示，在离散余弦变换压缩的目标标记上训练自回归模型，能在广泛的采样频率范围内持续实现较低的预测误差。我们在算法 1 中简要总结了分词方法，并在第六节中测试了快速分词在机器人控制问题上的有效性。

C. 通用机器人动作分词器

我们分词器中唯一需要学习的组件是字节对编码器的词汇表，该词汇表需要针对分词器所应用的每个新数据集进行训练。尽管这一学习过程很快（通常只需几分钟），但它为使用快速分词增加了额外的摩擦。因此，

我们旨在训练一个通用动作分词器，能够对来自任何机器人的动作块进行编码。为此，我们使用上述流程在一个大型跨具身机器人动作数据集上训练分词器，该数据集包含约一百万个 1 秒动作块，来自单臂、双臂和移动操作机器人，具有关节和末端执行器控制动作空间以及各种控制频率。我们在附录 A 中提供了用于训练通用分词器的数据混合的详细分解。训练完成后，我们的通用动作分词器 FAST+ 可作为黑盒分词器应用于任何机器人设置的 1 秒动作序列。我们的实验评估表明，它与针对单个数据集调优的分词器具有竞争力。代码

发布。我们以方便的 HuggingFace 自动处理器类形式发布了预训练的通用动作分词器 FAST+，只需三行代码即可将分词器应用于任何新的机器人动作块：从 **transformers** 导入 **AutoProcessor**

```
分词器 = AutoProcessor.from_pretrained(
    "physical-intelligence/fast", trust_remote_code=True ) 标记 =
tokenizer(action_chunk)
```

为获得最佳压缩效果，建议按第 V-B 节所述，通过分位数归一化将输入动作归一化到 $[-1, \dots, 1]$ 范围，并每次对 1 秒动作块进行分词。我们的模块还便于在给定的动作块数据集上训练新的 FAST 分词器：from **transformers import AutoProcessor**

```
分词器 = AutoProcessor.from_pretrained(
    "physical-intelligence/fast", trust_remote_code=True ) new_tokenizer
= tokenizer.fit(action_dataset)
```

六、实验

在实验中，我们用两种 VLA 主干测试 FAST： π_0 [7] 和 OpenVLA [39]。我们将 FAST 与替代动作分词方案进行比较，并消融关键设计决策。然后，我们将使用 FAST 分词训练的 π_0 模型与最先进的 π_0 流匹配（扩散）VLA 进行比较，并测试使用 FAST 的自回归 VLA 训练扩展到包含 1 万小时灵巧机器人操作数据的大规模跨具身数据集。

A. 实验设置

策略 实现。我们使用流行的 VLA 主干测试自回归 VLA 训练的不同分词方案。在大多数实验中，我们使用 π_0 [7]，一种基于 PaliGemma-3B [5] 的 VLA。我们还测试了基于 Prismatic 7B [37] 构建的 OpenVLA [39]。在训练期间，我们对 1 秒动作块进行分词，并用生成的动作标记覆盖 VLM 词汇表中使用的最少的标记，遵循先前 VLA 的做法 [10, 39]。我们微调




图 5：评估环境。我们在 7 个评估环境中测试 FAST：6 个真实机器人任务和 1 个仿真环境。这些任务旨在测试 VLA 在高度灵巧任务上的性能，例如从洗衣篮中折叠衣物（“衣物折叠”），以及泛化能力，例如在未见过的环境中进行零样本桌面操作（“DROID”）。

用于机器人动作预测的视觉-语言-动作模型，不冻结权重。策略训练设置的更多细节见附录 C。

评估任务。本文开发了一套包含 7 项评估任务的测试集（6 项真实机器人任务，1 项仿真任务；见图 5），旨在测试视觉-语言-动作模型在两类任务上的性能：高度灵巧的任务（如叠衣服）和泛化任务（如在未见环境中零样本执行桌面操作）。

- **Libero：**本文在 Libero [43] 仿真基准套件上进行测试。测量 Libero-Spatial、Libero-Object、Libero-Goal 和 Libero-10 的平均性能。
- **桌面清理 [7] (20 赫兹)：**一台 UR5 单臂机器人需要清理桌面，将 12 个物体分类放入垃圾桶（用于

垃圾）和塑料容器（用于盘子、碗、杯子和餐具）。该任务要求对各种物体进行精确抓取。

- **T 恤折叠 [7] (50 赫兹)：双臂 ARX 机器人装置需要在固定桌面上折叠各种衬衫。**任务开始时，衬衫平铺在桌面上。成功完成该任务需要精确的抓取和移动来折叠衬衫。

- **杂货装袋 [7] (20 赫兹)：一台 UR5 单臂机器人需要将七个物体从桌面装入杂货袋，过程中需注意不使袋子倾倒或撕裂。**

该任务要求抓取多种物体并小心地将其放入袋中。

- **从烤面包机取出吐司 [7] (50 赫兹)：一台双臂 Trossen Viper-X 机器人需要从烤面包机中取出两片面包并放到盘子上。**该任务要求精确抓取和放置面包片。

- **叠衣服 [7] (50 赫兹)：一台双臂 ARX 机器人需要从篮子中取出衬衫和短裤，在桌面上展平，折叠并堆叠。**这是我们测试中最灵巧的任务。它要求精确抓取、动态动作以展平衣物，在衣物缠绕时进行重试和纠正，并将折叠好的衣物精确放置在现有衣物堆上。我们报告单件衣物的成功率。

- **零样本 DROID 桌面操作 [38] (15 赫兹)：我们测试一个在完整 DROID 数据集上训练的策略，涵盖各种桌面操作任务，如拾取和放置物体、擦拭、开关抽屉等。**

重要的是，我们在完全未见过的环境中测试该策略，包括新的桌面布置、背景、新物体、视角和桌面高度。据我们所知，这是首次在完全未见过的环境中对 DROID 策略进行“零样本”评估，无需联合训练或微调，仅通过自然语言提示预训练模型。

Following Black et al. [7], we use grocery bagging, the toaster task, and laundry folding only to evaluate our most powerful, generalist VLA in Section VI-F. We provide additional details on training datasets and evaluation tasks in Appendix E.

比较。我们测试了 FAST（我们基于 DCT 的动作分词方法，分别在每个评估数据集上训练）和 FAST+（我们通用的基于 DCT 的动作分词器，在包含 100 万条动作序列的大规模数据集上训练）。注意，我们使用能收集到的最多样化的真实机器人数据集训练通用分词器，其中包含来自我们真实机器人评估任务的数据。我们将两种分词器与先前自回归视觉语言动作模型（如 RT-2 [10]、RT-2-X [52] 和 OpenVLA [39]）使用的逐维度分箱方案（称为朴素分词）进行比较。我们将分箱分词分别应用于动作块中的每个时间步，然后进行拼接。最后，虽然我们的方法提供了一种无需训练任何独立模型的压缩分词方式，但我们也可以考虑另一种压缩方案，即训练一个模型来生成动作的量化表示

通过有限标量量化（FSQ）[48] 进行分块，这是矢量量化变分自编码器（VQ-VAE）[59] 的一种更简单的替代方案。这种分词策略此前已被用于对高维图像数据进行分词 [48, 66]，并且可视为我们基于压缩方法的一种消融实验，它利用了压缩表示，但采用了比我们相对简单的离散余弦变换（DCT）方法更复杂的基于学习的替代方案。

B. 比较用于视觉-语言-动作（VLA）训练的动作分词器

Dataset	Action Dimension	Control Frequency	Avg. Token		Compression
			Naive	FAST	
BridgeV2	7	5 Hz	35	20	1.75
DROID	7	15 Hz	105	29	3.6
Bussing	7	20 Hz	140	28	5.0
Shirt Fold	14	50 Hz	700	53	13.2

表 I：朴素分词与 FAST 在每个动作块上的平均标记数比较。我们在所有数据集中使用 1 秒的块。使用我们的方法，每个块所需的标记数大大减少，尤其是在高频领域（如 T 恤折叠任务）中，这表明它在去除冗余方面更为有效。

我们首先在表 I 中比较了本文提出的 FAST 分词器与先前工作所用的朴素分箱方案之间的压缩率。我们使用来自不同动作维度和控制频率的数据集中的 1 秒动作块。对于两种方法，我们均采用默认超参数，其分词误差相当。我们发现，FAST 在所有数据集上均实现了对输入动作序列的显著压缩。对于具有高频动作数据的数据集，压缩优势尤为明显。有趣的是，FAST 在每个领域中每个机器人手臂始终生成约 30 个动作标记（即双臂设置为 60 个标记）。这表明 FAST 找到了一种近似底层动作信号复杂度的表示，且在很大程度上与动作数据的频率无关。我们注意到，这种压缩并非完全无损，压缩率与重建准确率之间的权衡由算法 1 中的尺度参数 γ 决定。表 I 中的数值是在可比较的重建准确率下获得的。关于各分词器压缩与保真度之间权衡的图示，请参见附录 B。接下来，我们使用第 VI-A 节中描述的策略架构和分词方法训练策略。我们在图 6 中报告结果。总体而言，我们发现先前工作中采用的朴素分词方法难以在高频机器人数据上学习有效的策略。这一点在我们评估中频率最高的任务上尤为明显：餐桌摆盘（20Hz）和 T 恤折叠（50Hz）。在这两个任务上，使用朴素分词训练的策略无法取得任务进展。相比之下，我们发现基于压缩的分词方法能够实现有效训练。将 FAST 与我们的 FSQ 进行比较




图 6：使用不同分词方法的策略性能比较。我们发现，压缩动作目标的分词方法（FAST、FSQ）比先前视觉语言动作模型（VLA）中使用的朴素分箱分词方法训练效率显著更高。总体而言，我们发现 FAST 比 FSQ 带来更有效的策略训练，尤其是在灵巧的真实机器人任务上。我们的通用分词器 FAST+ 达到了与数据集特定分词器相当的性能。我们报告均值和 95% 置信区间。




图 7：在 DROID [38] 上训练的 FAST 策略的评估环境。我们发现同一策略检查点具有鲁棒的泛化能力，并在三所大学校园中零样本执行各种简单的桌面任务。

基线相比，我们发现 FAST 表现相当甚至有时更优，尤其是在灵巧、高频任务上，尽管它更简单且无需单独的神经网络训练。值得注意的是，FAST 分词首次成功在 DROID 数据集 [38] 上训练出强大的通用策略，该策略可在未见环境中零样本评估，无需微调，只需用自然语言提示即可。所有先前工作，包括原始 DROID 论文 [38] 和 OpenVLA [39]，均未展示零样本结果，而是完全专注于联合训练或微调评估。我们通过在各种桌面操作任务上测试 DROID 策略来证明其通用性。




图 8：通用分词器。我们测试了 FAST+ 分词器与朴素分词在多种机器人数据集上的压缩率，这些数据集在分词器训练期间未见。我们发现 FAST 在广泛的机器人形态、动作空间和控制频率上均有效。

在三所大学校园的环境中（图 7）。开箱即用，该策略能够胜任简单的操作任务，如拾取和放置物体、开关橱柜和打开水龙头，在广泛的场景和相机视角下均表现良好。即使失败的试验也显示出合理的行为，例如接近微波炉和洗碗机门的把手，尽管最终未能打开它们。我们在网站上展示了成功和失败的视频。虽然远非完美，但该策略的通用性和鲁棒性水平显著超过了先前的 DROID 策略。

C. 通用动作分词器

在本节中，我们评估通用动作分词器 FAST+ 的性能，该分词器在 100 万条真实机器人动作序列上训练（见第 V-C 节）。为测试分词器的通用性，我们组装了一组多样化的小型测试数据集。该集合涵盖了广泛的机器人形态、动作空间和控制频率（见图 8，完整数据集列表见表 III）。请注意，这些数据集均不属于分词器训练集。因此，它们测试的场景是

其中分词器被应用于一个全新的机器人设置，而无需重新计算分词。我们发现，FAST+ 分词器在广泛的机器人数据集上实现了良好的压缩性能，在所有数据集上将动作标记数量减少了 2 倍，在某些数据集上减少得更多。我们还测试了通用分词器在策略训练中的性能，并在图 6 中与按数据集训练的分词器一起报告了结果。在所有任务中，通用分词器的性能与数据集特定的 FAST 分词器非常接近，这表明通用分词器可以作为机器人动作分词的强默认选择。

D. 消融研究

我们分析了方法的两个关键方面：（1）我们的 FAST 分词方法是否独立于底层的视觉-语言-动作（VLA）骨干网络？（2）BPE 压缩步骤（我们分词流程中唯一的学习组件）有多重要？

为了回答第一个问题，我们在具有挑战性的高频 T 恤折叠数据集上训练了一个 OpenVLA 策略 [39]，将 OpenVLA 中最初使用的朴素分词方法与我们的 FAST+ 分词器进行了比较。为了符合任务设置，我们修改了 OpenVLA 模型代码，使其接受多个输入图像并预测 1 秒的动作块。右侧的结果表明，FAST 能够显著提升 OpenVLA 的性能，使其能够有效地在高频机器人操作数据上进行训练。这表明我们的分词方法独立于底层模型骨干，并且可以轻松应用于各种预训练的自回归变换器模型。

其次，我们在餐桌清理和 T 恤折叠任务上对 BPE 编码步骤进行了消融。右侧的图显示，没有 BPE 编码的策略在部署性能上更差（但仍然优于朴素分词）。直观地说，离散余弦变换（DCT）仍然将大部分信号信息集中在少数标记中，从而改善了学习信号。然而，如果没有 BPE，会存在大量重复的 0 标记，这会稀释学习信号，并且显著减慢推理速度，因为模型需要自回归地预测数百个动作标记，最终导致策略性能下降。



E. FAST 与扩散模型的比较

在本节中，我们将 π_0 （一种最先进的扩散视觉-语言-动作模型）与我们的模型进行比较，后者结合了 π_0 与 FAST 并使用




图 9：扩散 π_0 [7] 与采用 FAST 解码的 π_0 模型在单任务训练上的比较。在小型数据集（Libero、T 恤折叠）上，两者性能相当。在大型数据集（Table Bussing）上，FAST 收敛更快。在 DROID 中，我们发现 FAST 能更好地遵循语言指令。我们报告均值和 95% 置信区间。

自回归解码。我们比较两种模型在第六-B 节任务上的性能。

我们在图 9 中报告结果。我们发现，在小型数据集（Libero、T 恤折叠；< 50 小时）上，两种 VLA 性能相当。然而，在大型数据集如 Table Bussing 上，我们发现基于 FAST 的 VLA 收敛显著更快，达到高性能所需的训练步数比 π_0 的扩散变体少 3 倍。此外，我们发现使用 FAST 分词训练的自回归 π_0 模型更紧密地遵循语言指令：在 DROID 评估中，扩散 π_0 模型经常忽略语言指令，导致得分较低。我们将把对扩散和自回归 VLA 的语言遵循能力的详细研究留待未来工作。

自回归 VLA 当前的一个局限性是其推理速度：虽然采用扩散的 π_0 通常在 NVIDIA 4090 GPU 上 100 毫秒内预测一秒的动作块，但采用 FAST 分词的 π_0 模型每个块需要约 750 毫秒的推理时间，因为它必须执行更多的自回归解码步骤（通常需要解码 30-60 个动作标记，而扩散 π_0 只需 10 个扩散步骤），并使用完整的 2B 参数语言模型骨干进行自回归解码（而扩散 π_0 使用 300M 参数的“动作专家”）。虽然我们发现这种较慢的推理并未损害我们所评估的静态操作任务的性能，但它使评估显著变慢。展望未来，有许多技术可以加速离散自回归变换器模型的推理，这些技术在 LLM 文献中被广泛使用（例如推测解码、量化、自定义推理核函数等），但我们将把这些研究留待未来工作。




图 10: π_0 -FAST 在衣物折叠任务上的执行过程。FAST 分词使自回归 VLA 能够执行复杂、长时程和灵巧的任务，这些任务在以前的分词方案下是不可能的。




图 11: π_0 -FAST 与扩散 π_0 [7] 通用策略的比较。 π_0 -FAST 在训练所需计算量显著更少的情况下，达到了与扩散 π_0 相当的性能。报告：均值及 95% 置信区间。

重要的是，我们发现 π_0 -FAST 的收敛速度显著快于扩散 π_0 模型：上述评估中的模型训练所需的 GPU 小时数比 Black 等人 [7] 的 π_0 模型少 5 倍。我们在图 1 中展示了训练过程中多个检查点的机器人评估结果（对两个代表性任务——桌面清理和 T 恤折叠的性能取平均）。结果清楚地表明， π_0 -FAST 显著更快地达到了高性能。对于通常需要数千 GPU 小时的最先进的视觉语言动作模型训练运行而言，所需计算量减少 5 倍意义重大。我们在附录图 15 中包含了计算量匹配的 π_0 检查点在所有任务上的完整比较，并发现结论相同：由于收敛速度更快， π_0 -FAST 明显优于计算量匹配的 π_0 。总而言之，我们已经证明 FAST 分词使我们能够在复杂、灵巧的机器人任务上训练自回归视觉语言动作模型，而先前的分词方案在这些任务上完全失败。我们还表明，当 FAST 与 π_0 等最先进的视觉语言动作模型结合时，能够扩展到训练通用、跨具身策略，其性能可与最佳扩散视觉语言动作模型相媲美，同时训练速度显著更快。

F. 将自回归视觉语言动作模型扩展到大型机器人数据集

我们已经证明了 FAST 在单个机器人数据集上训练自回归视觉语言动作模型的有效性，但它能否扩展到训练灵巧的通用策略？为了验证这一点，我们在 π_0 [7] 所使用的跨具身机器人数据混合上训练了上一节中的 π_0 -FAST 模型，该数据混合是迄今为止最大的灵巧机器人操作数据集。它包含来自我们自身数据集的 9.03 亿个时间步。此外，训练混合中有 9.1% 来自开源数据集 BRIDGE v2[60]、DROID[38] 和 OXE[52]。我们在图 11 中比较了该模型与扩散 π_0 模型在 Black 等人 [7] 的任务上的零样本性能。总体而言，我们发现自回归 π_0 -FAST 模型在包括最具挑战性的叠衣任务在内的所有任务上，性能与扩散 π_0 模型相当，同时训练所需计算量显著更少。我们在图 10 中展示了 π_0 -FAST 执行叠衣任务的定性示例，并在我们的网站上提供了更多视频。

七、讨论与未来工作

本文提出了 FAST，一种用于高频机器人控制数据的高效动作分词器。FAST 采用离散余弦变换（DCT）后接字节对编码（BPE）来压缩动作块，在一系列机器人领域中，其压缩效果显著优于现有动作分词器。我们的真实世界和模拟视觉-语言-动作（VLA）实验表明，与之前使用的朴素动作离散化方法相比，FAST 带来了显著的性能提升，并优于基于向量量化的更复杂学习式分词方法。我们还展示了可以训练 FAST+，一种通用动作分词器，可作为任何机器人动作序列的强默认分词器。利用它，我们训练了 π_0 -FAST，一种灵巧的通用策略，其性能可与

最先进的扩散 VLA 相媲美，同时训练效率显著更高。未来工作有许多令人兴奋的方向：

动作分词器。尽管我们认为 FAST 是迈向通用机器人动作分词器的重要一步，但仍有许多问题有待解决。在本工作中，我们在静态机器人机械臂上测试了 FAST。我们的离线实验展示了 FAST+ 在其他机器人形态（如移动机器人、灵巧手和人形机器人）上具有前景的压缩能力。在这些平台上测试实际策略性能是未来工作的一个令人兴奋的方向。此外，探索替代压缩方案，以及测试基于压缩的动作编码与非自回归解码方法（如扩散 [7]）的结合，是未来研究的有趣方向。

VLA 架构。本文初步探索了两大类 VLA 架构（自回归解码 VLA 和扩散解码 VLA）之间的权衡，但最佳 VLA 架构尚无定论。未来工作应仔细探索两种方法在训练速度、语言基础能力和表达能力方面的权衡。

推理速度。虽然 π_0 -FAST 在整体性能上与扩散 π_0 相当，但在推理时速度较慢（见第六-E 节）。虽然较慢的推理速度在我们评估的静态任务上是可以接受的，但未来工作应探索加速自回归 VLA 模型推理的方法，使其能够解决高度动态的任务。大语言模型领域有大量推理优化文献，可以直接应用于自回归 VLA。

致谢

我们感谢 Ury Zhilinsky 和 Kevin Black 在建立本项目所使用的数据和训练基础设施方面提供的帮助。我们还感谢 Pranav Atreya、Haohuan Wang、Lucy Shi、Arhan Jain 和 Andy Yun 在加州大学伯克利分校、斯坦福大学和华盛顿大学协助进行 DROID 策略评估，以及 Will Chen 对我们 FAST+ 开源实现的测试和调试。我们感谢 Noah Brown、Szymon Jakubczak、Adnan Esmail、Tim Jones、Mohith Mothukuri 和 James Tanner 在机器人维护方面的帮助，以及 Anna Walling 在机器人、数据和评估操作方面的帮助。我们感谢 Physical Intelligence 整个机器人操作员团队在运行数据收集和策略评估方面做出的巨大贡献。最后，我们感谢 Claudio Guglieri、Lachy Groom 和 Karol Hausman 在本文和项目网站上使用的可视化方面提供的帮助。

参考文献

- [1] Nasir Ahmed, T. Natarajan, and Kamisetty R Rao. Discrete cosine transform. *IEEE transactions on Computers*, 100(1):90–93, 1974.
- [2] Michael Ahn, Anthony Brohan, Noah Brown, Yevgen Chebotar, Omar Cortes, Byron David, Chelsea Finn, Chuyuan Fu, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Daniel Ho, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Eric Jang, Rosario Jauregui Ruano, Kyle Jeffrey, Sally Jesmonth, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Kuang-Huei Lee, Sergey Levine, Yao Lu, Linda Luu, Carolina Parada, Peter Pastor, Jornell Quiambao, Kanishka Rao, Jarek Rettinghouse, Diego Reyes, Pierre Sermanet, Nicolas Sievers, Clayton Tan, Alexander Toshev, Vincent Vanhoucke, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Mengyuan Yan, and Andy Zeng. Do as i can and not as i say: Grounding language in robotic affordances. In *arXiv preprint arXiv:2204.01691*, 2022.
- [3] Suneel Belkhale and Dorsa Sadigh. Minivla: A better vla with a smaller footprint, 2024. URL <https://github.com/Stanford-ILIAD/openvla-mini>.
- [4] Suneel Belkhale, Tianli Ding, Ted Xiao, Pierre Sermanet, Quon Vuong, Jonathan Tompson, Yevgen Chebotar, Debiddatta Dwivedi, and Dorsa Sadigh. Rt-h: Action hierarchies using language, 2024. URL <https://arxiv.org/abs/2403.01823>.
- [5] Lucas Beyer, Andreas Steiner, André Susano Pinto, Alexander Kolesnikov, Xiao Wang, Daniel Salz, Maxim Neumann, Ibrahim Alabdulmohsin, Michael Tschannen, Emanuele Bugliarello, et al. Paligemma: A versatile 3b vlm for transfer. *arXiv preprint arXiv:2407.07726*, 2024.
- [6] Homanga Bharadhwaj, Jay Vakil, Mohit Sharma, Abhinav Gupta, Shubham Tulsiani, and Vikash Kumar. Roboagent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 4788–4795. IEEE, 2024.
- [7] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [8] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, Sergey Levine, Yao Lu, Utsav Malla, Deeksha Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jornell Quiambao, Kanishka Rao, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Kevin Sayed, Jaspiar Singh, Sumedh Sontakke, Austin Stone, Clayton Tan, Huong Tran, Vincent Vanhoucke, Steve Vega, Quan Vuong, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-1: Robotics transformer for real-world control at scale. In *arXiv preprint arXiv:2212.06817*, 2022.
- [9] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana

- Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [10] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, Pete Florence, Chuyuan Fu, Montse Gonzalez Arenas, Keerthana Gopalakrishnan, Kehang Han, Karol Hausman, Alex Herzog, Jasmine Hsu, Brian Ichter, Alex Irpan, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Lisa Lee, Tsang-Wei Edward Lee, Sergey Levine, Yao Lu, Henryk Michalewski, Igor Mordatch, Karl Pertsch, Kanishka Rao, Krista Reymann, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Pierre Sermanet, Jaspiar Singh, Anikait Singh, Radu Soricut, Huong Tran, Vincent Vanhoucke, Quan Vuong, Ayzaan Wahid, Stefan Welker, Paul Wohlhart, Jialin Wu, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *arXiv preprint arXiv:2307.15818*, 2023.
- [11] Chi-Lam Cheang, Guangzeng Chen, Ya Jing, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Hongtao Wu, Jiafeng Xu, Yichu Yang, Hanbo Zhang, and Minzhao Zhu. Gr-2: A generative video-language-action model with web-scale knowledge for robot manipulation. *arXiv preprint arXiv:2410.06158*, 2024.
- [12] Sanyuan Chen, Yu Wu, Chengyi Wang, Shujie Liu, Daniel Tompkins, Zhuo Chen, and Furu Wei. Beats: Audio pre-training with acoustic tokenizers. *arXiv preprint arXiv:2212.09058*, 2022.
- [13] An-Chieh Cheng, Yandong Ji, Zhaojing Yang, Xueyan Zou, Jan Kautz, Erdem Biyik, Hongxu Yin, Sifei Liu, and Xiaolong Wang. NaVILA: Legged Robot Vision-Language-Action Model for Navigation. *arXiv preprint arXiv:2412.04453*, 2024.
- [14] Xuxin Cheng, Jialong Li, Shiqi Yang, Ge Yang, and Xiaolong Wang. Open-television: Teleoperation with immersive active visual feedback. *arXiv preprint arXiv:2407.01512*, 2024.
- [15] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023.
- [16] Cheng Chi, Zhenjia Xu, Chuer Pan, Eric Cousineau, Benjamin Burchfiel, Siyuan Feng, Russ Tedrake, and Shuran Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. In *Proceedings of Robotics: Science and Systems (RSS)*, 2024.
- [17] OX-Embodiment Collaboration, A Padalkar, A Pooley, A Jain, A Bewley, A Herzog, A Irpan, A Khazatsky, A Rai, A Singh, et al. Open X-Embodiment: Robotic learning datasets and RT-X models. *arXiv preprint arXiv:2310.08864*, 1(2), 2023.
- [18] James W Cooley and John W Tukey. An algorithm for the machine calculation of complex fourier series. *Mathematics of computation*, 19(90):297–301, 1965.
- [19] Norman Di Palo and Edward Johns. Keypoint action tokens enable in-context imitation learning in robotics. In *Proceedings of Robotics: Science and Systems (RSS)*, 2024.
- [20] Ria Doshi, Homer Walke, Oier Mees, Sudeep Dasari, and Sergey Levine. Scaling cross-embodied learning: One policy for manipulation, navigation, locomotion and aviation. In *Conference on Robot Learning*, 2024.
- [21] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.
- [22] Patrick Esser, Robin Rombach, and Björn Ommer. Taming transformers for high-resolution image synthesis, 2020.
- [23] Scott Ettinger, Shuyang Cheng, Benjamin Caine, Chenxi Liu, Hang Zhao, Sabeek Pradhan, Yuning Chai, Ben Sapp, Charles R. Qi, Yin Zhou, Zoey Yang, Aurélien Chouard, Pei Sun, Jiquan Ngiam, Vijay Vasudevan, Alexander McCauley, Jonathon Shlens, and Dragomir Anguelov. Large scale interactive motion forecasting for autonomous driving: The waymo open motion dataset. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9710–9719, October 2021.
- [24] Hao-Shu Fang, Hongjie Fang, Zhenyu Tang, Jirong Liu, Chenxi Wang, Junbo Wang, Haoyi Zhu, and Cewu Lu. Rh20t: A comprehensive robotic dataset for learning diverse skills in one-shot. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 653–660. IEEE, 2024.
- [25] Kuan Fang, Fangchen Liu, Pieter Abbeel, and Sergey Levine. Moka: Open-world robotic manipulation through mark-based visual prompting. *Robotics: Science and Systems (RSS)*, 2024.
- [26] Zipeng Fu, Qingqing Zhao, Qi Wu, Gordon Wetzstein, and Chelsea Finn. Humanplus: Humanoid shadowing and imitation from humans. In *Conference on Robot Learning (CoRL)*, 2024.
- [27] Philip Gage. A new algorithm for data compression. *The C Users Journal*, 12(2):23–38, 1994.
- [28] Dan Gillick, Cliff Brunk, Oriol Vinyals, and Amarnag Subramanya. Multilingual language processing from bytes, 2016. URL <https://arxiv.org/abs/1512.00103>.
- [29] Yuan Gong, Yu-An Chung, and James Glass. AST: Audio Spectrogram Transformer. In *Proc. Interspeech 2021*, pages 571–575, 2021. doi: 10.21437/Interspeech.2021-698.
- [30] Irmak Guzey, Yinlong Dai, Georgy Savva, Raunaq Bhirangi, and Lerrel Pinto. Bridging the human to robot dexterity gap through object-oriented rewards, 2024. URL <https://arxiv.org/abs/2410.23289>.

- [31] Huy Ha, Yihuai Gao, Zipeng Fu, Jie Tan, and Shuran Song. UMI on legs: Making manipulation policies mobile with manipulation-centric whole-body controllers. In *Proceedings of the 2024 Conference on Robot Learning*, 2024.
- [32] Wenlong Huang, Chen Wang, Yunzhu Li, Ruohan Zhang, and Li Fei-Fei. Rekep: Spatio-temporal reasoning of relational keypoint constraints for robotic manipulation. *arXiv preprint arXiv:2409.01652*, 2024.
- [33] David A. Huffman. A method for the construction of minimum-redundancy codes. *Proceedings of the IRE*, 40(9):1098–1101, 1952. doi: 10.1109/JRPROC.1952.273898.
- [34] Huiwon Jang, Sihyun Yu, Jinwoo Shin, Pieter Abbeel, and Younggyo Seo. Efficient long video tokenization via coordinated-based patch reconstruction. *arXiv preprint arXiv:2411.14762*, 2024.
- [35] Zhenyu Jiang, Yuqi Xie, Kevin Lin, Zhenjia Xu, Weikang Wan, Ajay Mandlekar, Linxi Fan, and Yuke Zhu. Dexmimicgen: Automated data generation for bimanual dexterous manipulation via imitation learning. *arXiv preprint arXiv:2410.24185*, 2024.
- [36] Joshua Jones, Oier Mees, Carmelo Sferrazza, Kyle Stachowicz, Pieter Abbeel, and Sergey Levine. Beyond sight: Finetuning generalist robot policies with heterogeneous sensors via language grounding. *arXiv preprint arXiv:2501.04693*, 2025.
- [37] Siddharth Karamcheti, Suraj Nair, Ashwin Balakrishna, Percy Liang, Thomas Kollar, and Dorsa Sadigh. Prismatic vlms: Investigating the design space of visually-conditioned language models. In *International Conference on Machine Learning (ICML)*, 2024.
- [38] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, Peter David Fagan, Joey Hejna, Masha Itkina, Marion Lepert, Yecheng Jason Ma, Patrick Tree Miller, Jimmy Wu, Suneel Belkhale, Shivin Dass, Huy Ha, Arhan Jain, Abraham Lee, Youngwoon Lee, Marius Memmel, Sungjae Park, Ilija Radosavovic, Kaiyuan Wang, Albert Zhan, Kevin Black, Cheng Chi, Kyle Beltran Hatch, Shan Lin, Jingpei Lu, Jean Mercat, Abdul Rehman, Pannag R Sanketi, Archit Sharma, Cody Simpson, Quan Vuong, Homer Rich Walke, Blake Wulfe, Ted Xiao, Jonathan Heewon Yang, Arefeh Yavary, Tony Z. Zhao, Christopher Agia, Rohan Baijal, Mateo Guaman Castro, Daphne Chen, Qiuyu Chen, Trinity Chung, Jaimyn Drake, Ethan Paul Foster, Jensen Gao, David Antonio Herrera, Minh Heo, Kyle Hsu, Jiaheng Hu, Donovan Jackson, Charlotte Le, Yunshuang Li, Kevin Lin, Roy Lin, Zehan Ma, Abhiram Maddukuri, Suvir Mirchandani, Daniel Morton, Tony Nguyen, Abigail O’Neill, Rosario Scalise, Derick Seale, Victor Son, Stephen Tian, Emi Tran, Andrew E. Wang, Yilin Wu, Annie Xie, Jingyun Yang, Patrick Yin, Yunchu Zhang, Osbert Bastani, Glen Berseth, Jeannette Bohg, Ken Goldberg, Abhinav Gupta, Abhishek Gupta, Dinesh Jayaraman, Joseph J Lim, Jitendra Malik, Roberto Martín-Martín, Subramanian Ramamoorthy, Dorsa Sadigh, Shuran Song, Jiajun Wu, Michael C. Yip, Yuke Zhu, Thomas Kollar, Sergey Levine, and Chelsea Finn. Droid: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.
- [39] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [40] Lucy Lai, Ann ZX Huang, and Samuel J Gershman. Action chunking as conditional policy compression.
- [41] Seungjae Lee, Yibin Wang, Haritheja Etukuru, H. Jin Kim, Nur Muhammad Mahi Shafuallah, and Lerrel Pinto. Behavior generation with latent actions. *arXiv preprint arXiv:2403.03181*, 2024.
- [42] Toru Lin, Yu Zhang, Qiyang Li, Haozhi Qi, Brent Yi, Sergey Levine, and Jitendra Malik. Learning visuotactile skills with two multifingered hands. *arXiv:2404.16823*, 2024.
- [43] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36, 2024.
- [44] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [45] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.
- [46] Jianlan Luo, Zheyuan Hu, Charles Xu, You Liang Tan, Jacob Berg, Archit Sharma, Stefan Schaal, Chelsea Finn, Abhishek Gupta, and Sergey Levine. Serl: A software suite for sample-efficient robotic reinforcement learning, 2024.
- [47] Ajay Mandlekar, Yuke Zhu, Animesh Garg, Jonathan Booher, Max Spero, Albert Tung, Julian Gao, John Emmons, Anchit Gupta, Emre Orbay, et al. Roboturk: A crowdsourcing platform for robotic skill learning through imitation. In *Conference on Robot Learning*, pages 879–893. PMLR, 2018.
- [48] Fabian Mentzer, David Minnen, Eirikur Agustsson, and Michael Tschannen. Finite scalar quantization: Vq-vae made simple, 2023. URL <https://arxiv.org/abs/2309.15505>.
- [49] Atharva Mete, Haotian Xue, Albert Wilcox, Yongxin Chen, and Animesh Garg. Quest: Self-supervised skill abstractions for learning continuous control, 2024. URL <https://arxiv.org/abs/2407.15840>.
- [50] Soroush Nasiriany, Fei Xia, Wenhao Yu, Ted Xiao, Jacky Liang, Ishita Dasgupta, Annie Xie, Danny Driess, Ayzaan Wahid, Zhuo Xu, et al. Pivot: Iterative visual prompting elicits actionable knowledge for vlms. In *Forty-first*

- International Conference on Machine Learning*, 2024.
- [51] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Charles Xu, Jianlan Luo, Tobias Kreiman, You Liang Tan, Pannag Sanketi, Quan Vuong, Ted Xiao, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, Delft, Netherlands, 2024.
- [52] Open X-Embodiment Collaboration, Abhishek Padalkar, Acorn Pooley, Ajinkya Jain, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anikait Singh, Anthony Brohan, Antonin Raffin, Ayzaan Wahid, Ben Burgess-Limerick, Beomjoon Kim, Bernhard Schölkopf, Brian Ichter, Cewu Lu, Charles Xu, Chelsea Finn, Chenfeng Xu, Cheng Chi, Chenguang Huang, Christine Chan, Chuer Pan, Chuyuan Fu, Coline Devin, Danny Driess, Deepak Pathak, Dhruv Shah, Dieter Buehler, Dmitry Kalashnikov, Dorsa Sadigh, Edward Johns, Federico Ceola, Fei Xia, Freek Stulp, Gaoyue Zhou, Gaurav S. Sukhatme, Gautam Salhotra, Ge Yan, Giulio Schiavi, Hao Su, Hao-Shu Fang, Haochen Shi, Heni Ben Amor, Henrik I Christensen, Hiroki Furuta, Homer Walke, Hongjie Fang, Igor Mordatch, Ilija Radosavovic, Isabel Leal, Jacky Liang, Jaehyung Kim, Jan Schneider, Jasmine Hsu, Jeannette Bohg, Jeffrey Bingham, Jiajun Wu, Jialin Wu, Jianlan Luo, Jiayuan Gu, Jie Tan, Jihoon Oh, Jitendra Malik, Jonathan Tompson, Jonathan Yang, Joseph J. Lim, João Silvério, Junhyek Han, Kanishka Rao, Karl Pertsch, Karol Hausman, Keegan Go, Keerthana Gopalakrishnan, Ken Goldberg, Kendra Byrne, Kenneth Oslund, Kento Kawaharazuka, Kevin Zhang, Keyvan Majd, Krishan Rana, Krishnan Srinivasan, Lawrence Yunliang Chen, Lerrel Pinto, Liam Tan, Lionel Ott, Lisa Lee, Masayoshi Tomizuka, Maximilian Du, Michael Ahn, Mingtong Zhang, Mingyu Ding, Mohan Kumar Srirama, Mohit Sharma, Moo Jin Kim, Naoaki Kanazawa, Nicklas Hansen, Nicolas Heess, Nikhil J Joshi, Niko Suenderhauf, Norman Di Palo, Nur Muhammad Mahi Shafiullah, Oier Mees, Oliver Kroemer, Pannag R Sanketi, Paul Wohlhart, Peng Xu, Pierre Sermanet, Priya Sundaesan, Quan Vuong, Rafael Rafailov, Ran Tian, Ria Doshi, Roberto Martín-Martín, Russell Mendonca, Rutav Shah, Ryan Hoque, Ryan Julian, Samuel Bustamante, Sean Kirmani, Sergey Levine, Sherry Moore, Shikhar Bahl, Shivin Dass, Shuran Song, Sichun Xu, Siddhant Halder, Simeon Adebola, Simon Guist, Soroush Nasiriany, Stefan Schaal, Stefan Welker, Stephen Tian, Sudeep Dasari, Suneel Belkhale, Takayuki Osa, Tatsuya Harada, Tatsuya Matsushima, Ted Xiao, Tianhe Yu, Tianli Ding, Todor Davchev, Tony Z. Zhao, Travis Armstrong, Trevor Darrell, Vidhi Jain, Vincent Vanhoucke, Wei Zhan, Wenxuan Zhou, Wolfram Burgard, Xi Chen, Xiaolong Wang, Xinghao Zhu, Xuanlin Li, Yao Lu, Yevgen Chebotar, Yifan Zhou, Yifeng Zhu, Ying Xu, Yixuan Wang, Yonatan Bisk, Yoonyoung Cho, Youngwoon Lee, Yuchen Cui, Yueh hua Wu, Yujin Tang, Yuke Zhu, Yunzhu Li, Yusuke Iwasawa, Yutaka Matsuo, Zhuo Xu, and Zichen Jeff Cui. Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>, 2023.
- [53] Artidoro Pagnoni, Ram Pasunuru, Pedro Rodriguez, John Nguyen, Benjamin Muller, Margaret Li, Chunting Zhou, Lili Yu, Jason Weston, Luke Zettlemoyer, Gargi Ghosh, Mike Lewis, Ari Holtzman†, and Srinivasan Iyer. Byte latent transformer: Patches scale better than tokens. 2024. URL <https://github.com/facebookresearch/blt>.
- [54] Haozhi Qi, Ashish Kumar, Roberto Calandra, Yi Ma, and Jitendra Malik. In-hand object rotation via rapid motor adaptation, 2022. URL <https://arxiv.org/abs/2210.04887>.
- [55] Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. 2019.
- [56] Scott Reed, Konrad Zolna, Emilio Parisotto, Sergio Gómez Colmenarejo, Alexander Novikov, Gabriel Barth-marón, Mai Giménez, Yury Sulsky, Jackie Kay, Jost Tobias Springenberg, et al. A generalist agent. *Transactions on Machine Learning Research*, 2022.
- [57] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. *arXiv preprint arXiv:1508.07909*, 2015.
- [58] Himanshu Gaurav Singh, Antonio Loquercio, Carmelo Sferrazza, Jane Wu, Haozhi Qi, Pieter Abbeel, and Jitendra Malik. Hand-object interaction pretraining from videos, 2024. URL <https://arxiv.org/abs/2409.08273>.
- [59] Aaron van den Oord, Oriol Vinyals, and Koray Kavukcuoglu. Neural discrete representation learning, 2018. URL <https://arxiv.org/abs/1711.00937>.
- [60] Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. BridgeData v2: A dataset for robot learning at scale. In *Conference on Robot Learning*, pages 1723–1736. PMLR, 2023.
- [61] Gregory K Wallace. The jpeg still picture compression standard. *IEEE transactions on consumer electronics*, 38 (1):xviii–xxxiv, 1992.
- [62] Lirui Wang, Xinlei Chen, Jialiang Zhao, and Kaiming He. Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024.
- [63] Junjie Wen, Yichen Zhu, Jinming Li, Minjie Zhu, Kun Wu, Zhiyuan Xu, Ning Liu, Ran Cheng, Chaomin Shen, Yaxin Peng, Feifei Feng, and Jian Tang. Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2409.12514*, 2024.
- [64] Wilson Yan, Matei Zaharia, Volodymyr Mnih, Pieter Abbeel, Aleksandra Faust, and Hao Liu. Elastictok: Adaptive tokenization for image and video. *arXiv preprint arXiv:2410.08368*, 2024.
- [65] Seonghyeon Ye, Joel Jang, Byeongguk Jeon, Sejeun Joo,

- Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, et al. Latent action pretraining from videos. *arXiv preprint arXiv:2410.11758*, 2024.
- [66] Lijun Yu, Yong Cheng, Kihyuk Sohn, José Lezama, Han Zhang, Huiwen Chang, Alexander G. Hauptmann, Ming-Hsuan Yang, Yuan Hao, Irfan Essa, and Lu Jiang. Magvit: Masked generative video transformer, 2023. URL <https://arxiv.org/abs/2212.05199>.
 - [67] Michał Zawalski, William Chen, Karl Pertsch, Oier Mees, Chelsea Finn, and Sergey Levine. Robotic control via embodied chain-of-thought reasoning. In *Conference on Robot Learning*, 2024.
 - [68] Neil Zeghidour, Alejandro Luebs, Ahmed Omran, Jan Skoglund, and Marco Tagliasacchi. Soundstream: An end-to-end neural audio codec, 2021. URL <https://arxiv.org/abs/2107.03312>.
 - [69] Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
 - [70] Tony Z Zhao, Jonathan Tompson, Danny Driess, Pete Florence, Kamyar Ghasemipour, Chelsea Finn, and Ayzaan Wahid. Aloha unleashed: A simple recipe for robot dexterity. *arXiv preprint arXiv:2410.13126*, 2024.
 - [71] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3d-vla: A 3d vision-language-action generative world model. *arXiv preprint arXiv:2403.09631*, 2024.
 - [72] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3d-vla: 3d vision-language-action generative world model. *arXiv preprint arXiv:2403.09631*, 2024.
 - [73] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. *arXiv preprint arXiv:2412.10345*, 2024.
 - [74] Zhiyuan Zhou, Pranav Atreya, Abraham Lee, Homer Walke, Oier Mees, and Sergey Levine. Autonomous improvement of instruction following skills via foundation models. In *Conference on Robot Learning*, 2024.
 - [75] Jacob Ziv and Abraham Lempel. Compression of individual sequences via variable-rate coding. *IEEE transactions on Information Theory*, 24(5):530–536, 1978.

附录

A. 训练通用分词器的数据混合

通用分词器的训练混合主要由第六-F 节中描述的 π_0 [7] 数据集组成。对于许多数据集，我们包含了多种动作空间参数化版本：关节空间、末端执行器世界坐标系和末端执行器相机坐标系，以确保所得分词器的通用性。开放 X-Embodiment[52]、DROID[38] 和 Bridge V2[60] 以其原始形式包含在内。在分词之前，所有动作都被填充到 32 维，以适应不同维度的动作空间。

Dataset Name	Morphology	Action Space	Control Frequency (Hz)	Mixture Weight (%)
ARX	Bi-manual	Joint	50	7.2
AgileX	Bi-manual	Joint	50	1.8
Fibocom	Mobile	Joint	50	2.9
Franka FR3	Single arm	Joint	20	3.7
Mobile Trossen	Mobile	Joint	50	2.5
Trossen Biarm	Bi-manual	Joint	50	4.3
UR5 single	Single arm	Joint	20	10.3
UR5 biarm	Bi-manual	Joint	20	2.4
ARX slate mobile	Mobile	Joint	50	2.5
ARX EE	Bi-manual	EE	50	3.6
AgileX EE	Bi-manual	EE	50	0.9
Fibocom EE	Mobile	EE	50	1.4
Franka FR3 EE	Single arm	EE	20	1.9
Mobile Trossen EE	Mobile	EE	50	1.2
Trossen Biarm EE	Bi-manual	EE	50	2.1
UR5 single EE	Single arm	EE	20	5.2
UR5 biarm EE	Bi-manual	EE	20	1.2
ARX slate mobile EE	Mobile	EE	50	1.2
ARX Cam	Bi-manual	CamFrame	50	3.6
AgileX Cam	Bi-manual	CamFrame	50	0.9
Fibocom Cam	Mobile	CamFrame	50	1.4
Franka FR3 Cam	Single arm	CamFrame	20	1.9
Mobile Trossen Cam	Mobile	CamFrame	50	1.2
Trossen Biarm Cam	Bi-manual	CamFrame	50	2.1
UR5 single Cam	Single arm	CamFrame	20	5.2
UR5 biarm Cam	Bi-manual	CamFrame	20	1.2
ARX slate mobile Cam	Mobile	CamFrame	50	1.2
ALOHA [69]	Bi-manual	Joint	50	5.0
DROID [38]	Single arm	Joint	15	11.2
Bridge V2 [60]	Single arm	EE	5	5.0
OpenX [52]	Single arm	EE	mixed	3.8

B. 压缩与重建之间的权衡

C. 策略训练

我们使用 π_0 [7] 和 OpenVLA[39] 骨干网络训练策略。根据任务的不同，策略以两幅或三幅输入图像为条件（一个第三人称相机，每个机器人手臂一个腕部相机），分辨率为 224x224 像素。VLA 骨干网络通过预训练的视觉编码器分别对每幅图像进行编码，并将生成的标记拼接起来。此外，我们还以自然语言任务指令和机器人的本体感受状态为条件。两者都通过 LLM 的语言分词器进行分词，将其视为字符串。对于本体感受状态，我们应用分箱分词预处理，类似于 RT-2 的动作分词 [10]，离散化为 256 个箱。然后，我们将整数作为文本输入序列的一部分进行分词。请注意，简单的分箱分词方案对于本体感受状态是足够的，因为它是




图 12: 六个训练数据集上压缩-重建权衡的比较。任何离散化方法都包含一些超参数，用于控制重建保真度与压缩水平之间的权衡，这里表示为输出中的标记数量（所有分词器的词汇量保持不变）。我们扫描该超参数（FAST：舍入尺度；朴素分词：子采样频率；FSQ：潜在标记数量），发现 FAST 在广泛的尺度范围内表现良好。特别是，尽管在低保真度下其效率低于基于 VQ 的分词器，但在更高重建保真度方面表现出更好的扩展性，使 FAST 更适用于细粒度控制问题。还展示了每种分词器的具体实例（FAST+，以及无子采样的朴素分词）。

策略的输入（与动作输出相反，动作输出需要高级分词，正如我们的实验所证明的那样）。我们使用短线性学习率预热（1k 步）训练所有策略，然后使用 5e-5 的恒定学习率。我们使用 AdamW 优化器 [45] ($b_1 = 0.9$, $b_2 = 0.95$)，不使用权重衰减，将梯度幅度裁剪为 1，并计算网络权重的 EMA，权重为 0.999。在推理过程中，我们使用简单的贪婪自回归

解码时，除双臂机器人任务（叠 T 恤、从烤面包机取吐司、叠衣物）外，我们发现较小的温度参数 $\beta = 0.7$ 有助于策略离开初始位置（因为部分数据包包含训练回合开始时机器人悬停在初始位置的静止动作片段）。

D. DROID 策略设置

此处，我们提供 DROID 训练设置的更多细节，以便他人复现并基于我们的结果进行扩展。在 DROID 数据集上训练时，策略以单一第三人称视角和腕部相机视角为条件。由于 DROID 为每个回合提供两个外部相机视角，我们在训练期间随机采样第三人称视角。类似地，DROID 为每个训练回合提供三条自然语言标注，我们在训练期间对它们进行随机化。我们不使用相机标定信息。因此，训练好的策略可以直接在新视角下测试，无需标定。我们使用关节速度和绝对夹爪位置动作空间，并训练策略预测 15 步动作块（推理时我们开环执行 8 步或 15 步动作块）。我们应用轻量数据策展：仅训练标记为“成功”的回合（7.5 万个回合），并在训练期间过滤掉所有零动作的空闲时间步（通常是数据收集期间遥操作员重置虚拟现实控制器位置的时间步）。除此之外，我们发现使用完整数据集训练效果良好，尽管通过更精细的策展可能仍有提升性能的潜力。我们训练策略三个训练轮次（24 万次迭代，批大小为 256），在 8 块 H100 GPU 上对 30 亿参数视觉语言动作模型大约需要 4 天。

E. 评估任务与训练数据集

下面，我们描述实验中使用的评估任务和训练数据集。我们详细说明初始条件分布和评分标准。

Libero。 我们遵循刘等人（Liu et al.）的训练与评估设置 [43]。我们在 **Libero-Spatial**、**Libero-Object**、**Libero-Goal** 和 **Libero-Long** 基准套件上进行评估，并使用作者提供的相应数据集进行训练。我们将所有数据集合并为一个包含 27 万样本的数据集，并联合训练一个策略以减少需要训练的策略数量。我们总共训练所有策略 4 万次迭代（ ≈ 40 个训练轮次）。我们使用金等人（Kim et al.）重新渲染的数据集 [39] 进行实验。成功按每个回合的二元标准进行评估。

餐桌清理。 该任务要求单个 UR5e 机械臂通过将物体（垃圾、盘子和碟子的混合物）放入垃圾桶或清理箱来清理餐桌。训练数据集包含随机清理场景中的演示，大约有 70 个物体。评估场景如图 13a 所示，包含桌子上未见配置的十二个物体。该场景旨在考验模型的能力，故意将餐具放在垃圾上、物体相互遮挡，以及具有挑战性的物体，如




(a) Table Bussing



(b) T-Shirt Folding



(c) Grocery Bagging



(d) Toast out of Toaster



(e) Laundry Folding

图 13: 评估任务的采样初始配置。

筷子、透明塑料和反光容器。总分计算为正确丢弃或放入箱中的物体百分比。

T 恤折叠。 该任务要求双臂 ARX 机器人折叠一件 T 恤。训练数据集包含约 150 件衬衫的折叠演示，尺寸、

颜色和款式各异。评估场景如图 13b 所示，循环展示五件不同颜色和尺寸的已见衬衫，每件从平铺配置开始。总分计算为成功折叠的衬衫百分比，由人工评分员判定。

杂货装袋。该任务要求单个 UR5e 机器人手臂将杂货装入袋中。该任务在 Black 等人 [7] 中详述的全混合预训练模型上进行了开箱即用评估。评估场景如图 13c 所示，包含七件物品（形状、尺寸、材质和重量各异）和一个大型纸质杂货袋。总分按放入杂货袋的物品百分比计算。

从烤面包机中取出吐司。该任务要求一个双臂 Trossen ViperX 机器人（镜像 ALOHA[70] 设置）从烤面包机中取出两片吐司并将其放到盘子上。该任务在 Black 等人 [7] 中详述的全混合预训练模型上进行了开箱即用评估。评估场景如图 13d 所示，总分跟踪任务进度，每取出一片吐司得一分，每将其放到盘子上得一分，满分为四分。

叠衣服。该任务要求一个双臂 ARX 机器人从洗衣篮中取出一件衣物（短裤或 T 恤）并将其折叠。这是一项极具挑战性的任务，因为成功折叠缠绕的衣物需要在开始折叠前进行多个展开和铺平步骤。遵循 Black 等人 [7] 的方法，该任务使用在 Black 等人 [7] 中详述的全 π_0 训练混合上预训练并用少量高质量任务特定数据微调的模型进行评估。评估场景如图 13e 所示，包含五件随机放置在洗衣篮中的衣物。总分按由人工评分员判定成功折叠并堆叠的衣物百分比计算。

DROID。我们在 DROID 数据集的所有成功回合（75k 个回合，21M 个样本）上训练 240k 次迭代（ ≈ 3 个回合）。我们应用了轻量级数据策展（见附录 D）。训练后，我们在新场景中零样本部署策略，这些场景具有未见过的背景、相机角度和物体。为了进行定量评估，我们设计了一个包含 16 个任务和每个策略总共 44 次试验的评估套件（见表 II）。每次试验都根据任务进度评分标准进行评分（例如，拾取正确物体得 1 分，将其放入正确容器得 1 分）。我们在图 14 中展示了定量评估的示例场景。我们进一步在三个不同的大学校园中对策略进行了各种真实世界设置的定性测试（见图 7）。在这些评估中，我们不测量成功率，但提供了大量成功和失败的定性视频，以帮助读者了解策略的能力。

表 II: DROID 评估任务。

Task	Trials
Put the spoon in the dish rack	4
Put carrot in bowl	4
Put plate in dish rack	2
Wipe the table	2
Put the plate on the table	2
Clean up the table	2
Close the drawer	4
Put the stapler on the notebook	2
Put stapler in the drawer	4
Clean the whiteboard	2
Put the marker in the cup	4
Put the black sponge in the blue bowl	2
Put the red bottle in the black bowl	2
Put the watermelon in the purple bowl	2
Move the watermelon from the purple bowl to the blue bowl	2
Put the tape in the purple bowl	2
Put the water bottle on the left side of the table	2
总计 44	



图 14: 用于定量 DROID 评估的设置。




图 15: π_0 -FAST 与计算匹配的扩散 π_0 [7] 通用策略的比较。 π_0 -FAST 在相同训练计算量下明显优于扩散 VLA，这是由于其更快的收敛速度。报告：均值和 95% 置信区间。

表 III: 通用分词器评估数据集。

Morphology	Dataset Name	Platform	Action Space	Action Dim	Control Frequency	Task
Single Arm	SOAR [74]	WidowX	EEF	7	5	Pick/place
	DROID-Eval EEF [38]	Franka	EEF	7	15	Pick/place
	DROID-Eval Joint [38]	Franka	Joint	8	15	Pick/place
	SERL [46]	Franka	EEF	7	10	Insertion
	π Table Bussing [7]	UR5	Joint	8	20	Pick/place
Dexterous	NYU DexHand [30]	ALLEGRO	Joint+EEF	30	16	Dexterous manipulation
	Berkeley DexHand [54]	ALLEGRO	Joint	16	20	In-hand manipulation
	Berkeley DexArm [58]	xArm+ALLEGRO	Joint	23	20	Dextrous pick/place
	HATO [42]	UR5+Psyonic Hand	EEF+Joint	24	10	Dextrous pick/place
UMI	UMI [16]	UMI	EEF	7	20	Pick/place
	UMI on Legs [31]	UMI	EEF	7	20	Whole-body manipulation
Humanoid	HumanPlus [26]	Unitree H1	Joint	40	50	Whole-body manipulation
	UCSD TeleVision [14]	Unitree H1 w/Neck	Joint	28	60	Manipulation+active perception
Navigation	Waymo [23]	Waymo Car	2D delta	2	10	Autonomous Driving