

# StarVLA：面向视觉-语言-动作模型开发的乐高式代码库

StarVLA Community & Von Neumann Institute, HKUST

## Abstract

构建通用具身智能体需要整合感知、语言理解与动作执行，这些核心能力由基于多模态基础模型的视觉-语言-动作（VLA）方法所解决，包括视觉语言模型与世界模型的最新进展。尽管进展迅速，VLA 方法仍分散于互不兼容的架构、代码库与评估协议中，阻碍了原则性比较与可复现性。本文提出 **StarVLA**，一个面向 VLA 研究的开源代码库。**StarVLA** 从三个方面应对这些挑战。首先，它提供模块化的主干-动作头架构，同时支持 VLM 主干（如 Qwen-VL）与世界模型主干（如 Cosmos），并涵盖四种代表性动作解码范式，所有组件共享统一抽象，主干与动作头可独立替换。其次，它提供可复用的训练策略，包括跨具身学习与多模态协同训练，这些策略一致适用于所有支持的范式。第三，它通过统一的评估接口集成主要基准，包括 LIBERO、SimplerEnv、RoboTwin 2.0、RoboCasa-GR1 与 BEHAVIOR-1K，同时支持仿真与真实机器人部署。**StarVLA** 还附带简单、完全可复现的单基准训练方案，尽管数据工程极少，但已在多个基准上使用 VLM 与世界模型主干达到或超越先前方法。据我们所知，**StarVLA** 是目前最全面的开源 VLA 框架之一，我们期望它能降低复现现有方法与原型化新方法的门槛。**StarVLA** 正在积极维护

**并持续扩展；我们将随项目进展更新本报告。**代码与文档可在 [github.com/starVLA/starVLA](https://github.com/starVLA/starVLA) 获取。

**Date:** April 2026

**Project Page:** <https://starvla.github.io>

## 1 引言

具身智能正朝着通用智能体的方向发展，这类智能体在物理世界中整合感知、语言理解与行动，其进展部分得益于大型基础模型（Large Foundation Model）的近期突破（OpenAI, 2023; Bai et al., 2025a; Gao et al., 2025）。视觉-语言-动作（Vision-Language-Action, VLA）模型已成为实现这一目标的主导范式，并呈现出多样化的设计选择。现有方法大致可分为两类：基于视觉语言模型（VLM）的方法，其将语言模型的表征能力重新用于动作解码；以及基于世界模型的方法，其采用生成式架构联合建模动作分布与未来观测。尽管这两个方向均展现出巨大潜力，但它们往往各自独立发展，使用不同的代码库、接口假设和评估协议，这使得系统性地比较它们并理解不同设计选择之间的权衡变得困难。

**碎片化阻碍系统性探索。**尽管取得了这些进展，视觉-语言-动作（VLA）研究仍受到多个层面碎片化的阻碍。在架构层面，现有方法（Kim 等人, 2025; Brohan 等人, 2022, 2023; Bjorck 等人, 2025; Black 等人, 2024; Intelligence 等人, 2025a; Wu 等人, 2026; Li 等人, 2026）采用了多样化的动作解码设计，从视觉-语言模型原生方法（自回归分词、并行回归）到基于生成模型的方法（扩散、流匹配），这使得系统性的比较变得困难。

跨范式家族困难重重。在系统层面，方法发布时与模型架构、数据处理和训练流程紧密耦合，限制了跨项目的组件复用。在评估层面，结果报告在不相交的基准子集上，协议不一致，使得公平比较不可行。这些问题共同造成了视觉-语言-动作研究的“巴别塔”现象，思想难以比较、复现或重组。我们将这种碎片化归因于视觉-语言-动作系统缺乏统一的抽象。现有代码库（Bjorck et al., 2025; Black et al., 2024）大多针对特定方法，不支持（i）跨不同动作解码范式的模块化组合，（ii）跨异构数据源的可复用训练，或（iii）跨基准和实体的标准化评估与部署。

**StarVLA：探索具身智能的统一平台。**我们推出了 **StarVLA**，这是一个开源研究平台，将基于视觉语言模型（VLM）和基于世界模型的视觉语言动作（VLA）范式统一到一个模块化框架中。其核心设计是骨干网络-动作头分解，其中共享的视觉语言骨干网络对场景和指令进行编码，而可插拔的动作头将得到的表示映射为运动指令。这种表述足够灵活，能够支持广泛的现有方法，包括自回归分词、并行回归、流匹配去噪和双系统推理，其重新实现达到或在某些情况下超过了已报告的性能。在实践中，**StarVLA** 提供了三项核心能力：

- **统一的视觉语言动作（VLA）框架：**StarVLA 在共享的骨干网络-动作头抽象下实现了四种代表性范式（第 2 节）：StarVLA-FAST（自回归分词）、StarVLA-OFT（并行回归）、StarVLA- $\pi$ （流匹配去噪）和 StarVLA-GR00T（双系统推理）。至关重要的是，视觉语言模型骨干网络（例如 Qwen3-VL）和世界模型骨干网络（例如 Cosmos-Predict2）都作为即插即用的替代方案得到支持，从而能够在相同的训练和评估条件下直接比较基于视觉语言模型和基于世界模型的研究路径。所有变体共享相同的数据接口和下游基础设施；只有骨干网络或动作头不同，使研究人员能够在保持其他所有条件不变的情况下，隔离任何单一设计选择的影响。

- **灵活的训练方案：**StarVLA 将跨具身学习和多模态协同训练视为可复用的、与范式无关的配置，而非特定于方法的附加组件。相同的训练基础设施支持监督式动作学习、与网络规模的视觉语言数据进行协同训练以保持多模态推理能力，以及跨异构机器人数据集的跨具身预训练。每种训练方案统一适用于所有受支持的范式，从而可以轻松研究训练策略如何与不同的架构选择相互作用。

- **广泛的基准集成：**StarVLA 通过统一的服务器-客户端测试接口整合了五个主流基准（LIBERO、SimplerEnv、RoboTwin 2.0、RoboCasa-GR1 和 BEHAVIOR-1K），实现了跨环境和跨具身形式的受控比较。对于每个基准，我们提供了简单、完全可复现的训练方案，仅需极少的数据工程即可在视觉语言模型（VLM）和世界模型骨干网下达到具有竞争力或最先进的性能，降低了社区在此基础上构建的门槛。同一接口无需修改代码即可支持仿真评估和真实机器人部署，弥合了研究探索与实际部署之间的差距。

为了在现有生态系统中定位 StarVLA，我们在表 1 中将其与具有代表性的开源视觉语言动作（VLA）系统在关键能力上进行了比较。据我们所知，StarVLA 是首个在统一接口内整合这些能力的平台。借助该框架实现的受控比较，StarVLA 在多个基准上使用视觉语言模型和世界模型骨干网均达到了具有竞争力、在某些情况下最先进的性能，表明该平台不仅可作为研究工具包，还可作为强大且易于复现的基线提供者。

**一种广义的视觉语言动作（VLA）视角。**除了工程实用性之外，StarVLA 还提出了一个更广泛的视角来统一不同的视觉语言动作方法。经验上，我们发现单一骨干-动作头抽象可以容纳基于视觉语言模型的解码、基于生成模型的解码以及双系统架构，所有这些都在共享的数据管道、训练循环和评估协议内进行。这一观察表明，基于视觉语言模型的方法和基于世界模型的方法或许不应被理解为根本不同的范式，而应被视为一个共同结构框架内的变体，其主要区别在于辅助学习信号的形式（例如，语言对齐推理或未来观测预测）。我们将此称为广义视觉语言动作视角。这并非纯粹的概念观点，而是源于 StarVLA 实现的实用统一：当基础设施差异被最小化时，潜在的共性变得更加明显。我们希望这一视角能鼓励对机器人基础模型进行更系统、更累积的探索。

**表 1：代表性开源视觉-语言-动作系统比较。**模块化动作头：动作头可在共享骨干上即插即用。模块化视觉-语言模型：支持更换视觉-语言模型骨干。模块化世界模型：支持将世界模型作为视觉-语言骨干。混合数据源：内置用于异构数据源的混合数据加载器。开源多模态协同训练：支持开源多模态协同训练。开源跨具身协同训练：支持开源跨具身协同训练。仿真基准数量：集成仿真基准的数量（含评估代码）。多基准协同训练：将所有基准联合训练为一个模型。

| Framework                          | Modular Action Heads | Modular VLM | Modular WA | Mixture DS | Open-Source MM Co-train | Open-Source X-Emb. Co-train | #Bench | Multi-Bench Co-train |
|------------------------------------|----------------------|-------------|------------|------------|-------------------------|-----------------------------|--------|----------------------|
| OpenPI Intelligence et al. (2025a) | ✗                    | ✗           | ✗          | ✗          | ✗                       | ✗                           | 2      | ✗                    |
| Isaac-GR00T Bjorck et al. (2025)   | ✗                    | ✗           | ✗          | ✓          | ✗                       | ✓                           | 6      | ✗                    |
| OpenVLA-OFT Kim et al. (2025)      | ✗                    | ✗           | ✗          | ✗          | ✗                       | ✓                           | 1      | ✗                    |
| Dexbotic Contributors (2025)       | ✗                    | ✓           | ✗          | ✗          | ✓                       | ✗                           | 5      | ✗                    |
| X-VLA Zheng et al. (2025a)         | ✗                    | ✗           | ✗          | ✓          | ✗                       | ✓                           | 5      | ✗                    |
| <b>StarVLA (Ours)</b>              | ✓                    | ✓           | ✓          | ✓          | ✓                       | ✓                           | 7      | ✓                    |

## 2 视觉-语言-动作系统的统一框架

视觉-语言-动作模型的快速演进催生了大量异构设计，其预处理流程、模型边界和推理假设各不相同。这种多样性虽然有利于快速探索，但往往阻碍可复现性，并使公平比较变得困难。为解决这一问题，StarVLA 在系统层面采用统一的框架抽象：每种方法被实现为具有明确训练和推理接口的模块化组件，从而将算法差异隔离在最小的一组可互换模块中。

### 视觉-语言-动作系统的抽象。

除系统级抽象外，本文还引入了一种以策略为中心的统一视觉-语言-动作模型表述。以往工作通常区分基于视觉-语言模型的策略和基于世界模型的方法；本文则将二者置于以动作生成为核心的统一视角之下。




图 1：StarVLA 所采用的统一视觉-语言-动作表述的概念视图。策略  $\pi$  将视觉观测和语言指令映射为未来动作块。训练目标分解为  $\mathcal{L} = \mathcal{L}_{\text{action}} + \mathcal{L}_{\text{aux}}$ ，其中不同模型族对应不同形式的  $\mathcal{L}_{\text{aux}}$ 。

如图 1 所示，本文将视觉-语言-动作系统建模为一个策略，该策略将视觉-语言输入映射为未来动作序列及可选的辅助输出：

$$\pi(\mathbf{a}_{t:t+k}, \mathbf{y}_{\text{aux}} \mid \mathbf{x}_{\leq t}, \ell), \quad (1)$$

where:

- $\mathbf{x}_{\leq t} = \{o_{\leq t}^{\text{vis}}, o_{\leq t}^{\text{depth}}, o_{\leq t}^{\text{tactile}}, \dots\}$  表示截至时间  $t$  的多模态观测历史，其中可能包括视觉观测、深度图、触觉反馈、本体感受状态或其他传感器模态；
- $\ell$  是描述任务的语言指令；
- $\mathbf{a}_{t:t+k}$  表示从时间  $t$  到  $t+k$  预测的  $k$  步动作块；

- $y_{\text{aux}}$  表示未来时间范围内的可选辅助输出，例如预测的未来视觉观测  $t+1:t+k$ 、中间语言推理或子目标描述  $\ell_{\text{plan}}$ ，或其他模态预测。

该公式抽象掉了中间表示，并在存在潜在预测时隐式地对其边缘化，从而允许直接策略和基于模型的方法在通用接口内表达。

训练目标采用一般形式

$$\mathcal{L} = \mathcal{L}_{\text{action}} + \mathcal{L}_{\text{aux}}, \quad (2)$$

其中  $\mathcal{L}_{\text{action}}$  监督预测的动作， $\mathcal{L}_{\text{aux}}$  作为塑造所学表示的归纳偏置。不同的视觉语言动作（VLA）范式可以被解释为具有不同学习信号的该公式的实例化：

- **直接视觉语言动作（VLA）建模** 设置  $\mathcal{L}_{\text{aux}} = 0$ ，仅优化动作。
- 基于视觉语言模型的视觉语言动作模型引入了语言对齐的辅助目标，例如子任务规划、空间定位或结构化推理监督，要求模型生成语言标记作为辅助输出。
- 基于世界模型的视觉语言动作模型引入了未来观测预测（例如图像或视频），既可以作为辅助目标，也可以作为支持动作生成的隐式潜在结构，其中模型必须预测视觉状态作为辅助输出。

在这一视角下，看似不同的范式，如基于视觉语言模型、基于世界模型和直接策略，可以被理解为具有不同归纳偏置的共享策略公式的变体。这种视角简化了比较，同时与逐步执行和多步开环控制兼容。

## 2.1 背景：用于具身智能的视觉语言基础模型

具身智能体与物理世界持续交互，其中视觉作为感知场景结构、物体身份、空间关系和交互可供性的主要模式。

**视觉语言基础模型。**视觉的这一核心作用推动了视觉表示学习的进展，从监督模型如残差网络（ResNet）（He 等人，2016）和视觉变换器（Vision Transformers）（Dosovitskiy 等人，2021），到可扩展的自监督方法（Oquab 等人，2023）以及捕捉时间结构的视频预训练。基于这些骨干网络，语言对齐预训练（Radford 等人，2021；Zhai 等人，2023）实现了共享的视觉-语言表示，而可提示系统如分割一切模型（SAM）（Kirillov 等人，2023；Liu 等人，2023b）扩展了开放世界感知。与指令调优的视觉语言模型（Liu 等人，2023a；Chen 等人，2023；Karamcheti 等人，2024；Bai 等人，2025b；OpenAI，2024；Gemini 团队，谷歌，2024）和生成式视频模型（Gao 等人，2025；谷歌深度思维，2025）一起，这些进展显著增强了感知定位能力。然而，仅靠感知是不够的：具身智能体还必须对语言条件目标进行推理，并预测动作下的环境动态。现有模型并非天然为动作生成或视觉运动控制而设计（Zhao 等人，2023；Dhariwal 和 Nichol，2021；Ze 等人，2024）。

**用于机器人感知和推理的视觉语言建模。**视觉语言预训练将感知建立在语言之上，为任务指定和高层推理提供了可扩展的接口（Radford 等，2021；Zhai 等，2023）。扩展这一范式，视觉-语言-动作（VLA）模型引入动作监督，以统一感知、语言和控制（Brohan 等，2022，2023；Kim 等，2024；Black 等，2024；Intelligence 等，2025b；Bjorck 等，2025）。早期工作（Nair 等，2022；Xiao 等，2022）表明，强大的视觉先验能够改善控制，而 VLA 模型通过行为克隆或策略学习直接将观测和指令映射为动作。通过将大规模语义知识迁移到控制中，它们提升了指令遵循和跨任务泛化能力，通常优于先前的机器人策略（Zhao 等，2023；Chi 等，2024a；Ze 等，2024）。近期工作将这些模型扩展到人形机器人移动操作（Wei 等，2026）。为了保持推理能力，后续方法探索了多模态协同训练（Driess 等，2025；Ye 等，2026a；Chen 等，2025c；Zeng 等，2024；Yang 等，2025c；Zhou 等，2025），而另一些方法则扩展了遥操作数据集（Collaboration 等，2023；Khazatsky 等，2024；Wu 等，2024；AgiBot，2025；Ebert 等，2021；Duan 等，2024）。然而，这些数据集在任务、语言和场景多样性方面仍然有限（Shi 等，2025；Chi 等，2024b），这促使了便携式数据收集的发展（Generalist AI，2025；Liu 等，2024b；Chi 等，2024b）。与此同时，紧密耦合的流程阻碍了可复现性、模块化和可扩展性，凸显了对统一框架的需求。

**基于视频的世界模型，用于机器人动力学与交互。**与基于语言的扩展正交，基于视频的世界模型通过视觉预测学习物理动力学。视频比静态数据更有效地捕捉运动、接触和因果关系。早期方法通过预测性潜在建模增强视觉-语言-动作策略（Zheng 等，2025b; Bjorck 等，2025; Ye 等，2025），而大规模视频预训练使得仅需极少机器人数据即可进行规划（Assran 等，2025; Jang 等，2025）。后续工作将视频视为主要策略基底，要么统一策略、仿真和评估，要么将规划与控制解耦（Du 等，2023; Ko 等，2024; Pai 等，2025; Chen 等，2025a）。动作条件世界模型进一步支持策略评估与改进：想象推演达到强大性能（Wu 等，2023），而近期系统支持反事实重放与安全评估（1X 世界模型团队，2025; Team 等，2025）。其他方法利用可控世界模型进行轨迹生成、强化学习或可扩展的数据综合（Guo 等，2025; Jiang 等，2026; GigaWorld 团队等，2025; GigaBrain 团队等，2026; Qiu 等，2026）。近期工作强调因果一致性、可控性和闭环效率，通过将动作和价值预测集成到预训练视频模型中，或联合学习动力学与控制（Kim 等，2026; Li 等，2026; Cai 等，2026; Gao 等，2026; Zhu 等，2025; Yuan 等，2025）。一些方法将联合视频-动作预测表述为策略学习，或分析测试时想象与协同训练带来的增益（Ye 等，2026b; Yuan 等，2026）。此外，人类视频提供了可扩展的运动先验，以自我为中心的流程使得跨任务和具身形态的可迁移行为成为可能（Hoque 等，2025; Yang 等，2025b; Zheng 等，2026）。

在视觉语言预训练和基于视频的世界建模之上，沿互补但基本割裂的轴扩展具身智能，这促使 StarVLA 的设计选择将方法间应变化的内容与训练、评估和部署中应保持稳定的内容分离开来。

## 2.2 在视觉语言基础模型上构建视觉-语言-动作框架

尽管上述综述的基础模型提供了强大的视觉-语言表征，但它们并非原生为动作生成而设计。StarVLA 的一个关键设计目标是把这些视觉-语言基础模型转变为视觉-语言-动作就绪：我们提供了一个统一的输入输出接口契约和一个组合式架构，允许在相同的视觉-语言骨干上灵活组合多种动作解码策略。

**统一输入输出接口。**StarVLA 中的所有框架模块均继承自一个公共基类，并暴露两个共享统一输入输出接口的方法：训练和推理均消耗原始的、环境级别的观测，与机器人在部署时接收到的观测完全相同。

- 前向（{原始图像，字符串，...}） → {原始图像，字符串，...}：训练入口点。它接收一批原始样本，每个样本包含多视角 RGB 图像、一条自然语言指令和一个动作块，并返回一个损失字典。
- `predict_action({raw 图像，字符串，...})` → {归一化动作，...}：推理入口点。它接受相同的观测格式（减去真值动作）并返回预测的动作块。

通过刻意采用这种统一的输入输出接口，其中训练输入镜像真实部署观测，而非依赖重度预处理的数据加载器张量，我们最小化了训练与测试分布不匹配，这是视觉-语言-动作系统中性能静默退化的常见来源。

这一设计选择反映了机器人部署的一个更深层不变量：无论不同的视觉-语言基础模型如何预训练——它们采用何种分词方案、如何调整图像大小或划分图像、或在预训练期间优化何种辅助目标——在推理时，每个模型最终都必须接受物理机器人提供的相同原始传感器流，并产生可执行的电机命令。统一输入输出接口将这一部署时不变量编码为系统的一等契约，确保任何推理路径能够消耗原始观测的视觉-语言模型都能立即与 StarVLA 兼容，而无需用户逆向工程或复制模型特定的预处理流水线。至关重要的是，这一相同的不变量驱动原则自然延伸到内部架构，正如我们接下来所述。

**组合式框架。**在内部应用同样的原则，我们将每种视觉-语言-动作方法分解为两个明确分离的组件，并通过标准化的表示契约连接：一个视觉-语言骨干网络（例如 Qwen2.5-VL），它消费原始多模态观测，并通过通用输出规范暴露隐藏状态表示；以及一个可插拔的动作头，它通过相应的输入规范读取这些表示，并将其转换为运动指令。每个框架都通过相同的两步组合来组装自身（首先加载骨干网络，然后附加动作头），

两个组件都通过 YAML 进行声明式配置。由于外部系统边界（原始观测  $\rightarrow$  动作）和内部骨干-头边界（多模态输入  $\rightarrow$  隐藏状态  $\rightarrow$  动作）都受标准化契约约束，StarVLA 实现了双向模块化：骨干网络和动作头可以各自独立替换，而不会影响对方或任何周围基础设施。

这种模块化为视觉-语言-动作开发的不同阶段提供了灵活性。对于研究人员，它支持在多个方向上进行快速实验。新的动作解码范式可以通过实现并注册一个动作头模块来原型化，而新的视觉-语言骨干网络——例如指令微调的视觉-语言模型（如 Qwen2.5-VL (Bai 等人, 2025b)、InternVL (Cai 等人, 2026)）或视频原生模型（如 Cosmos (Kim 等人, 2026)）——可以通过符合共享表示接口的轻量级适配器进行集成。一旦集成，这些骨干网络可以在不同的动作头上进行评估，而无需针对每种方法进行修改。对于训练基础设施，标准化接口允许大部分上游和下游栈（例如训练流水线、基准测试工具和部署服务）在很大程度上保持骨干网络和动作头无关，从而在引入新范式或模型时减少对方法特定代码路径的需求。对于部署，在不同骨干网络或动作范式之间切换可以通过配置更改来处理，而无需进行代码级修改。

## 2.3 代表性视觉-语言-动作实例化

在这一统一抽象下，我们实现了四种范式，涵盖当前视觉语言动作（VLA）文献中的主要动作解码家族，如图 2 所示。所有变体共享相同的视觉语言（VL）骨干网络、相同的基类以及相同的 `forward` / `predict_action` 契约，区别仅在于它们如何从骨干网络的表示中提取动作：




图 2：在统一接口下，StarVLA 中将视觉语言模型适配为视觉-语言-动作框架的四种代表性方法（FAST、OFT、 $\pi$  和 GR00T）概览。

- **StarVLA-FAST** ( $\pi_{\text{fast}}$ ): 在 VL 骨干网络上附加一个 FAST 分词器 (Pertsch 等人, 2025)，并通过下一词元预测自回归地生成离散动作词元，使用大语言模型 (LLM) 自身的词汇空间。
- **StarVLA-OFT**: 附加一个轻量级多层感知机 (MLP)，读取预定义动作词元的隐藏状态，并以并行方式回归连续动作 (L1 损失)，遵循 OpenVLA-OFT (Kim 等人, 2025) ——这是最简单的可插拔头形式。
- **StarVLA- $\pi$**  ( $\pi_0$ ): 集成一个逐层交叉 DiT 流匹配动作专家，通过交叉注意力以多层 VL 隐藏状态为条件，并通过迭代去噪预测连续动作，遵循  $\pi_0$  (Black 等人, 2024)。
- **StarVLA-GR00T**  
采用双系统设计，其中 VL 骨干网络作为系统 2（慢速推理），基于 DiT 的流匹配模块作为系统 1（快速动作生成），与 GR00T N1.5 (Bjorck 等人, 2025) 一致。该变体表明，即使在推理时计算模式根本不同的情况下，也能在同一接口下共存。

该谱系从视觉语言模型原生解码（自回归分词、并行回归）到与世界模型架构共享的基于生成模型的解码（迭代流匹配去噪、双系统推理），表明所提出的组合式架构与统一接口具有广泛的适用性。添加更多范式只需实现并注册一个新的动作头；骨干网络、训练循环和评估流程保持不变。



### 3 模型训练与测试的统一系统流程

StarVLA 代码库支持多种实用的视觉语言动作策略训练模式，涵盖从下游机器人数据集上的标准监督微调（SFT）到与视觉语言（VLM）网络数据的多目标协同训练，以及在混合机器人形态上的跨形态协同训练。所有训练流程均以基于 Accelerate + DeepSpeed 的显式 PyTorch 循环实现，用于分布式执行，同时在各方法间保持统一的 YAML 配置接口。图 3 总结了支持的训练模式以及数据流如何连接到统一模型框架。




图 3: StarVLA 框架概览。我们提出了一个统一且模块化的流程，将异构数据源、可插拔数据加载器和灵活的数据表示与标准化的模型前向接口相连接。该框架支持多种视觉语言基础模型和视觉语言动作架构，实现端到端的训练与部署。

#### 3.1 训练范式

##### 3.1.1 用于行为克隆的监督学习

最直接的训练模式是仅使用机器人数据的监督学习，策略被训练为根据观测和语言指令预测连续动作。在我们的代码库中，该训练路径在 `starVLA/training/train_starvla.py` 中实现。目标是由框架 `forward()` 方法返回的动作建模损失（例如，输出字典中的 `action_loss`）。

**优化设置。** 本文支持（一）全参数微调，以及（二）通过 `trainer.freeze_modules`（逗号分隔的模块路径）选择性冻结子模块。为在异构组件间稳定训练，优化器可采用多个参数组，并配置不同学习率（例如，为 `qwen_vl_interface` 与动作模型分别设置学习率），由 `trainer.learning_rate` 进行配置。训练过程采用 `bfloat16` 自动混合精度、梯度累积、梯度裁剪，以及带最小学习率的余弦调度。

##### 3.1.2 面向具身推理的多目标协同训练

仅使用机器人数据进行监督微调（SFT）可能使视觉语言模型（VLM）主干过度特化于狭窄的指令分布。为在学习动作预测的同时保持通用视觉推理与语言对齐能力，StarVLA 支持一种联合训练机制，将机器人动作学习与基于多模态网络数据的视觉语言模型损失交替进行。该模式在 `starVLA/training/train_starvla_cotrain.py` 中实现。

**双加载器多目标训练方案。** 协同训练使用两个数据加载器（视觉语言动作模型与视觉语言模型），并在每个优化步骤中执行两次前向/反向传播：（一）通过框架进行视觉语言动作模型的前向传播

前向传播以获得 `action_loss`，以及 (ii) 通过 `qwen_vl_interface` 进行视觉语言模型前向传播以获得语言建模损失。视觉语言模型损失在配置中按 `trainer.loss_scale.vlm` 缩放，从而在动作学习与视觉语言模型能力保持之间实现可控的权衡。

### 3.1.3 基于机器人数据混合的跨具身协同训练

为支持跨具身泛化，代码库提供了统一的乐高机器人混合数据集接口，允许在不同具身、动作约定和相机设置下对异构机器人数据集进行训练。在配置中，用户通过 `datasets.vla_data.data_mix` 选择命名的混合数据集，该映射到（数据集名称、采样权重、机器人类型）元组列表。在运行时，混合数据集被实例化为乐高机器人混合数据集，根据指定权重跨数据集采样轨迹，并根据机器人类型跟踪具身标签。这种设计使“跨具身预训练”成为一种可操作的配置选择，而非定制训练脚本。

### 3.1.4 强化学习微调

除了监督学习和协同训练机制外，我们计划支持强化学习（RL）微调，作为同一框架抽象的扩展，与 RLinf 项目 (<https://github.com/RLinf/RLinf>) 合作。在撰写本文时，强化学习微调是一个正在进行的集成工作；当前公开代码库专注于监督学习和协同训练流程，以构建强大的机器人基础模型。

## 3.2 评估与部署

### 3.2.1 跨基准的统一服务器-客户端评估

StarVLA 采用轻量级服务器-客户端测试抽象，使基准侧的评估代码保持接近官方实现，而模型侧推理则标准化。在实践中，检查点由 `baseframework.from_pretrained()` 加载，并在 StarVLA 运行时环境中作为轻量级 WebSocket 策略服务器托管。基准评估器可能位于具有自身模拟器依赖项的不同 conda 环境中，通过小型客户端包装器与模型交互，而非直接导入框架代码。这种解耦对于 LIBERO、SimplerEnv 和 RoboTwin 等基准特别有用，它们的官方评估器各自具有不同的依赖栈和控制循环。

**推理** 接口。所有框架变体均暴露相同的推理入口点，`Framework.predict_action()`，服务器以最简路由逻辑将传入的载荷字典转发至该方法。基准端客户端将观测打包为单一字典，通常包含图像（单视角或多视角 RGB 观测）、语言（任务指令）以及可选字段，如状态、时间戳或回合元数据。载荷经 `msgpack` 序列化后发送至策略服务器，服务器返回包含模型输出的字典，例如 `normalized_actions`。由于通信契约与动作头无关，从 OFT 切换至 FAST、 $\pi$  或 GR00T 无需修改基准代码。

**基准特定适配器。**在 StarVLA 中，基准差异被隔离在轻量级接口文件中，例如 `model2libero_interface.py`，`model2simpler_interface.py`，和 `model2robotwin_interface.py`。这些适配器将原始环境观测转换为通用的 StarVLA 示例格式，并将返回的动作后处理为基准的原生控制 API。典型职责包括将图像缩放至训练分辨率、从检查点目录读取 `dataset_statistics.json` 以进行动作反归一化、将分块归一化预测转换为可执行动作、应用动作集成，以及处理基准特定约定，如粘性夹爪或增量/相对到绝对动作转换。该设计使核心策略服务器与基准无关，同时确保在每个官方协议下进行忠实评估。

### 3.2.2 真实机器人部署

相同的客户端-服务器契约也支持真实机器人或托管基准部署。在此设置中，机器人控制器扮演基准客户端的角色：捕获相机观测，组装与仿真中相同的示例字典，查询远程策略服务器，并在硬件上执行返回的动作。因此，控制回路、安全逻辑和设备特定中间件保持在 StarVLA 模型运行时之外，而模型服务保持不变。



**部署接口。**这种分离使得部署的侵入性大大降低。模型栈可以保留在面向图形处理器（GPU）的推理环境中，而机器人端的进程则可以继续与供应商软件开发工具包（SDK）、机器人操作系统（ROS）节点或诸如机器人挑战赛（RoboChallenge）之类的托管评估平台集成。更重要的是，只要客户端以约定的字典格式提供观测，并应用适当的基准或机器人特定的后处理，同一个检查点就可以在仿真和真实机器人设置中复用。从这个意义上说，StarVLA 将部署视为同一测试范式的延续，而不是一条独立的工程路径。

## 4 多基准集成

近年来，视觉-语言-动作（VLA）研究在广泛的基准上取得了快速进展。然而，大多数现有方法仅在有限数量的环境中进行评估，并且它们的实现在预处理流水线、策略接口和评估协议方面往往存在显著差异。这些不一致阻碍了公平的跨论文比较，并削弱了可复现性。

### 4.1 统一基准集成接口

StarVLA 旨在通过以下方式在多样化的基准套件中提供简单且可复现的基线：（i）尽可能严格遵循每个基准的官方训练和评估工作流程，尽量减少数据工程和环境特定的修改，以及（ii）标准化策略侧接口。具体而言，所有 StarVLA 变体都暴露一个统一的轻量级 WebSocket 服务，使不同的基准运行器能够与共享的推理端点交互。这种设计便于无缝集成，并简化了扩展到更多基准的过程。

为了便于复现，StarVLA 为基准接入定义了一个统一的集成接口。具体来说，每个基准集成都围绕三个对齐的组件构建：（i）一个包含已保存的 `config.yaml` 和 `dataset_statistics.json` 的检查点包；（ii）一个可运行的训练入口（YAML 配置和位于 `examples/<BENCH>/train_files/` 下的启动脚本）；以及（iii）一个可运行的评估工作流程，该流程启动策略服务器并调用官方基准评估器（通常位于 `examples/<BENCH>/eval_files/` 下）。这种设计确保基准特定的工作流程保持可复现，同时在不同环境中保持一致的策略接口。

### 4.2 支持的基准套件

StarVLA 整合了多样化的操作基准，涵盖不同的仿真器、机器人本体和评估协议，包括 LIBERO、SimplerEnv、RoboTwin 2.0、RoboCasa GR1 桌面任务和 BEHAVIOR-1K。实验部分报告了在每个基准官方评估协议下的详细结果和比较。

**LIBERO。**LIBERO (Liu 等人, 2024a) 是一个广泛使用的基准，用于语言条件下的机器人操作和终身机器学习。它包含 130 个操作任务，分为四个套件：空间、物体、目标和长程，每个套件针对不同形式的泛化，包括空间变化、以物体为中心的操作、目标条件执行和长程依赖。标准训练协议每个任务使用 50 个演示，总共约 6.5K 条轨迹。LIBERO 提供了标准化的评估协议，并作为指令遵循、组合泛化和多任务策略学习的综合测试平台。

**LIBERO-Plus。**LIBERO-Plus (Fei 等人, 2025) 是一个以鲁棒性为导向的基准，建立在 LIBERO 之上，用于系统评估视觉-语言-动作模型在分布偏移下的泛化能力。它通过引入七个因素的扰动来扩展原始基准，包括物体布局、相机视角、机器人初始状态、语言指令、光照、背景纹理和传感器噪声。最终基准是一个仅测试的评估集，包含 10,030 个任务，涵盖 7 个扰动因素和 21 个低级组件。

**SimplerEnv。**SimplerEnv (Li 等人, 2024b) 是一个基于仿真的评估基准，设计为真实世界机器人评估的可扩展代理。它提供了与常见真实机器人平台相对应的标准化仿真环境，包括 WidowX (BridgeData V2) 和 Google Robot (RT 系列) 设置。该基准定义了固定的评估协议，如视觉匹配和变体聚合，以及标准化的成功率聚合规则。尽管它没有指定固定的任务数量

或数据集大小，但它被广泛用于在可复现的仿真条件下评估基于真实世界数据训练的策略，先前工作表明仿真性能与真实世界性能之间存在强相关性。

**RoboCasa-GR1。** RoboCasa-GR1 (Nasiriany 等人, 2024; Bjorck 等人, 2025) 是一个基于 RoboCasa 仿真框架构建的桌面操作基准，常用于评估人形风格的操作策略。与标准单臂设置相比，它引入了更复杂的具身形态以及涉及关节物体和多阶段任务的家庭交互场景。该基准包含 24 个任务，每个任务约有 1,000 条演示，总计约 24K 条轨迹。

**RoboTwin 2.0。** RoboTwin 2.0 (Chen 等人, 2025b) 是一个大规模双臂机器人操作基准，专注于多种场景下的双臂协调。它包含 50 个任务，具有两种评估设置：干净和随机化。每个任务包含 50 条干净演示以及 500 条随机化演示，每个任务总计约 550 条轨迹，总共约 27.5K 条轨迹。随机化数据通过结构化领域随机化生成，包括场景杂乱、背景、桌面高度和光照的变化，为协调性和鲁棒性提供了具有挑战性的测试平台。评估时，每个任务在每种设置下测试 100 个回合。总共产生 50 个任务  $\times$  2 设置  $\times$  100 个回合，等于 10,000 次评估试验。

**BEHAVIOR-1K。** BEHAVIOR-1K (Li 等人, 2023) 是一个以日常活动为核心的大规模具身智能基准。它在 50 个交互场景中定义了 1,000 项活动，涉及超过 9,000 个物体，覆盖家庭、办公室和餐厅等环境。该基准基于 OmniGibson 构建，支持刚体、可变形体和液体的真实物理仿真，并强调需要感知、导航和操作的长程交互。一个活跃的评估设置是 BEHAVIOR 挑战赛，它从活动集中选取 50 个家庭任务，并提供 10,000 条遥操作演示（超过 1,200 小时），其中每个任务发布 200 条演示用于训练。评估时，每个任务包含 20 个具有不同初始条件的额外实例，其中 10 个用于报告，每个实例在固定超时下评估一次。性能通过所有任务的平均任务成功率来衡量，并根据目标完成情况给予部分得分。

**CALVIN。** CALVIN (Mees 等人, 2022) 是一个用于长时程语言条件操作的基准，旨在评估单一策略能否根据视觉观察执行自然语言指令序列。它包含四个环境（A、B、C 和 D）以及 34 个涉及关节物体和有状态场景元素（如抽屉、滑动门、灯和开关）的操作任务。标准评估遵循  $ABC \rightarrow D$  设置，即策略在 A-C 上训练，并在 D 上使用 1,000 个长度为 5 的任务序列进行测试。性能通过成功完成的子任务序列的平均长度来报告。

## 5 单基准训练示例

在本节中，我们报告单基准监督微调（SFT）结果，以在官方评估协议下建立透明、可复现的参考点。为了向社区提供尽可能干净的基线，我们有意避免任何 VLA 特定的预训练（例如大规模机器人预训练混合）、数据增强或在线细化技术（如 DAgger）。每个模型都从公开的视觉语言（VL）预训练权重初始化，并仅在基准的标准演示数据集上进行微调。这些最小假设的结果可作为未来研究的可靠锚点：它们使衡量额外预训练数据、增强策略或联合训练方案的边际价值变得简单直接。

### 5.1 LIBERO 上的结果

LIBERO (Liu 等人, 2024a) 是一个广泛使用的桌面操作基准，包含四个难度递增的任务套件：空间（**Spatial**）、物体（**Object**）、目标（**Goal**）和长程（**Long**）。我们将其视为单基准流水线的第一个工作示例，并逐步讲解数据加载、训练和评估的每一步，以便读者能够完全复现我们的结果。

**训练数据格式。** 为了保持简单且可复现的基线，我们采用最少的数据工程，并遵循基准的原生模式。

- 输入：直接从 LeRobot 格式数据集加载的原始样本字典，包含主（第三人称）RGB 视图和腕部相机 RGB 视图。对于此基线，我们不使用本体感受状态、历史堆叠或图像增强。

- 输出：遵循 LIBERO 动作定义连续末端执行器（EEF）控制动作向量，并采用动作分块 = 8。

**训练设置。**我们使用 8 块 A100 GPU 的分布式训练（通过 accelerate + DeepSpeed ZeRO-2）训练 LIBERO 基线。除非另有说明，每设备批大小为 16，训练进行 100K 优化步。每 10K 步保存检查点，并在训练期间定期记录日志和评估。为保证透明性和精确可复现性（完整命令行、YAML 配置和环境变量），我们在 examples/LIBERO/train\_files/. 下提供完整的训练脚本。我们在四个 LIBERO 套件（Spatial、Object、Goal 和 LIBERO-10）上联合训练单一策略，使用相应的 LeRobot 格式数据集：它们作为公共集合可在 <https://huggingface.co/collections/IPEC-COMMUNITY/libero-benchmark-dataset> 获取。

**评估协议。**我们使用官方 LIBERO 评估脚本在四个套件（Spatial、Object、Goal 和 LIBERO-Long）上进行评估，并报告成功率。我们定期评估检查点（默认每 10K 步），并报告达到最佳平均成功率的最早检查点。对于每个套件，我们运行 10 个任务，每个任务 50 个回合（共 500 次试验），并报告所有试验的平均成功率。为确保在不修改基准逻辑的情况下可复现，我们在 examples/LIBERO/eval\_files/. 下提供完整的评估脚本和启动说明。

**结果与分析。**表 2 总结了 LIBERO 基线性能。仅使用 30K 步（~10 个训练轮次），StarVLA 已经达到或超过多个强已发布基线。例如，OpenVLA-OFT 训练 175K 步（223 个训练轮次）达到 97.1% 的平均成功率，而 StarVLA-OFT 以 6 $\times$  更少的步数和 23 $\times$  更少的训练轮次达到 96.6%（Qwen3-VL）和 95.8%（Cosmos-Predict2-2B）。 $\pi_0$ +FAST 和 GR00T-N1.5 分别得分 85.5% 和 86.5%，均远低于我们的变体。值得注意的是，将视觉语言骨干从 Qwen3-VL-4B 替换为 Cosmos-Predict2-2B 可获得相当的性能（所有动作头的平均  $\geq 95.2\%$ ），表明 StarVLA 在不同视觉语言骨干上具有良好的泛化能力。这些比较表明 StarVLA 流程在 LIBERO 上具有很高的数据效率。

表 2：不同 VLA 模型在 LIBERO 上的比较。我们为所有 4 个套件训练一个策略。所有分数均为每个任务套件 500 次试验的平均值（10 个任务  $\times$  50 个回合）。

| Model                               | Steps | Epochs | Spatial | Object | Goal | Long | Avg  |
|-------------------------------------|-------|--------|---------|--------|------|------|------|
| $\pi_0$ +FAST Pertsch et al. (2025) | -     | -      | 96.4    | 96.8   | 88.6 | 60.2 | 85.5 |
| OpenVLA-OFT Kim et al. (2025)       | 175K  | 223    | 97.6    | 98.4   | 97.9 | 94.5 | 97.1 |
| $\pi_0$                             | -     | -      | 96.8    | 98.8   | 95.8 | 85.2 | 94.1 |
| GR00T-N1.5 Bjorck et al. (2025)     | 20K   | 203    | 92.0    | 92.0   | 86.0 | 76.0 | 86.5 |
| <b>VL = Qwen3-VL-4B</b>             |       |        |         |        |      |      |      |
| StarVLA-FAST                        | 30K   | 9.54   | 97.3    | 97.4   | 96.3 | 90.6 | 95.4 |
| StarVLA-OFT                         | 30K   | 9.54   | 97.8    | 98.6   | 96.2 | 93.8 | 96.6 |
| StarVLA- $\pi$                      | 30K   | 9.54   | 98.8    | 99.6   | 95.8 | 88.4 | 95.7 |
| StarVLA-GR00T                       | 30K   | 9.54   | 97.8    | 98.8   | 97.4 | 92.0 | 96.5 |
| <b>VL = Cosmos-Predict2-2B</b>      |       |        |         |        |      |      |      |
| StarVLA-OFT                         | 30K   | 9.54   | 98.6    | 97.6   | 95.0 | 91.8 | 95.8 |
| StarVLA- $\pi$                      | 30K   | 9.54   | 98.9    | 98.3   | 94.4 | 90.4 | 95.5 |
| StarVLA-GR00T                       | 30K   | 9.54   | 97.4    | 98.0   | 95.1 | 90.4 | 95.2 |

## 5.2 SimplerEnv 上的结果

**训练设置。**所有模型均采用全参数微调，并在 16 块 A100 GPU 上进行分布式训练。除非另有说明，每设备批大小为 16，训练共进行 100K 优化步。每 10K 步保存一次检查点，训练期间定期进行日志记录与评估。为确保透明性和精确可复现性（完整命令行、YAML 配置及环境变量），我们在 examples/SimplerEnv/train\_files/. 下提供完整的训练脚本。我们在 LeRobot 格式下，基于 Bridge 与 Fractal 数据集的合并混合数据训练 SimplerEnv 基线：

[https://huggingface.co/datasets/IPEC-COMMUNITY/bridge\\_orig\\_lerobot](https://huggingface.co/datasets/IPEC-COMMUNITY/bridge_orig_lerobot) 和 [https://huggingface.co/datasets/IPEC-COMMUNITY/fractal20220817\\_data\\_lerobot](https://huggingface.co/datasets/IPEC-COMMUNITY/fractal20220817_data_lerobot).

**评估协议。**我们使用官方 SimplerEnv 评估流程进行评估，并报告任务成功率。我们在两种标准 SimplerEnv 设置下展示详细的分任务结果：(i) WidowX

机器人采用视觉匹配（Visual Matching, VM），结果见表 3；(ii) Google 机器人结果见表 4。我们严格遵循官方协议进行每任务重复/回合次数及成功率聚合，未修改基准逻辑。由于 SimplerEnv 评估可能表现出不可忽视的方差，我们对每个报告设置运行五次（每次重新运行完整官方评估），并报告平均成功率。为确保在不修改基准逻辑的前提下可复现，我们在 `examples/SimplerEnv/eval_files/` 下提供完整的评估脚本和启动说明。

**结果。**表 3 和表 4 总结了 SimplerEnv 性能。在 WidowX (VM) 上，StarVLA 搭配 Qwen3-VL-4B 取得了较高的平均成功率（最高 65.3%），而 Cosmos-Predict2-2B 骨干网络也提供了有竞争力的结果（最高 61.6%），证实 StarVLA 在不同视觉语言骨干网络上具有泛化能力。两种配置在最结构化任务上均表现出一致的高性能，而在物体放置任务上仍存在差距。在 Google 机器人上，StarVLA 在视觉匹配设置下与近期强基线相比具有竞争力或更优，在变体聚合（Variant Aggregation）设置下仍保持可比性，表明该策略在标准化仿真评估设置间具有稳健的迁移能力。

表 3: SimplerEnv WidowX 基准（视觉匹配）上的详细结果。Steps 表示优化步数；所有数字均为成功率（%）。

| WidowX Robot                  | Method                                   | Steps | Put Spoon<br>on Towel | Put Carrot<br>on Plate | Stack Green Block<br>on Yellow Block | Put Eggplant<br>in Yellow Basket | Average |
|-------------------------------|------------------------------------------|-------|-----------------------|------------------------|--------------------------------------|----------------------------------|---------|
| SIMPLERENV<br>Visual Matching | RT-1-X Brohan et al. (2022)              | -     | 0.0                   | 4.2                    | 0.0                                  | 0.0                              | 1.1     |
|                               | Octo-Base Octo Model Team et al. (2024)  | -     | 15.8                  | 12.5                   | 0.0                                  | 41.7                             | 17.5    |
|                               | Octo-Small Octo Model Team et al. (2024) | -     | 41.7                  | 8.2                    | 0.0                                  | 56.7                             | 26.7    |
|                               | OpenVLA Kim et al. (2024)                | -     | 4.2                   | 0.0                    | 0.0                                  | 12.5                             | 4.2     |
|                               | CogACT Li et al. (2024a)                 | -     | 71.7                  | 50.8                   | 15.0                                 | 67.5                             | 51.3    |
|                               | SpatialVLA Qu et al. (2025)              | -     | 16.7                  | 25.0                   | 29.2                                 | <b>100.0</b>                     | 42.7    |
|                               | $\pi_0$ Black et al. (2024)              | -     | 29.1                  | 0.0                    | 16.6                                 | 62.5                             | 27.1    |
|                               | $\pi_0$ -FAST Pertsch et al. (2025)      | -     | 29.1                  | 21.9                   | 10.8                                 | 66.6                             | 48.3    |
|                               | GR00T N1.5 Bjorck et al. (2025)          | -     | 75.3                  | 54.3                   | <b>57.0</b>                          | 61.3                             | 61.9    |
|                               | Magma Yang et al. (2025a)                | -     | 37.5                  | 31.0                   | 12.7                                 | 60.5                             | 35.8    |
|                               | <b>VL = Qwen3-VL-4B</b>                  |       |                       |                        |                                      |                                  |         |
|                               | <b>StarVLA-FAST</b>                      | 15K   | 18.8                  | 31.3                   | 4.2                                  | 71.9                             | 31.6    |
|                               | <b>StarVLA-OFT</b>                       | 65K   | <b>90.3</b>           | 38.5                   | 29.7                                 | <b>100.0</b>                     | 64.6    |
|                               | <b>StarVLA-<math>\pi</math></b>          | 40K   | 78.1                  | 46.9                   | 30.2                                 | 88.5                             | 60.9    |
|                               | <b>StarVLA-GR00T</b>                     | 20K   | 83.0                  | 59.4                   | 18.8                                 | <b>100.0</b>                     | 65.3    |
|                               | <b>VL = Cosmos-Predict2-2B</b>           |       |                       |                        |                                      |                                  |         |
|                               | <b>StarVLA-OFT</b>                       | 30K   | 66.8                  | 62.6                   | 25.3                                 | 90.2                             | 61.2    |
|                               | <b>StarVLA-<math>\pi</math></b>          | 30K   | 81.4                  | 55.2                   | 25.1                                 | 73.0                             | 58.7    |
|                               | <b>StarVLA-GR00T</b>                     | 30K   | 80.4                  | 65.4                   | 20.0                                 | 80.6                             | 61.6    |

### 5.3 RoboCasa-GR1 上的结果

**训练设置。**我们在 16 块 A100 图形处理器上采用分布式全参数微调训练 RoboCasa-GR1 基线。除非另有说明，每设备批大小为 16，训练最多进行 100K 优化步骤。每 10K 步保存一次检查点，训练期间定期进行日志记录与评估。对于专家设置，我们使用官方 RoboCasa-GR1 桌面版本，仅在此基准的全部 24 个任务上联合训练一个模型。这保持了策略架构不变，同时将 RoboCasa 视为多任务人形风格操作套件，而非 24 个独立的单任务运行。

**评估协议。**我们遵循官方 RoboCasa-GR1 评估流程，报告 24 个任务的平均成功率。对于本节中的架构比较，每个模型在每个任务上评估 50 次回放。表 6 进一步报告了代表性基线和 StarVLA 变体的任务级成功率。

**结果。**表 5 总结了单基准设置下 RoboCasa-GR1 的平均性能。该基准明显比 LIBERO 和 SimplerEnv 更难，动作头的选择影响更大：离散 StarVLA-FAST 基线达到 39.0%，而连续动作变体提升至 43.9 – 48.8%。在 StarVLA 变体中，StarVLA-OFT 表现最佳，平均成功率为 48.8%，略高于 StarVLA-GR00T（47.8%），并比  $\pi_{0.5}$  高出 11.8 个百分点。详细的任务级结果见表 6。我们将跨基准通才结果推迟到第 7 节。

### 5.4 Robotwin 2.0 上的结果

**训练设置。**我们使用 48 块 A100 图形处理器（通过 accelerate + DeepSpeed ZeRO-2）进行分布式训练来训练 RoboTwin 2.0 基线。除非另有说明，每设备批大小为 4

表 4: SimplerEnv Google Robot 基准上的详细结果。数字为官方报告，除非标有 \*，该标记表示我们的重新实现。由于该平台评估成本较高，我们报告 StarVLA-OFT 与 Qwen3-VL-4B 作为代表性配置。

| Google Robot           | Models                              | Pick<br>Coke Can | Move<br>Near | Open/Close<br>Drawer | Open Top Drawer<br>and Place Apple | Avg  |
|------------------------|-------------------------------------|------------------|--------------|----------------------|------------------------------------|------|
| Visual<br>Matching     | RT-1 Brohan et al. (2022)           | 85.7             | 44.2         | <b>73.0</b>          | 6.5                                | 52.4 |
|                        | RT-1-X Collaboration et al. (2023)  | 56.7             | 31.7         | 59.7                 | 21.3                               | 42.4 |
|                        | RT-2-X Brohan et al. (2023)         | 78.7             | 77.9         | 25.0                 | 3.7                                | 46.3 |
|                        | OpenVLA Kim et al. (2024)           | 18.0             | 56.3         | 63.0                 | 0.0                                | 34.3 |
|                        | CogACT Li et al. (2024a)            | 91.3             | 85.0         | 71.8                 | 50.9                               | 74.8 |
|                        | SpatialVLA Qu et al. (2025)         | 86.0             | 77.9         | 57.4                 | -                                  | 75.1 |
|                        | $\pi_0$ Black et al. (2024)         | 72.7             | 65.3         | 38.3                 | -                                  | 58.8 |
|                        | $\pi_0$ -FAST Pertsch et al. (2025) | 75.3             | 67.5         | 42.9                 | -                                  | 61.9 |
|                        | GR00T N1.5* Bjorck et al. (2025)    | 51.7             | 54.0         | 27.8                 | 7.4                                | 35.2 |
|                        | Magma Yang et al. (2025a)           | 83.7             | 65.4         | 56.0                 | 6.4                                | 52.9 |
|                        | <b>StarVLA-OFT</b>                  | <b>95.3</b>      | 75.0         | 68.8                 | 66.1                               | 76.0 |
| Variant<br>Aggregation | RT-1 Brohan et al. (2022)           | 89.8             | 50.0         | 32.3                 | 2.6                                | 43.7 |
|                        | RT-1-X Collaboration et al. (2023)  | 49.0             | 32.3         | 29.4                 | 10.1                               | 30.2 |
|                        | RT-2-X Brohan et al. (2023)         | 82.3             | 79.2         | 35.3                 | 20.6                               | 54.4 |
|                        | OpenVLA Kim et al. (2024)           | 60.8             | 67.7         | 28.8                 | 0.0                                | 39.3 |
|                        | CogACT Li et al. (2024a)            | 89.6             | 80.8         | 28.3                 | 46.6                               | 61.3 |
|                        | SpatialVLA Qu et al. (2025)         | 88.0             | <b>82.5</b>  | 41.8                 | -                                  | 70.7 |
|                        | $\pi_0$ Black et al. (2024)         | 75.2             | 63.7         | 25.6                 | -                                  | 54.8 |
|                        | $\pi_0$ -FAST Pertsch et al. (2025) | 77.6             | 68.2         | 31.3                 | -                                  | 59.0 |
|                        | GR00T N1.5 Bjorck et al. (2025)     | 69.3             | 68.7         | 35.8                 | 4.0                                | 44.5 |
|                        | Magma Yang et al. (2025a)           | 68.8             | 65.7         | 53.4                 | 18.5                               | 51.6 |
|                        | <b>StarVLA-OFT</b>                  | 91.3             | 75.1         | 55.0                 | 59.4                               | 70.2 |

表 5: 单基准训练设置下 RoboCasa-GR1 (24 个任务) 的平均成功率。

| Method                                  | Avg (%) | Method                          | Avg (%)     |
|-----------------------------------------|---------|---------------------------------|-------------|
| $\pi_{0.5}$ Intelligence et al. (2025a) | 37.0    | GR00T-N1.6 Bjorck et al. (2025) | 47.6        |
| StarVLA-FAST                            | 39.0    | StarVLA- $\pi$                  | 43.9        |
| StarVLA-GR00T                           | 47.8    | StarVLA-OFT                     | <b>48.8</b> |

训练进行 150K 优化步骤。每 10K 步保存一次检查点，训练期间定期进行日志记录与评估。为了透明性和精确可复现性（完整命令行、YAML 配置和环境变量），我们在 `examples/Robotwin/train_files/` 下提供完整的训练脚本。我们在 LeRobot 格式的官方干净和随机数据集上训练 RoboTwin 2.0 基线：  
<https://huggingface.co/datasets/StarVLA/RoboTwin-Clean> 和  
<https://huggingface.co/datasets/StarVLA/RoboTwin-Randomized>。

**评估协议。**我们使用官方 RoboTwin 2.0 评估脚本在 50 个任务上进行评估，并报告成功率。我们定期评估检查点（默认每 10K 步一次），并报告达到最佳平均成功率的最早检查点。对于每个套件，我们在干净和随机条件下运行 50 个任务，每个任务 100 个回合（共 10000 次试验），并报告所有试验的平均成功率。为了在不修改基准逻辑的情况下确保可复现性，我们在 `examples/Robotwin/eval_files/` 下提供了完整的评估脚本和启动说明。

**结果。**表 7 总结了 RoboTwin 基线性能。在 Qwen3-VL-4B 骨干网络下，所有四个 StarVLA 变体在 50 个任务上作为单一统一策略训练时均取得了较高的平均成功率，表明我们的端到端基线流程（数据  $\rightarrow$  training  $\rightarrow$  evaluation）是可靠且可复现的。

表 6: RoboCasa GR1 桌面任务评估结果。单个模型针对所有 24 个任务进行训练。结果基于每个任务 50 次 rollout 报告 (250 次 rollout 的平均成功率为 48.97%)。

| Task                                   | GR00T-N1.6  | StarVLA-GR00T | StarVLA- $\pi$ | StarVLA-OFT | StarVLA-FAST |
|----------------------------------------|-------------|---------------|----------------|-------------|--------------|
| PnPbottleToCabinetClose                | <b>51.5</b> | 46.0          | 26.0           | <b>30.0</b> | 38.0         |
| PnPCanToDrawerClose                    | 13.0        | 80.0          | 62.0           | 76.0        | 44.0         |
| PnPCupToDrawerClose                    | 8.5         | 54.0          | 42.0           | <b>44.0</b> | <b>56.0</b>  |
| PnPMilkToMicrowaveClose                | 14.0        | 48.0          | <b>50.0</b>    | <b>44.0</b> | 44.0         |
| PnPPotatoToMicrowaveClose              | 41.5        | 28.0          | <b>42.0</b>    | <b>32.0</b> | 14.0         |
| PnPWineToCabinetClose                  | 16.5        | <b>46.0</b>   | 32.0           | <b>36.0</b> | 14.0         |
| PnPNovelFromCuttingboardToBasket       | <b>58.0</b> | 48.0          | 40.0           | <b>50.0</b> | 54.0         |
| PnPNovelFromCuttingboardToCardboardbox | <b>46.5</b> | 40.0          | 46.0           | <b>40.0</b> | 42.0         |
| PnPNovelFromCuttingboardToPan          | 68.5        | 68.0          | <b>70.0</b>    | 70.0        | 58.0         |
| PnPNovelFromCuttingboardToPot          | <b>65.0</b> | 52.0          | 40.0           | 54.0        | 58.0         |
| PnPNovelFromCuttingboardToTieredbasket | 46.5        | <b>56.0</b>   | 44.0           | <b>38.0</b> | 40.0         |
| PnPNovelFromPlacematToBasket           | <b>58.5</b> | 42.0          | 44.0           | <b>32.0</b> | 36.0         |
| PnPNovelFromPlacematToBowl             | 57.5        | <b>44.0</b>   | 52.0           | <b>58.0</b> | 38.0         |
| PnPNovelFromPlacematToPlate            | <b>63.0</b> | 48.0          | 50.0           | <b>52.0</b> | 42.0         |
| PnPNovelFromPlacematToTieredshelf      | <b>28.5</b> | 18.0          | 28.0           | <b>24.0</b> | 18.0         |
| PnPNovelFromPlateToBowl                | 57.0        | <b>60.0</b>   | 52.0           | <b>60.0</b> | 52.0         |
| PnPNovelFromPlateToCardboardbox        | 43.5        | <b>50.0</b>   | 40.0           | <b>50.0</b> | 30.0         |
| PnPNovelFromPlateToPan                 | 51.0        | <b>54.0</b>   | 36.0           | <b>66.0</b> | 48.0         |
| PnPNovelFromPlateToPlate               | 78.7        | <b>70.0</b>   | 48.0           | <b>68.0</b> | 50.0         |
| PnPNovelFromTrayToCardboardbox         | <b>51.5</b> | 38.0          | 34.0           | 44.0        | 28.0         |
| PnPNovelFromTrayToPlate                | <b>71.0</b> | 56.0          | 64.0           | <b>56.0</b> | 34.0         |
| PnPNovelFromTrayToPot                  | <b>64.5</b> | 50.0          | 44.0           | <b>62.0</b> | 46.0         |
| PnPNovelFromTrayToTieredbasket         | <b>57.0</b> | 36.0          | 50.0           | <b>54.0</b> | 36.0         |
| PnPNovelFromTrayToTieredshelf          | <b>31.5</b> | 16.0          | 28.0           | <b>30.0</b> | 16.0         |
| <b>Average</b>                         | <b>47.6</b> | <b>47.8</b>   | <b>43.9</b>    | <b>48.8</b> | 39.0         |

表 7: RoboTwin 2.0 基准上的详细结果。我们报告了该平台上不同 StarVLA 模型架构的表现。

| Method                      | Clean | Random | Method                                  | Clean | Random |
|-----------------------------|-------|--------|-----------------------------------------|-------|--------|
| $\pi_0$ Black et al. (2024) | 65.9  | 58.4   | $\pi_{0.5}$ Intelligence et al. (2025a) | 82.7  | 76.8   |
| X-VLA Zheng et al. (2025a)  | 72.9  | 72.8   | Lingbot-VLA Wu et al. (2026)            | 88.6  | 86.7   |
| StarVLA-FAST                | 72.5  | 83.2   | StarVLA-OFT                             | 88.2  | 88.3   |
| StarVLA-GR00T               | 88.0  | 88.5   | StarVLA- $\pi$                          | 88.1  | 88.8   |

## 6 多模态协同训练示例

除了单一基准的监督微调之外，StarVLA 原生支持多模态协同训练，其中视觉语言模型骨干网络在机器人动作数据和辅助视觉语言任务（例如空间定位、视觉问答和图像描述）上联合优化。动机有两方面：(i) 仅进行动作微调会迅速退化预训练的多模态表示，削弱指令理解和空间推理能力；(ii) 使用精心策划的辅助数据进行协同训练可以对齐感知与控制的优化动态，从而产生性能更优的策略。

当预训练的视觉语言模型仅在动作预测上进行微调时，它往往会在数千步内“遗忘”预训练的视觉和语言能力。这表现为物体定位、指令遵循和场景理解的退化，而这些都是稳健操作的前提条件。与多模态定位数据进行协同训练通过维持感知相关通路的梯度流来抵消这种遗忘。

### 6.1 实验设置

**联合训练设置。**StarVLA 为训练期间混合异构数据源提供了内置支持。用户可以在单个配置文件中指定动作数据集和视觉语言模型（VLM）风格问答数据集的任意组合；该框架透明地处理跨数据类型的标记化、损失掩码和梯度累积。这使得无需修改训练循环即可轻松复现联合训练方案，例如将 OXE 动作数据与 RefCOCO 空间定位或 LLaVA 风格视觉问答数据混合。



**评估与基线。**为说明效果，我们总结了一项基于 StarVLA 代码库的空间引导联合训练研究（Ye 等人，2026a）。该研究比较了三种训练策略：（1）普通 VLA，仅在动作数据上微调；（2）普通联合训练 VLA，在空间定位和动作数据上联合优化；（3）空间引导训练 VLA，在联合训练期间额外引入空间预训练和空间提示。

## 6.2 多模态联合训练的主要结果

图 4 可视化了训练步骤中空间感知（以 RefCOCO-g 上的 IoU@0.5 衡量）与操作性能（WidowX 成功率）之间的交互。普通 VLA 遭受快速的感知退化：RefCOCO-g 性能在 20K 步内降至接近随机水平。普通联合训练部分保留了感知能力，但表现出不稳定的振荡。空间引导的 StarVLA（ST4VLA（Ye 等人，2026a））变体实现了最佳平衡，在保持  $\sim 70\%$  原始定位性能的同时达到较高的操作成功率。




图 4：不同联合训练策略下的感知-动作协同优化动态（转载自基于 StarVLA 的空间引导联合训练研究 ST4VLA（Ye 等人，2026a））。从左到右：（a）空间定位性能（RefCOCO-g 上的 IoU@0.5）；（b）操作成功率（WidowX）；（c）普通联合训练与空间引导联合训练下空间定位和动作目标之间的梯度子空间对齐（PSS）。

表 8 进一步量化了协同训练对多模态理解、空间定位和机器人操作的影响。与普通视觉语言动作模型相比，普通协同训练已能提升操作性能（谷歌机器人视觉运动提升 4.1%，WidowX 提升 6.4%），同时恢复多模态能力。空间引导的 StarVLA 变体进一步提升了结果，在谷歌机器人视觉运动/视觉动作上达到 84.6%/75.9%，在 WidowX 上达到 73.2%，同时保持强大的空间定位能力（在 RefCOCO-g 上 IoU@0.5 为 71.2）。

表 8：协同训练策略对多模态理解、空间定位和机器人操作的影响（来自基于 StarVLA 的空间引导协同训练研究 Ye 等人（2026a））。

| Training Strategy      | Multi-modal Understanding |       |         |          | Spatial Grounding |                   | Robotic Manipulation |           |
|------------------------|---------------------------|-------|---------|----------|-------------------|-------------------|----------------------|-----------|
|                        | MME                       | MMVet | TextVQA | POPE Acc | RefCOCO-g IoU@0.5 | RoboRefIt Acc@0.5 | Google Robot VM / VA | WidowX VM |
| Vanilla VLA            | —                         | —     | —       | —        | —                 | —                 | 66.1 / 63.5          | 54.7      |
| + Co-training          | 1106                      | 19.2  | 20.5    | 78.0     | 47.1              | 66.7              | 70.2 / 66.5          | 61.1      |
| + Spatially guided     | 1374                      | 23.0  | 28.4    | 84.6     | 68.1              | 72.5              | 78.8 / 70.0          | 67.4      |
| + Spatially pretrained | 1411                      | 23.3  | 28.6    | 86.2     | 71.2              | 74.3              | 84.6 / 75.9          | 73.2      |

**要点。**这些结果表明，StarVLA 的协同训练基础设施相比仅动作微调能带来显著提升。通过在策略学习过程中保留多模态理解，协同训练能产生更具泛化能力的智能体。关于空间引导协同训练的全面论述，包括完整训练方案、梯度对齐分析和大量真实世界实验，请读者参阅 ST4VLA Ye 等人（2026a），这是一篇基于 StarVLA 的研究论文。

**表 9：通用设置与专用设置之间的性能比较。**专用设置表示针对每个基准特定数据集分别训练多个模型，而通用设置表示在所有数据集上联合训练单个模型。

| Settings   | Method         | LIBERO      |             |             |             |             | SimplerEnv  |             |             | RoboTwin 2.0 |             |             | RoboCasa-GR1<br>(avg of 24 tasks) |
|------------|----------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|--------------|-------------|-------------|-----------------------------------|
|            |                | Spatial     | Object      | Goal        | Long        | avg         | WidowX      | Google VA   | Google VM   | clean        | clean*      | random*     |                                   |
| Specialist | $\pi_{0.5}$    | 98.8        | 98.2        | 98.0        | 92.4        | 96.9        | 46.9        | 68.4        | 72.7        | <b>60.2</b>  | 82.7        | 76.8        | 37.0                              |
|            | GR00T-N1.6     | 97.5        | 98.5        | 97.5        | 94.4        | 94.1        | 67.8        | 41.5        | 35.2        | –            | –           | –           | 47.6                              |
|            | StarVLA- $\pi$ | 98.0        | 99.2        | 98.2        | 93.6        | 98.1        | 65.9        | 72.8        | 76.6        | 50.8         | 88.1        | <b>88.8</b> | 48.9                              |
|            | StarVLA-GR00T  | 98.9        | 99.6        | 98.4        | <b>95.3</b> | 98.7        | 65.3        | 70.7        | 75.3        | 48.8         | 88.0        | 88.5        | 52.8                              |
|            | StarVLA-OFT    | <b>99.0</b> | <b>99.8</b> | 98.5        | 94.1        | <b>98.8</b> | 64.6        | 70.2        | 76.0        | 53.4         | 88.2        | 88.3        | 53.8                              |
| Generalist | StarVLA        | 98.7        | 99.7        | <b>98.6</b> | 94.2        | 97.8        | <b>70.2</b> | <b>73.8</b> | <b>79.3</b> | –            | <b>88.7</b> | 87.8        | <b>57.3</b>                       |

## 7 跨基准训练示例

在第 5 节基准专用基线的基础上，我们进一步评估了具身泛化更严格的设置：一个模型在多个基准和机器人形态上联合训练。StarVLA 原生支持在统一框架下对异构数据集进行协同训练，这使得这种一体化设置成为通用视觉语言动作模型训练的自然案例研究。

**现有评估模式。**具身智能（Embodied AI）社区怀有共同的愿景：开发一个能够在多样任务、环境和机器人之间无缝运作的通用智能体。然而，在实践中，研究格局仍然碎片化。许多最先进的系统针对特定基准进行了调优，当迁移到不同环境或具身形态时，其性能可能大幅下降。这使得衡量真正的泛化能力变得困难。

### 7.1 实验设置

**训练设置。**在此设置下，我们在来自 LIBERO、SimplerEnv、RoboTwin 2.0 和 RoboCasa-GR1 的合并训练集上联合训练一个模型，然后直接在每个基准的官方协议下进行评估。不应用额外的基准特定微调。我们将学习率设置为  $1 \times 10^{-4}$ ，总批大小设置为 256，并在合并的基准数据集上联合训练。为了处理不同具身形态之间的动作空间差异，我们避免使用任务特定的动作头，并应用一种简单的统一填充策略，将低自由度的动作扩展为共享的 32 维动作向量。

**作为通用智能体的评估协议。**测试泛化能力的一种实用方法是要求一个模型同时处理多个基准。遵循这一原则，我们在统一的多基准设置下评估 StarVLA，其中单一策略仅训练一次，并在多个套件上进行评估，无需基准特定的微调。

**基线。**为了进一步证明我们方法的有效性和所提出设置的价值，我们报告了专家结果（模型仅在单个数据集上训练）和通用训练设置下的结果。除了与我们的模型进行比较外，我们还评估了几种最先进的方法，例如  $\pi_{0.5}$  和 GR00T-N1.6。

### 7.2 作为通用智能体的主要结果

如表 9 所示，我们将通用模型（跨数据集联合训练）与按基准训练的专业模型进行比较。通用模型在大多数基准上保持竞争力，并将 RoboCasa-GR1 的 24 任务平均成功率从最佳专业模型的 48.8% 提升至 57.3%。这些结果支持在统一训练/评估设置下，单一策略跨任务和跨具身迁移的可行性。

**要点** 本节侧重于直接能力展示而非消融分析：StarVLA 能够在异构、跨具身的基准数据集上联合训练，并产生一个在多样化评估套件中保持竞争力的单一模型。我们认为这证明了一体化多基准训练是未来通用 VLA 系统大规模跨具身预训练的实用路径。

## 8 计算效率

本节报告 StarVLA 的训练效率，使用问题 <https://github.com/starVLA/starVLA/issues/158> 中收集的公开性能测量数据。我们的目标是为实践者提供可操作的扩展指导，同时使报告的度量与常见的分布式训练瓶颈（计算和通信）保持一致。

表 10: 单节点训练效率 ( $8 \times A100$ )。样本吞吐量由每 10 万步的测量时间和全局批大小推导得出。

| Per-GPU batch | Global batch | Time / 100K steps | Seconds / step | Samples / s | GPU util |
|---------------|--------------|-------------------|----------------|-------------|----------|
| 2             | 16           | 19:32:17          | 0.703          | 22.7        | 74%      |
| 4             | 32           | 24:35:59          | 0.886          | 36.1        | 89%      |
| 8             | 64           | 31:25:38          | 1.131          | 56.6        | 92%      |
| 16            | 128          | 49:15:53          | 1.774          | 72.2        | 91%      |
| 24            | 192          | 66:47:02          | 2.404          | 79.9        | 96%      |




图 5: 单个 8-GPU 节点上的每步延迟和吞吐量。左图: 在 A100 和 H200 上, 我们方法的每步延迟随每 GPU 批大小的变化, 与 LingBot-VLA 和 Dexbotic (均在  $8 \times H200$ ) 上) 进行比较。右图: 在  $8 \times A100$  上不同批大小下的训练吞吐量和 GPU 利用率。




图 6: 多节点扩展效率。左图: 从 8 到 32 个 GPU, 每步延迟因节点间通信开销而显著上升, 然后在 64 到 256 个 GPU 之间趋于平稳。右图: 实测样本吞吐量与理想线性扩展的对比; 超过 32 个 GPU 后, 并行效率稳定在 79 - 80% 左右。

表 11: 多节点训练效率（每 GPU 批大小=8）。“理想”扩展假设从 8-GPU 基线线性增长样本数/秒。

| # GPUs | Global batch | Time / 100K steps | Seconds / step | Samples / s | Scaling eff. |
|--------|--------------|-------------------|----------------|-------------|--------------|
| 8      | 64           | 20:25:48          | 0.735          | 87.0        | 100%         |
| 16     | 128          | 23:36:00          | 0.850          | 150.7       | 86.7%        |
| 32     | 256          | 24:58:45          | 0.899          | 284.7       | 81.9%        |
| 64     | 512          | 25:40:59          | 0.925          | 553.8       | 79.6%        |
| 128    | 1024         | 25:35:26          | 0.921          | 1111.5      | 79.9%        |
| 256    | 2048         | 25:51:41          | 0.931          | 2200.0      | 79.1%        |

**实验设置。**除非另有说明，测量使用 StarVLA-GR00T，其骨干网络为 Qwen3-VL-4B，在 RoboCasa-GR1 数据集上训练，使用 A100 80GB GPU。本文报告每 10 万优化步的墙钟时间，包括分布式通信和系统开销。

**效率度量。**本文区分两种吞吐量概念：(i) 步吞吐量（秒/步越低越好），以及 (ii) 样本吞吐量（样本数/秒越高越好），其中样本数/秒计算为全局批大小 / (除以每步秒数。这一区分很重要，因为分布式扩展通常降低步吞吐量（由于同步），同时提高样本吞吐量（由于更大的全局批大小）。

## 8.1 单节点训练效率

表 10 总结了单节点扫描，改变每 GPU 批大小。本文省略推导的“24 小时”预测，专注于直接测量的量和隐含的样本吞吐量。

图 5 可视化了主要权衡。较小的每 GPU 批大小产生更快的步（例如，批大小 2 时为 0.703 秒/步，批大小 24 时为 2.404 秒/步），而较大的每 GPU 批大小提高样本吞吐量（从 22.7 到 79.9 样本数/秒），代价是步延迟急剧增加。

## 8.2 多节点扩展效率

接下来，我们将每个图形处理器（GPU）的批大小固定为 8，并扩展 GPU 数量。如表 11 所示，由于节点间通信开销，每步时间从 0.735 秒（8 个 GPU）增加到 0.899 秒（32 个 GPU），随后在  $\sim 0.93$  秒处趋于稳定，直至 256 个 GPU。尽管存在这一开销，样本吞吐量仍从 87.0 扩展到 2200.0 样本/秒，这是当训练目标为快速处理固定数据量时的相关度量。

图 6 绘制了步延迟和样本吞吐量随 GPU 数量变化的情况，并附有理想线性参考线。结果突显了一条实用准则：对于数据量驱动的训练，横向扩展最为有益，而固定步数的训练不会因 GPU 增多而变得更快。

**要点。**首先，节点间通信引入一次性延迟开销（0.735  $\rightarrow$  0.93 秒/步），但样本吞吐量仍通过更大的全局批大小实现近线性扩展。其次，在单节点上，适中的每 GPU 批大小（例如 8）通常能在步延迟和 GPU 利用率之间提供最佳平衡；非常大的批大小（例如 24）可最大化利用率（96%），但会使步延迟增加  $3.4\times$ 。第三，对于大规模训练，一旦系统扩展超过 8 个节点（64 个 GPU），通信负担不再进一步增长，从而保持 79 - 80% 的稳定扩展效率。这表明实践者可以放心地扩展到数百个 GPU，而不会招致额外的并行效率下降。

# 目录

|          |                                                               |           |
|----------|---------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                           | <b>1</b>  |
| <b>2</b> | <b>Unified Framework for VLA Systems</b>                      | <b>3</b>  |
| 2.1      | Background: VL Foundation Models for Embodied Intelligence    | 4         |
| 2.2      | Building VLA Frameworks on VL Foundation Models               | 5         |
| 2.3      | Representative VLA Instantiations                             | 6         |
| <b>3</b> | <b>Unified System Pipeline for Model Training and Testing</b> | <b>7</b>  |
| 3.1      | Training Paradigms                                            | 7         |
| 3.1.1    | Supervised Learning for Behavior Cloning                      | 7         |
| 3.1.2    | Multi-Objective Co-Training for Embodied Reasoning            | 7         |
| 3.1.3    | Cross-Embodiment Co-Training with Robot Data Mixtures         | 8         |
| 3.1.4    | Reinforcement Learning Fine-Tuning                            | 8         |
| 3.2      | Evaluation and Deployment                                     | 8         |
| 3.2.1    | Unified Server-Client Evaluation Across Benchmarks            | 8         |
| 3.2.2    | Deployment on Real Robots                                     | 8         |
| <b>4</b> | <b>Multiple Benchmark Integration</b>                         | <b>9</b>  |
| 4.1      | Unified Benchmark Integration Interface                       | 9         |
| 4.2      | Supported Benchmark Suite                                     | 9         |
| <b>5</b> | <b>单基准训练示例</b>                                                | <b>10</b> |
| 5.1      | LIBERO 上的结果                                                   | 10        |
| 5.2      | SimplerEnv 上的结果                                               | 11        |
| 5.3      | RoboCasa-GR1 上的结果                                             | 11        |
| 5.4      | Robotwin 2.0 上的结果                                             | 12        |
| <b>6</b> | <b>多模态协同训练示例</b>                                              | <b>14</b> |
| 6.1      | 实验设置                                                          | 14        |
| 6.2      | 多模态协同训练主要结果                                                   | 15        |
| <b>7</b> | <b>跨基准训练示例</b>                                                | <b>16</b> |
| 7.1      | 实验设置                                                          | 16        |
| 7.2      | 作为通用模型的主要结果                                                   | 16        |
| <b>8</b> | <b>计算效率</b>                                                   | <b>17</b> |
| 8.1      | 单节点训练效率                                                       | 17        |
| 8.2      | 多节点扩展效率                                                       | 18        |
| <b>9</b> | <b>StarVLA v1.0 作者与贡献者</b>                                    | <b>25</b> |

## 参考文献

- 1X World Model Team (2025). 1x world model: Evaluating bits, not atoms. Supplementary technical progress report. Contributed by Daniel Ho, Jack Monas, Juntao Ren, Christina Yu.
- AgiBot (2025). Agibot official website. <https://www.agibot.com/>.
- Assran, M., Bardes, A., Fan, D., Garrido, Q., Howes, R., Komeili, M., Muckley, M., Rizvi, A., Roberts, C., Sinha, K., Zholus, A., Arnaud, S., Gejji, A., Martin, A., Hogan, F. R., Dugas, D., Bojanowski, P., Khalidov, V., Labatut, P., Massa, F., Szafraniec, M., Krishnakumar, K., Li, Y., Ma, X., Chandar, S., Meier, F., LeCun, Y., Rabbat, M., and Ballas, N. (2025). V-jepa 2: Self-supervised video models enable understanding, prediction and planning. *arXiv preprint arXiv:2506.09985*.
- Bai, S., Cai, Y., Chen, R., Chen, K., Chen, X., Cheng, Z., Deng, L., Ding, W., Gao, C., Ge, C., et al. (2025a). Qwen3-vl technical report. *arXiv preprint arXiv:2511.21631*.
- Bai, S., Chen, K., Liu, X., Wang, J., Ge, W., Song, S., Dang, K., Wang, P., Wang, S., Tang, J., Zhong, H., Zhu, Y., Yang, M.-H., Li, Z., Wan, J., Wang, P., Ding, W., Fu, Z., Xu, Y., Ye, J., Zhang, X., Xie, T., Cheng, Z., Zhang, H., Yang, Z., Xu, H., and Lin, J. (2025b). Qwen2.5-VL technical report. *CoRR*, abs/2502.13923.
- Bjorck, J., Castañeda, F., Cherniadev, N., Da, X., Ding, R., Fan, L., Fang, Y., Fox, D., Hu, F., Huang, S., et al. (2025). Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*.
- Black, K., Brown, N., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., Groom, L., Hausman, K., Ichter, B., et al. (2024).  $\pi_0$ : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*.
- Brohan, A., Brown, N., Carbajal, J., Chebotar, Y., Chen, X., Choromanski, K., Ding, T., Driess, D., Dubey, A., Finn, C., et al. (2023). Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*.
- Brohan, A., Brown, N., Carbajal, J., Chebotar, Y., Dabis, J., Finn, C., Gopalakrishnan, K., Hausman, K., Herzog, A., Hsu, J., et al. (2022). Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*.
- Cai, J., Cai, Z., Cao, J., Chen, Y., He, Z., Jiang, L., Li, H., Li, H., Li, Y., Liu, Y., et al. (2026). Internvla-a1: Unifying understanding, generation and action for robotic manipulation. *arXiv preprint arXiv:2601.02456*.
- Chen, B., Zhang, T., Geng, H., Song, K., Zhang, C., Li, P., Freeman, W. T., Malik, J., Abbeel, P., Tedrake, R., Sitzmann, V., and Du, Y. (2025a). Large video planner enables generalizable robot control. *arXiv preprint arXiv:2512.15840*.
- Chen, D., Zhang, J., Mu, T., Tan, Q., Li, Y., Mao, J., Liu, X., Li, K., Qiao, Y., Xiao, F., Ling, Z., and Su, H. (2025b). Robotwin 2.0: Towards general robot policies with active data generation. *arXiv preprint arXiv:2504.13059*.
- Chen, X., Chen, Y., Fu, Y., Gao, N., Jia, J., Jin, W., Li, H., Mu, Y., Pang, J., Qiao, Y., et al. (2025c). Internvla-m1: A spatially guided vision-language-action framework for generalist robot policy. *arXiv preprint arXiv:2510.13778*.
- Chen, X., Djolonga, J., Padlewski, P., Mustafa, B., Changpinyo, S., Wu, J., Riquelme Ruiz, C., Goodman, S., Wang, X., Tay, Y., Shakeri, S., Dehghani, M., Salz, D., Lucic, M., Tschannen, M., Nagrani, A., Hu, H., Joshi, M., Pang, B., Montgomery, C., Pietrzyk, P., Ritter, M., Piergiovanni, A., Minderer, M., Pavetic, F., Waters, A., Li, G., Alabdulmohsin, I., Beyer, L., Amelot, J., Lee, K., Steiner, A. P., Li, Y., Keysers, D., Arnab, A., Xu, Y., Rong, K., Kolesnikov, A., Seyedhosseini, M., Angelova, A., Zhai, X., Houlsby, N., and Soricut, R. (2023). PaLI-X: On scaling up a multilingual vision and language model.
- Chi, C., Xu, Z., Feng, S., Cousineau, E., Du, Y., Burchfiel, B., Tedrake, R., and Song, S. (2024a). Diffusion policy: Visuomotor policy learning via action diffusion.
- Chi, C., Xu, Z., Pan, C., Cousineau, E., Burchfiel, B., Feng, S., Tedrake, R., and Song, S. (2024b). Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. In *Proceedings of Robotics: Science and Systems (RSS)*.
- Collaboration, O. X.-E., O’Neill, A., Rehman, A., Gupta, A., Maddukuri, A., Gupta, A., Padalkar, A., Lee, A., Pooley, A., Gupta, A., Mandlekar, A., Jain, A., Tung, A., Bewley, A., Herzog, A., Irpan, A., Khazatsky, A., Rai, A., Gupta, A., Wang, A., Kolobov, A., Singh, A., Garg, A., Kembhavi, A., Xie, A., Brohan, A., Raffin, A., Sharma, A., Yavary, A., Jain, A., Balakrishna, A., Wahid, A., Burgess-Limerick, B., Kim, B., Schölkopf, B., Wulfe, B., Ichter, B., Lu, C., Xu, C., Le, C., Finn, C., Wang, C., Xu, C., Chi, C., Huang, C., Chan, C., Agia, C., Pan, C., Fu, C., Devin, C., Xu, D., Morton, D., Driess, D., Chen, D., Pathak, D., Shah, D., Büchler, D., Jayaraman, D., Kalashnikov, D., Sadigh, D., Johns, E., Foster, E., Liu, F., Ceola, F., Xia, F., Zhao, F., Frueh, F. V., Stulp, F., Zhou, G., Sukhatme, G. S., Salhotra, G., Yan, G., Feng, G., Schiavi, G., Berseth, G., Kahn, G., Yang, G., Wang, G., Su, H., Fang, H.-S., Shi, H., Bao, H., Amor, H. B., Christensen, H. I., Furuta, H., Bharadhwaj, H., Walke, H., Fang, H., Ha, H., Mordatch, I., Radosavovic, I., Leal, I., Liang, J., Abou-Chakra, J., Kim, J., Drake, J., Peters, J., Schneider, J., Hsu, J., Vakili, J., Bohg, J., Bingham, J., Wu, J.,

- Gao, J., Hu, J., Wu, J., Wu, J., Sun, J., Luo, J., Gu, J., Tan, J., Oh, J., Wu, J., Lu, J., Yang, J., Malik, J., Silvério, J., Hejna, J., Booher, J., Tompson, J., Yang, J., Salvador, J., Lim, J. J., Han, J., Wang, K., Rao, K., Pertsch, K., Hausman, K., Go, K., Gopalakrishnan, K., Goldberg, K., Byrne, K., Oslund, K., Kawaharazuka, K., Black, K., Lin, K., Zhang, K., Ehsani, K., Lekkala, K., Ellis, K., Rana, K., Srinivasan, K., Fang, K., Singh, K. P., Zeng, K.-H., Hatch, K., Hsu, K., Itti, L., Chen, L. Y., Pinto, L., Fei-Fei, L., Tan, L., Fan, L. J., Ott, L., Lee, L., Weihs, L., Chen, M., Lepert, M., Memmel, M., Tomizuka, M., Itkina, M., Castro, M. G., Spero, M., Du, M., Ahn, M., Yip, M. C., Zhang, M., Ding, M., Heo, M., Srirama, M. K., Sharma, M., Kim, M. J., Kanazawa, N., Hansen, N., Heess, N., Joshi, N. J., Suenderhauf, N., Liu, N., Palo, N. D., Shafiullah, N. M. M., Mees, O., Kroemer, O., Bastani, O., Sanketi, P. R., Miller, P. T., Yin, P., Wohlhart, P., Xu, P., Fagan, P. D., Mitrano, P., Sermanet, P., Abbeel, P., Sundareshan, P., Chen, Q., Vuong, Q., Rafailov, R., Tian, R., Doshi, R., Mart'in-Mart'in, R., Bajjal, R., Scalise, R., Hendrix, R., Lin, R., Qian, R., Zhang, R., Mendonca, R., Shah, R., Hoque, R., Julian, R., Bustamante, S., Kirmani, S., Levine, S., Lin, S., Moore, S., Bahl, S., Dass, S., Sonawani, S., Tulsiani, S., Song, S., Xu, S., Haldar, S., Karamcheti, S., Adebola, S., Guist, S., Nasiriany, S., Schaal, S., Welker, S., Tian, S., Ramamoorthy, S., Dasari, S., Belkhale, S., Park, S., Nair, S., Mirchandani, S., Osa, T., Gupta, T., Harada, T., Matsushima, T., Xiao, T., Kollar, T., Yu, T., Ding, T., Davchev, T., Zhao, T. Z., Armstrong, T., Darrell, T., Chung, T., Jain, V., Kumar, V., Vanhoucke, V., Zhan, W., Zhou, W., Burgard, W., Chen, X., Chen, X., Wang, X., Zhu, X., Geng, X., Liu, X., Liangwei, X., Li, X., Pang, Y., Lu, Y., Ma, Y. J., Kim, Y., Chebotar, Y., Zhou, Y., Zhu, Y., Wu, Y., Xu, Y., Wang, Y., Bisk, Y., Dou, Y., Cho, Y., Lee, Y., Cui, Y., Cao, Y., Wu, Y.-H., Tang, Y., Zhu, Y., Zhang, Y., Jiang, Y., Li, Y., Li, Y., Iwasawa, Y., Matsuo, Y., Ma, Z., Xu, Z., Cui, Z. J., Zhang, Z., Fu, Z., and Lin, Z. (2023). Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>.
- Contributors, D. (2025). Dexbotic: Open-source vision-language-action toolbox. *arXiv preprint arXiv:2510.23511*.
- Dhariwal, P. and Nichol, A. (2021). Diffusion models beat gans on image synthesis. *Advances in neural information processing systems*, 34:8780–8794.
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., and Housley, N. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. In *9th International Conference on Learning Representations (ICLR 2021)*. OpenReview.net.
- Driess, D., Springenberg, J. T., Ichter, B., Yu, L., Li-Bell, A., Pertsch, K., Ren, A. Z., Walke, H., Vuong, Q., Shi, L. X., et al. (2025). Knowledge insulating vision-language-action models: Train fast, run fast, generalize better. *arXiv preprint arXiv:2505.23705*.
- Du, Y., Yang, M., Dai, B., Dai, H., Nachum, O., Tenenbaum, J. B., Schuurmans, D., and Abbeel, P. (2023). Learning universal policies via text-guided video generation. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Duan, J., Yuan, W., Pumacay, W., Wang, Y. R., Ehsani, K., Fox, D., and Krishna, R. (2024). Manipulate-anything: Automating real-world robots using vision-language models. *arXiv preprint arXiv:2406.18915*.
- Ebert, F., Yang, Y., Schmeckpeper, K., Bucher, B., Georgakis, G., Daniilidis, K., Finn, C., and Levine, S. (2021). Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*.
- Fei, S., Wang, S., Shi, J., Dai, Z., Cai, J., Qian, P., Ji, L., He, X., Zhang, S., Fei, Z., Fu, J., Gong, J., and Qiu, X. (2025). Libero-plus: In-depth robustness analysis of vision-language-action models.
- Gao, S., Liang, W., Zheng, K., Malik, A., Ye, S., Yu, S., Tseng, W.-C., Dong, Y., Mo, K., Lin, C.-H., Ma, Q., Nah, S., Magne, L., Xiang, J., Xie, Y., Zheng, R., Niu, D., Tan, Y. L., Zentner, K. R., Kurian, G., Indupuru, S., Jannaty, P., Gu, J., Zhang, J., Malik, J., Abbeel, P., Liu, M.-Y., Zhu, Y., and Linxi "Jim" Fan (2026). Dreamdojo: A generalist robot world model from large-scale human videos. *arXiv preprint arXiv:2602.06949*.
- Gao, Y., Guo, H., Hoang, T., Huang, W., Jiang, L., Kong, F., Li, H., Li, J., Li, L., Li, X., Li, X., Li, Y., Lin, S., Lin, Z., Liu, J., Liu, S., Nie, X., Qing, Z., Ren, Y., Sun, L., Tian, Z., Wang, R., Wang, S., Wei, G., Wu, G., Wu, J., Xia, R., Xiao, F., Xiao, X., Yan, J., Yang, C., Yang, J., Yang, R., Yang, T., Yang, Y., Ye, Z., Zeng, X., Zeng, Y., Zhang, H., Zhao, Y., Zheng, X., Zhu, P., Zou, J., and Zuo, F. (2025). Seedance 1.0: Exploring the boundaries of video generation models. *CoRR*, abs/2506.09113.
- Gemini Team, Google (2024). Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context.
- Generalist AI (2025). Gen-0: Embodied foundation models that scale with physical interaction. <https://generalistai.com/blog/nov-04-2025-GEN-0>. Generalist AI Blog.
- GigaBrain Team, Wang, B., Li, B., Ni, C., Huang, G., Zhao, G., Li, H., Li, J., Lv, J., Liu, J., Feng, L., Yu, M., Li, P., Deng, Q., Liu, T., Zhou, X., Chen, X., Wang, X., Wang, Y., Li, Y., Nie, Y., Li, Y., Zhou, Y., Ye, Y., Liu, Z., and Zhu, Z. (2026). Gigabrain-0.5m\*: a vla that learns from world model-based reinforcement learning. *arXiv preprint arXiv:2602.12099*.
- GigaWorld Team, Ye, A., Wang, B., Ni, C., Huang, G., Zhao, G., Li, H., Zhu, J., Li, K., Xu, M., Deng, Q., Wang, S., Qin, W., Chen, X., Wang, X., Wang, Y., Cao, Y., Chang, Y., Xu, Y., Ye, Y., Wang, Y., Zhou, Y., Zhang, Z., Dong, Z., and Zhu, Z. (2025). Gigaworld-0: World models as data engine to empower embodied ai. *arXiv preprint arXiv:2511.19861*.

- Google DeepMind (2025). Veo 3 model card. Technical report, Google DeepMind. Published May 23, 2025.
- Guo, Y., Shi, L. X., Chen, J., and Finn, C. (2025). Ctrl-world: A controllable generative world model for robot manipulation. *arXiv preprint arXiv:2510.10125*.
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778.
- Hoque, R., Huang, P., Yoon, D. J., Sivapurapu, M., and Zhang, J. (2025). Egodex: Learning dexterous manipulation from large-scale egocentric video. *arXiv preprint arXiv:2505.11709*.
- Intelligence, P., Black, K., Brown, N., Darpinian, J., Dhabalia, K., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., et al. (2025a).  $\pi_{0.5}$ : a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*.
- Intelligence, P., Black, K., Brown, N., Darpinian, J., Dhabalia, K., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., et al. (2025b).  $\pi_{0.5}$ : a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*.
- Jang, J., Ye, S., Lin, Z., Xiang, J., Bjorck, J., Fang, Y., Hu, F., Huang, S., Kundalia, K., Lin, Y.-C., Magne, L., Mandlekar, A., Narayan, A., Tan, Y. L., Wang, G., Wang, J., Wang, Q., Xu, Y., Zeng, X., Zheng, K., Zheng, R., Liu, M.-Y., Zettlemoyer, L., Fox, D., Kautz, J., Reed, S., Zhu, Y., and Fan, L. (2025). Dreamgen: Unlocking generalization in robot learning through neural trajectories. *arXiv preprint arXiv:2505.12705*.
- Jiang, Z., Zhou, S., Jiang, Y., Huang, Z., Wei, M., Chen, Y., Zhou, T., Guo, Z., Lin, H., Zhang, Q., Wang, Y., Li, H., Yu, C., and Zhao, D. (2026). Wovr: World models as reliable simulators for post-training vla policies with rl. *arXiv preprint arXiv:2602.13977*.
- Karamcheti, S., Nair, S., Balakrishna, A., et al. (2024). Prismatic: A (nearly) universal vision-language model with fine-grained visual representations. In *International Conference on Machine Learning (ICML)*.
- Khazatsky, A., Pertsch, K., Nair, S., Balakrishna, A., Dasari, S., Karamcheti, S., Nasiriany, S., Srirama, M. K., Chen, L. Y., Ellis, K., et al. (2024). Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*.
- Kim, M. J., Finn, C., and Liang, P. (2025). Fine-tuning vision-language-action models: Optimizing speed and success. *arXiv preprint arXiv:2502.19645*.
- Kim, M. J., Gao, Y., Lin, T.-Y., Lin, Y.-C., Ge, Y., Lam, G., Liang, P., Song, S., Liu, M.-Y., Finn, C., and Gu, J. (2026). Cosmos policy: Fine-tuning video models for visuomotor control and planning. *arXiv preprint arXiv:2601.16163*.
- Kim, M. J., Pertsch, K., Karamcheti, S., Xiao, T., Balakrishna, A., Nair, S., Rafailov, R., Foster, E., Lam, G., Sanketi, P., et al. (2024). Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*.
- Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T., Whitehead, S., Berg, A. C., Lo, W.-Y., Dollar, P., and Girshick, R. (2023). Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4015–4026.
- Ko, P.-C., Mao, J., Du, Y., Sun, S.-H., and Tenenbaum, J. B. (2024). Learning to act from actionless videos through dense correspondences. In *International Conference on Learning Representations (ICLR)*.
- Li, C., Zhang, R., Wong, J., Gokmen, C., Srivastava, S., Martín-Martín, R., Wang, C., Levine, G., Lingelbach, M., Sun, J., et al. (2023). Behavior-1k: A benchmark for embodied ai with 1,000 everyday activities and realistic simulation. In *Conference on Robot Learning*, pages 80–93. PMLR.
- Li, L., Zhang, Q., Luo, Y., Yang, S., Wang, R., Han, F., Yu, M., Gao, Z., Xue, N., Zhu, X., Shen, Y., and Xu, Y. (2026). Causal world modeling for robot control. *arXiv preprint arXiv:2601.21998*.
- Li, Q., Liang, Y., Wang, Z., Luo, L., Chen, X., Liao, M., Wei, F., Deng, Y., Xu, S., Zhang, Y., et al. (2024a). Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*.
- Li, X., Hsu, K., Gu, J., Pertsch, K., Mees, O., Walke, H. R., Fu, C., Lunawat, I., Sieh, I., Kirmani, S., et al. (2024b). Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941*.
- Liu, B., Zhu, Y., Gao, C., Feng, Y., Liu, Q., Zhu, Y., and Stone, P. (2024a). Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36.
- Liu, H., Li, C., Wu, Q., and Lee, Y. J. (2023a). Visual instruction tuning. *CoRR*, abs/2304.08485.
- Liu, S., Wu, L., Li, B., Tan, H., Chen, H., Wang, Z., Xu, K., Su, H., and Zhu, J. (2024b). Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*.



- Liu, S., Zeng, Z., Ren, T., Li, F., Zhang, H., Yang, J., Jiang, Q., Li, C., Yang, J., Su, H., Zhu, J., and Zhang, L. (2023b). Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection.
- Mees, O., Hermann, L., Rosete-Beas, E., and Burgard, W. (2022). Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters*, 7(3):7327–7334.
- Nair, S., Rajeswaran, A., Kumar, V., Finn, C., and Gupta, A. (2022). R3M: A universal visual representation for robot manipulation.
- Nasiriany, S., Maddukuri, A., Zhang, L., Parikh, A., Lo, A., Joshi, A., Mandlekar, A., and Zhu, Y. (2024). Robocasa: Large-scale simulation of everyday tasks for generalist robots. *arXiv preprint arXiv:2406.02523*.
- Octo Model Team, Ghosh, D., Walke, H., Pertsch, K., Black, K., Mees, O., Dasari, S., Hejna, J., Xu, C., Luo, J., Kreiman, T., Tan, Y., Sanketi, P., Vuong, Q., Xiao, T., Sadigh, D., Finn, C., and Levine, S. (2024). Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, Delft, Netherlands.
- OpenAI (2023). Gpt-4 technical report. *arXiv:2303.08774*.
- OpenAI (2024). GPT-4o system card. *CoRR*, abs/2410.21276.
- Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y., Li, S.-W., Misra, I., Rabbat, M., Sharma, V., Synnaeve, G., Xu, H., Jegou, H., Mairal, J., Labatut, P., Joulin, A., and Bojanowski, P. (2023). DINOv2: Learning robust visual features without supervision.
- Pai, J., Achenbach, L., Montesinos, V., Forrai, B., Mees, O., and Nava, E. (2025). mimic-video: Video-action models for generalizable robot control beyond vlas. *arXiv preprint arXiv:2512.15692*.
- Pertsch, K., Stachowicz, K., Ichter, B., Driess, D., Nair, S., Vuong, Q., Mees, O., Finn, C., and Levine, S. (2025). Fast: Efficient action tokenization for vision-language-action models. *arXiv preprint arXiv:2501.09747*.
- Qiu, Y., Zhao, Z., Li, W., Ziser, Y., Korhonen, A., Cohen, S. B., and Ponti, E. M. (2026). Self-improving world modelling with latent actions. *arXiv preprint arXiv:2602.06130*.
- Qu, D., Song, H., Chen, Q., Yao, Y., Ye, X., Ding, Y., Wang, Z., Gu, J., Zhao, B., Wang, D., et al. (2025). Spatialvla: Exploring spatial representations for visual-language-action model. *arXiv preprint arXiv:2501.15830*.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., and Sutskever, I. (2021). Learning transferable visual models from natural language supervision. In Meila, M. and Zhang, T., editors, *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763. PMLR.
- Shi, L. X., Ichter, B., Equi, M., Ke, L., Pertsch, K., Vuong, Q., Tanner, J., Walling, A., Wang, H., Fusai, N., et al. (2025). Hi robot: Open-ended instruction following with hierarchical vision-language-action models. *arXiv preprint arXiv:2502.19417*.
- Team, G. R., Choromanski, K., Devin, C., Du, Y., Dwibedi, D., Gao, R., Jindal, A., Kipf, T., Kirmani, S., Leal, I., Liu, F., Majumdar, A., Marmon, A., Parada, C., Rubanova, Y., Shah, D., Sindhvani, V., Tan, J., Xia, F., Xiao, T., Yang, S., Yu, W., and Zhou, A. (2025). Evaluating gemini robotics policies in a veo world simulator.
- Wei, S., Jing, H., Li, B., Zhao, Z., Mao, J., Ni, Z., He, S., Liu, J., Liu, X., Kang, K., Zang, S., Yuan, W., Pavone, M., Huang, D., and Wang, Y. (2026).  $\Psi_0$ : An open foundation model towards universal humanoid loco-manipulation. *arXiv preprint arXiv:2603.12263*.
- Wu, K., Hou, C., Liu, J., Che, Z., Ju, X., Yang, Z., Li, M., Zhao, Y., Xu, Z., Yang, G., Fan, S., Wang, X., Liao, F., Zhao, Z., Li, G., Jin, Z., Wang, L., Mao, J., Liu, N., Ren, P., Zhang, Q., Lyu, Y., Liu, M., He, J., Luo, Y., Gao, Z., Li, C., Gu, C., Fu, Y., Wu, D., Wang, X., Chen, S., Wang, Z., An, P., Qian, S., Zhang, S., and Tang, J. (2024). Robomind: Benchmark on multi-embodiment intelligence normative data for robot manipulation. *arXiv preprint arXiv:2412.13877*.
- Wu, P., Escontrela, A., Hafner, D., Abbeel, P., and Goldberg, K. (2023). Daydreamer: World models for physical robot learning. In *Proceedings of The 6th Conference on Robot Learning*, volume 205 of *Proceedings of Machine Learning Research*, pages 2226–2240. PMLR.
- Wu, W., Lu, F., Wang, Y., Yang, S., Liu, S., Wang, F., Zhu, Q., Sun, H., Wang, Y., Ma, S., et al. (2026). A pragmatic vla foundation model. *arXiv preprint arXiv:2601.18692*.
- Xiao, T., Radosavovic, I., Darrell, T., and Malik, J. (2022). Masked visual pre-training for motor control.
- Yang, J., Tan, R., Wu, Q., Zheng, R., Peng, B., Liang, Y., Gu, Y., Cai, M., Ye, S., Jang, J., et al. (2025a). Magma: A foundation model for multimodal ai agents. *arXiv preprint arXiv:2502.13130*.

- Yang, R., Yu, Q., Wu, Y., Yan, R., Li, B., Cheng, A.-C., Zou, X., Fang, Y., Cheng, X., Qiu, R.-Z., Yin, H., Liu, S., Han, S., Lu, Y., and Wang, X. (2025b). Egovla: Learning vision-language-action models from egocentric human videos. *arXiv preprint arXiv:2507.12440*.
- Yang, S., Li, H., Chen, Y., Wang, B., Tian, Y., Wang, T., Wang, H., Zhao, F., Liao, Y., and Pang, J. (2025c). Instructvla: Vision-language-action instruction tuning from understanding to manipulation. *arXiv preprint arXiv:2507.17520*.
- Ye, J., Wang, F., Gao, N., Yu, J., Zhu, Y., Wang, B., Zhang, J., Jin, W., Fu, Y., Zheng, F., et al. (2026a). St4vla: Spatially guided training for vision-language-action models. *arXiv preprint arXiv:2602.10109*.
- Ye, S., Ge, Y., Zheng, K., Gao, S., Yu, S., Kurian, G., Indupuru, S., Tan, Y. L., Zhu, C., Xiang, J., Malik, A., Lee, K., Liang, W., Ranawaka, N., Gu, J., Xu, Y., Wang, G., Hu, F., Narayan, A., Bjorck, J., Wang, J., Kim, G., Niu, D., Zheng, R., Xie, Y., Wu, J., Wang, Q., Julian, R., Xu, D., Du, Y., Chebotar, Y., Reed, S., Kautz, J., Zhu, Y., Fan, L., and Jang, J. (2026b). World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*.
- Ye, S., Jang, J., Jeon, B., Joo, S., Yang, J., Peng, B., Mandlekar, A., Tan, R., Chao, Y.-W., Lin, B. Y., Liden, L., Lee, K., Gao, J., Zettlemoyer, L., Fox, D., and Seo, M. (2025). Latent action pretraining from videos. In *The Thirteenth International Conference on Learning Representations (ICLR)*.
- Yuan, C., Zhou, R., Liu, M., Hu, Y., Wang, S., Yi, L., Wen, C., Zhang, S., and Gao, Y. (2025). Motiontrans: Human vr data enable motion-level learning for robotic manipulation policies. *arXiv preprint arXiv:2509.17759*.
- Yuan, T., Dong, Z., Liu, Y., and Zhao, H. (2026). Fast-wam: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*.
- Ze, Y., Zhang, G., Zhang, K., Hu, C., Wang, M., and Xu, H. (2024). 3d diffusion policy. *arXiv preprint arXiv:2403.03954*.
- Zeng, A., Florence, P., Yang, M., Du, Y., et al. (2024). Molmoact: Vision-language-action model for robotic manipulation. *arXiv preprint arXiv:2403.03368*.
- Zhai, X., Mustafa, B., Kolesnikov, A., and Beyer, L. (2023). Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 11975–11986.
- Zhao, T. Z., Kumar, V., Levine, S., and Finn, C. (2023). Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*.
- Zheng, J., Li, J., Wang, Z., Liu, D., Kang, X., Feng, Y., Zheng, Y., Zou, J., Chen, Y., Zeng, J., et al. (2025a). X-vla: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. *arXiv preprint arXiv:2510.10274*.
- Zheng, R., Niu, D., Xie, Y., Wang, J., Xu, M., Jiang, Y., Castañeda, F., Hu, F., Tan, Y. L., Fu, L., Darrell, T., Huang, F., Zhu, Y., Xu, D., and Fan, L. (2026). Egoscale: Scaling dexterous manipulation with diverse egocentric human data. *arXiv preprint arXiv:2602.16710*.
- Zheng, R., Wang, J., Reed, S., Bjorck, J., Fang, Y., Hu, F., Jang, J., Kundalia, K., Lin, Z., Magne, L., Narayan, A., Tan, Y. L., Wang, G., Wang, Q., Xiang, J., Xu, Y., Ye, S., Kautz, J., Huang, F., Zhu, Y., and Fan, L. (2025b). Flare: Robot learning with implicit world modeling. *arXiv preprint arXiv:2505.15659*.
- Zhou, Z., Zhu, Y., Zhu, M., Wen, J., Liu, N., Xu, Z., Meng, W., Cheng, R., Peng, Y., Shen, C., et al. (2025). Chatvla: Unified multimodal understanding and robot control with vision-language-action model. *arXiv preprint arXiv:2502.14420*.
- Zhu, L. Y., Kuppili, P., Punamiya, R., Aphiwetsa, P., Patel, D., Kareer, S., Ha, S., and Xu, D. (2025). Emma: Scaling mobile manipulation via egocentric human data. *arXiv preprint arXiv:2509.04443*.

## 9 StarVLA v1.0 的作者与贡献者

StarVLA 的蓬勃发展得益于其专注的核心团队与活跃的开源社区之间的协同作用。为准确反映参与性质，我们将贡献者分为两类：作者与社区贡献者。我们向所有帮助塑造和扩展 StarVLA 的人致以最深切的感谢。

**作者。**叶金辉，高宁，陈一伦<sup>†</sup>，郭伟宇，王子轩，陈宇星，王芳静，杨森乔，王成耀，刘玉琪，楚萌，陆长胜，陈鹏光，刘枢<sup>†</sup>，贾佳亚<sup>†\*</sup>

**社区贡献者。**余俊秋，曾爽，连世杰，万瀚文，张长玖，宋志杰，李明胜，王秋月，谢思成，郑金良，周德宇，周佳明，戴璐，赵晓瑞

**贡献者政策。**作者构成 StarVLA 的核心团队。该团队负责持续迭代核心功能、维护基础框架，并为项目提供长期持续的支持。我们强烈鼓励有兴趣做出持续性、结构性贡献并希望加入核心作者团队的研究人员和开发者与我们联系。社区贡献者是项目更广泛生态系统的关键力量。我们持续从开源社区获得宝贵的支持——从新功能实现（拉取请求）和缺陷修复到建设性反馈。我们深切感谢这些努力，它们使 StarVLA 得以快速发展。完整且持续更新的贡献者历史记录维护于 [starvla.github.io/contributors](https://starvla.github.io/contributors)。<sup>†</sup> 通讯作者。 \* 香港科技大学冯·诺依曼研究所