

StarVLA- α : 降低视觉-语言-动作系统的复杂度

Jinhui Ye^{1,†} Ning Gao^{2,†} Senqiao Yang³ Jinliang Zheng⁴ Zixuan Wang¹ Yuxin Chen¹
Pengguang Chen⁶ Yilun Chen^{5,‡} Shu Liu⁶ Jiaya Jia^{1,6,‡}

¹HKUST ²XJTU ³CUHK ⁴THU ⁵Tongyi Lab, Alibaba Group ⁶SmartMore Ltd.

Abstract

视觉-语言-动作（VLA）模型近年来已成为构建通用机器人智能体的一种有前景的范式。然而，VLA 领域仍然高度分散且复杂：现有方法在架构、训练数据、实体配置以及基准特定的工程处理上差异显著。本文提出 **StarVLA- α** ，一个简单而强大的基线，旨在受控条件下研究 VLA 的设计选择。**StarVLA- α** 刻意最小化架构与流程复杂度，以减少实验混杂因素并支持系统性分析。具体而言，本文重新评估了若干关键设计维度，包括动作建模策略、机器人特定预训练以及接口工程。在 LIBERO、SimplerEnv、RoboTwin 和 RoboCasa 上的统一多基准训练中，同一简单基线仍保持高度竞争力，表明强大的视觉-语言模型骨干结合极简设计已足以实现强劲性能，无需依赖额外的架构复杂度或工程技巧。值得注意的是，本文的单一通用模型在公开的真实世界 RoboChallenge 基准上比 $\pi_{0.5}$ 高出 20%。本文期望 **StarVLA- α** 能作为未来 VLA 领域研究的坚实起点。代码将发布于 <https://github.com/starVLA/starVLA>。

Date: April 2026

Project Page: <https://starvla.github.io>

1 引言

机器人操作领域的最新进展日益受到视觉-语言-动作（Vision-Language-Action, VLA）模型的推动，这些模型旨在超越特定任务的策略，迈向通用机器人智能体。自 RT 系列 Brohan 等人（2023, 2022）；Belkhale 等人（2024）作为机器人基础模型提出以来，该领域通过利用大型基础模型、扩展机器人数据 Black 等人（2024a）；Wu 等人（2024）；Generalist AI（2025）以及通用多模态监督 Intelligence 等人（2025a）；Brohan 等人（2023）；Yang 等人（2025b）；Chen 等人（2025b）；Ye 等人（2026），实现了令人瞩目的策略迁移能力和任务覆盖范围 Brohan 等人（2022, 2023）；Kim 等人（2024）；Octo Model Team 等人（2024）；Black 等人（2024b）；Intelligence 等人（2025a），从而迅速发展。因此，越来越多的 VLA 系统在各种机器人基准上展示了令人印象深刻的结果 Li 等人（2024d）；Liu 等人（2024a）；Mees 等人（2022）；Mu 等人（2025）；Chen 等人（2025a）；Gu 等人（2023）。与此同时，开源工作 Kim 等人（2024）；Intelligence 等人（2025b）；Bjorck 等人（2025）；Liu 等人（2024c）；Cai 等人（2026）拓宽了可及性并加速了实验。

尽管 VLA 系统发展迅速，该领域仍缺乏对哪些组件真正驱动性能提升的清晰理解。现有系统在模型架构、预训练数据、实体配置和基准特定微调方面各不相同，使得经验比较难以解释。所报告的性能提升往往与数据集选择、预处理流程和基准特定工程纠缠在一起，掩盖了增益究竟来自建模创新还是实验设置。

[†] 同等贡献

[‡] 通讯作者




图 1: 当前的 VLA 系统由于异构的机器人数据集、碎片化的架构以及大量的基准特定工程而难以比较。StarVLA- α 通过简单的基于 VLM 的架构、最少的数据处理和统一的跨基准训练消除了这些混杂因素。这种受控基线能够对动作建模、机器人预训练和接口设计进行系统分析, 揭示了许多普遍采用的复杂性所提供的上下文相关收益有限。

变化。与视觉语言建模 (VLM) 中训练实践逐渐收敛于标准化方案不同 Li et al. (2024a); Dai et al. (2023); Liu et al. (2024b), 视觉语言动作 (VLA) 研究仍然高度碎片化。因此, 建立更清晰的方法论共识对于指导该领域未来的进展日益重要。

然而, 由于 VLA 流程中存在如图 1 所示的显著异质性, 达成方法论共识是一个具有挑战性且长期存在的问题。首先, 预训练数据和机器人形态配置在不同研究中差异显著。机器人平台和遥操作流水线的快速演进导致了异构数据集, 这些数据集具有不兼容的接口、动作空间和归一化方案 Kim et al. (2024); Liu et al. (2024c)。机器人形态涵盖单臂机械臂 (如 Franka 和 UR5) Franka Emika (2025); Universal Robots (2025)、轮式双臂系统 Galbot (2025); Galaxea (2025); AgiBot (2025) 以及人形机器人 Fourier Intelligence (2025); Unitree Robotics (2025); AgiBot (2025), 并伴随相机视角和末端执行器的差异, 进一步使建模选择与形态特定的预处理相互纠缠。其次, 建模和训练策略缺乏共识。现有 VLA 系统采用视觉塔、语言骨干和动作专家的多种组合 Octo Model Team et al. (2024); Kim et al. (2024); Li et al. (2024c, 2023b); Black et al. (2024a); Intelligence et al. (2025b); Team (2025), 而连续机器人状态和控制的动作参数化与归一化等设计选择仍未被充分理解。第三, 评估实践的多样性使比较变得复杂。通常需要针对特定基准的超参数调优、数据集划分和动作分块策略才能达到高性能 Li et al. (2024d); Liu et al. (2024a); Mu et al. (2025); Chen et al. (2025a); Nasiriany et al. (2024); Li et al. (2023a), 且基准内的强劲结果并不一定转化为更广泛分布偏移下的鲁棒性 Pumacay et al. (2024); Nasiriany et al. (2024); Gao et al. (2025)。

为揭示视觉-语言-动作 (VLA) 系统的基本组成, 本文基于 StarVLA 社区 (2026) 的基础设施提出 **StarVLA- α** , 这是一个简单但强大的基线, 可作为系统研究现有 VLA 范式的起点。该基线明确旨在减少实验混淆并隔离建模效应。本文不引入额外的架构复杂度, 而是刻意最小化结构差异, 采用预训练的视觉-语言模型 (VLM) 骨干 (Qwen3-VL), 不进行机器人特定预训练或复杂的动作工程。本文遵循官方评估协议, 避免针对特定基准的调优, 以确保受控且可复现的比较。目标并非架构新颖性, 而是方法论清晰性: 通过控制主要变异来源, **StarVLA- α** 为在可比条件下重新评估广泛采用的 VLA 设计选择提供了受控基础。

在此受控设置下, 一个基于强大 VLM 的基线在保持骨干、训练数据和训练设置完全一致的情况下, 达到或超越了近期 VLA 系统。在受控条件下, 本文考察了

常见 VLA 设计选择的必要性，沿三个维度展开：动作头设计、机器人特定预训练以及数据/接口工程。在保持骨干、数据规模和训练协议一致的前提下，本文在统一流程中比较了几种典型的 VLM 到 VLA 实例化方案，包括基于离散词元的自回归解码（FAST 风格）、使用轻量级多层感知机（MLP）头进行直接连续动作回归（OpenVLA-OFT 风格）、基于扩散/流匹配的连续动作生成（ π_0 风格），以及将 VLM 与独立低层动作模块耦合的双系统设计（GR00T 风格）。结果表明，简单的 MLP 动作头仍具有高度竞争力，而更复杂的设计仅带来场景相关的增益（见第 3.1 节）。本文重新评估了通过引入大规模动作数据进行机器人预训练的方法（Collaboration 等, 2023; contributors, 2025）。本文观察到，异构预训练可能损害跨具身泛化能力，且领域对齐的数据仅带来条件性而非整体性的改进（第 3.2 节）。最后，本文重新审视了常见的工程选择（例如辅助输入、动作输出建模）。总体而言，消除主要混淆因素后表明，架构和工程复杂度带来的增益有限且依赖于具体情境（第 3.3 节）。

为缓解单一基准评估中潜在的基准特定偏差，本文进一步在更广泛的泛化设置下评估鲁棒性。我们在 LIBERO Liu et al. (2024a)、SimplerEnv Minderer et al. (2022)、RoboTwin 2.0 Chen et al. (2025a) 和 RoboCasa-GR1 Nasiriany et al. (2024); Bjorck et al. (2025) 上联合训练统一模型，不进行基准特定适配，并在不同实施例间使用统一的动作填充（第 4 节）。在此多基准设置下，同样简单的基线仍具竞争力，且在若干情况下优于任务特定模型。这些结果表明，强大的骨干初始化和统一训练能够支持跨任务和跨实施例的泛化，而无需增加额外的架构复杂度。

本文贡献总结如下：

- 本文提出一个简单而强大的视觉-语言-动作基线，消除了关键混杂因素，表明精简的视觉-语言模型设计可在涵盖五种实施例的四个基准上达到领先性能。
- 在受控的骨干、数据和训练设置下，本文系统地重新评估了常见的视觉-语言-动作设计选择，发现增加的架构或数据工程复杂度带来的收益比通常假设的更小且更依赖上下文。
- 本文进一步证明，在无任务特定适配的情况下，跨基准联合训练的单一通用模型能够跨任务和实施例泛化，这得益于强大的初始化和标准化流程。

2 StarVLA- α

自 2022 年 RT-1 Brohan et al. (2022) 提出以来，视觉-语言-动作（Vision – Language – Action, VLA）研究一直致力于构建基于基础模型的通用具身智能体。在此过程中，社区探索了众多设计维度——视觉骨干（如 SigLIP Zhai et al. (2023)、DINO Oquab et al. (2023)、CLIP Radford et al. (2021)）、动作头（离散标记、连续回归、扩散、流匹配）以及动作/数据流水线（增量动作与相对动作；跨末端执行器/关节/6D 位姿的实施例特定预处理）。尽管这些选择带来了稳步提升，但也使领域碎片化：系统往往变得复杂、难以复现，并过度调优至基准特定细节，这可能损害向新实施例的迁移。

在此背景下，我们提出一个简单的问题：能否化繁为简？具体而言，我们检验一个强大的视觉语言模型骨干是否能在不依赖复杂架构或繁重数据工程的情况下，提供具有竞争力的性能。为此，我们从零构建了一个简洁、透明且稳健的视觉语言动作基线（图 2）。

2.1 简洁统一的视觉语言动作框架

我们的框架遵循最小充分性假设：一个强大的视觉语言模型搭配轻量级动作头，即可获得通常归因于更复杂设计的大部分收益。此处，“简洁”体现在两个方面：最少的数据处理和简单的架构。

最少的数据处理。为促进跨多种机器人形态和基准的泛化，我们采用一个在所有环境中共享的单一最小数据流水线。模型以原始 RGB 图像和提供的语言指令作为输入，不进行针对特定基准的工程化或自定义格式化。我们仅使用训练集对动作进行归一化（零均值、单位方差）。评估时，我们遵循每个




图 2: StarVLA- α 概览。我们采用统一的视觉语言模型骨干（Qwen3-VL），配合最少预处理和轻量级多层感知机动作头。这种简单设置避免了专用视觉编码器、针对特定基准的数据流水线以及复杂动作头，同时支持跨多种基准的一致训练与评估。

基准的官方协议。这种统一的预处理使框架能够直接应用于新的机器人形态和基准，无需额外适配。

简洁的架构。我们遵循通用做法，将视觉语言模型骨干与轻量级动作头耦合，用于连续动作预测。我们使用 Qwen 系列模型（Wang 等人，2024b；Bai 等人，2025）实例化骨干，具体为 Qwen3-VL。选择 Qwen 有两个原因：（i）它是广泛采用的开源视觉语言模型，拥有强大的社区支持；（ii）其统一设计原生处理视觉和语言输入，避免了单独选择和组合视觉编码器（例如 CLIP（Radford 等人，2021）、SigLIP（Zhai 等人，2023））的需要。在视觉语言模型之上，我们附加一个简单的多层感知机动作头，读取指定动作令牌的隐藏状态，并回归一段连续动作。模块化设计还允许我们以最小的改动替换其他视觉语言模型骨干或动作头。

统一基准集成。为了实现系统性评估，我们将多样化的操作基准套件（例如 LIBERO、SimplerEnv、RoboTwin 2.0 和 RoboCasa-GR1）集成到统一流水线中，无需针对特定基准的设计。对于每个基准，我们严格遵循其原始数据和评估协议，仅应用我们最小的处理，同时保持动作表示一致。我们将异构性限制在薄适配器中，这些适配器标准化观测格式、动作接口和评估入口点。因此，相同的模型和训练方案在所有基准上无需定制即可运行，并且该框架易于扩展到新基准。此设置还支持更通用的评估机制：在所有基准上联合训练单个模型。我们请读者参阅第 4 节，了解此统一多基准设置中的详细结果。

2.2 实验设置

我们在多样化的广泛使用的操作基准上评估我们的模型：**LIBERO**（Liu 等人，2024a）、**SimplerEnv**（Li 等人，2024d）、双臂基准 **RoboTwin 2.0**（Chen 等人，2025a）以及人形机器人基准 **RoboCasa-GR1**（Nasiriany 等人，2024；Bjorck 等人，2025）。基准详情见附录 B。

基线。我们将 StarVLA- α 与几种代表性的视觉语言动作方法进行了比较：FAST Pertsch 等人（2025 年）、OpenVLA-OFT Kim 等人（2024 年）、 π_0 Black 等人（2024 年 a）以及 GR00T-N1.6 Bjorck 等人（2025 年）。这些先前的方法通常在每个基准上使用各自任务特定的数据处理流程分别进行训练。对于我们的方法，我们考虑了两种训练协议：（1）专家训练，即使用我们统一的极简数据管道在每个基准的训练集上独立训练 StarVLA- α ；（2）通才训练，即将所有基准的数据合并为一个单一的训练集，并训练一个单一的模型。我们注意到，通才模型代表了一种大规模的统一训练场景，其纳入是为了完整性考虑；为了在相似的计算预算下进行直接比较，我们主要关注专家训练。在统一设置中，来自不同机器人的动作被简单地用零填充到最大维度（此处为 32），

表 1：StarVLA- α 与现有视觉语言动作方法的性能比较。 * 表示同时使用干净数据和随机数据进行训练。默认的 StarVLA- α 代表在每个基准特定数据集上分别训练的多个模型，而通才模型代表在所有数据集上联合训练的单一模型。

Method	LIBERO					SimplerEnv			RoboTwin 2.0			RoboCasa-GR1 (avg of 24 tasks)
	Spatial	Object	Goal	Long	avg	WidowX	Google VA	Google VM	clean	clean*	random*	
Specialist												
OpenVLA-OFT	97.6	98.4	97.9	94.5	97.1	31.3	54.3	63.0	–	–	–	–
π_0	96.8	98.8	95.8	85.2	94.1	27.1	54.8	58.8	46.42	65.9	58.4	–
π_0 +FAST	96.4	96.8	88.6	60.2	85.5	39.5	60.5	61.9	–	–	–	–
$\pi_{0.5}$	98.8	98.2	98.0	92.4	96.9	46.9	68.4	72.7	60.2	82.7	76.8	37.0
GR00T-N1.6	97.5	98.5	97.5	94.4	97.0	62.0	65.3	67.7	–	–	–	47.6
StarVLA- α	99.0	99.8	98.5	94.1	98.8	64.6	70.2	76.0	50.3	88.2	88.3	53.8
StarVLA- α (Generalist)	98.7	99.7	98.6	94.2	97.8	65.2	69.8	74.3	–	88.7	87.8	57.3

无需任何针对特定任务的工程；更多细节见第 4 节。训练和实现细节见附录 C。

2.3 主要结果

如表 1 所示，与先前的视觉语言动作方法相比，StarVLA- α 在所有基准上均表现出色。在 LIBERO 上，StarVLA- α 达到了 98.8% 的平均成功率，超越了所有先前的方法。在 SimplerEnv 上，它大幅超越了现有最佳方法（例如，在 Google VM 上高出 6.8%）。在更具挑战性的双臂和人形机器人设置中，StarVLA- α 的成功率最高可达 53.8%，凸显了即使使用轻量级动作头，强大的视觉语言模型骨干也能发挥出优势。

此外，在统一的通才训练设置下，我们发现使用多样化数据训练单一模型可以在每个基准上取得具有竞争力的性能，同时在诸如 RoboCasa-GR1（第 4 节）等具有挑战性的基准上显著提升性能。

综合而言，这些结果支持了本文的核心假设：一个强大的视觉语言模型（VLM），配合一个直接的动作头与最少的数据预处理，能够实现极具竞争力的性能。更广泛地看，这些结果提出了一种实用的方法来降低该领域日益增长的复杂度：固定骨干网络，标准化数据流程，并避免针对特定任务的工程设计。这种方法产生了一个强大且可复现的基线，可作为未来工作的坚实基础。

3 重新思考视觉-语言-动作系统中的常见实践

如第 2 节所述，StarVLA- α 基线设计刻意保持简洁：将强大的视觉语言模型（Qwen3-VL）与轻量级多层感知机动作头配对，使用经过最少处理的数据，且不引入状态输入、历史帧或额外预训练。尽管设计极简，StarVLA- α 仍在多个基准上取得了最先进的结果，并显著超越了先前方法。这一发现引出一个自然的问题：当具备强大骨干网络时，究竟是什么驱动了视觉语言动作模型的性能？本节系统分析了三种常被强调的设计选择：动作头架构、动作特定预训练以及数据工程。

3.1 不同的动作头设计是否重要？

动机。鉴于本文简单的多层感知机（MLP）头已能提供强劲性能，我们探究当与同样强大的视觉语言模型（VLM）骨干网络搭配时，更复杂的动作头（例如快速令牌预测器、扩散模型或双系统设计）是否能带来额外收益。以往的比较常因骨干网络和训练方案的差异而受到干扰；本文的统一框架使我们能够单独分离出动作头本身的影响。

实现细节。如图 3 所示，我们评估了四种常用设计：（1）**StarVLA- α - FAST**：

通过自回归 **FAST** 分词器进行离散动作预测，类似于 π_0 -**FAST** Pertsch 等人（2025）。（2）**StarVLA- α** ：使用轻量级多层感知机头对专用动作标记进行连续动作回归，遵循 OpenVLA-OFT Kim 等人（2025）。（3）**StarVLA- α -GR00T**：一种双系统架构，其中视觉语言模型作为系统 2（高层推理），流匹配模块作为系统 1 执行动作，遵循 GR00T N1.5 Bjorck 等人（2025）。（4）**StarVLA- α - π** ：使用流匹配专家进行扩散式连续动作预测，类似于 π_0 Black 等人（2024a）。




图 3: StarVLA- α 上的动作专家设计。从左到右: StarVLA- α -FAST、StarVLA- α (多层感知机回归)、StarVLA- α -GR00T (双系统流匹配) 和 StarVLA- α -PI (扩散式流匹配)。

表 2: 不同动作头设计的性能比较。

Method	LIBERO					SimplerEnv			RoboTwin 2.0			RoboCasa-GR1
	Spatial	Object	Goal	Long	avg	WidowX	Google VA	Google VM	clean	clean*	random*	(avg of 24 tasks)
StarVLA- α	99.0	99.8	98.5	94.1	98.8	64.6	70.2	76.0	50.3	88.2	88.3	53.8
StarVLA- α -FAST	98.3	98.4	97.3	91.6	97.8	35.6	58.8	60.1	46.4	72.5	83.2	45.0
StarVLA- α -GR00T	98.9	99.6	98.4	95.3	98.7	65.3	70.7	75.3	48.8	88.0	88.5	52.8
StarVLA- α - π	98.0	99.2	98.2	93.6	98.1	65.9	72.8	76.6	50.8	88.1	88.8	48.9

主要结果。 如表 2 所示，我们在多个设置下比较了四种动作头设计。连续动作预测在几乎所有基准上始终优于离散动作预测 (StarVLA- α -FAST)。然而，在连续动作变体中，三种动作头达到了相当的性能。特别是，所有方法在 LIBERO 上成功率超过 98%，在 WidowX 上约为 65%。值得注意的是，最简单的设计 StarVLA- α 在 RoboCasa-GR1 上达到了 53.8%。

要点。 这些结果揭示了两个关键观察：（1）连续动作预测对于实现强大性能至关重要，并且始终优于基于离散标记的方法；（2）在给定强大视觉语言模型的情况下，连续动作头的选择影响有限。因此，轻量级多层感知机头可作为一种简单、高效且有竞争力的默认选择。这一结果表明，当底层视觉语言模型骨干足够强大时，动作头中额外的架构复杂性是不必要的。

3.2 现有的动作特定预训练是否重要？

动机。 大多数现有的视觉-语言-动作 (VLA) 模型在下游任务微调之前会进行大规模的动作特定预训练。例如，OpenVLA 使用 Open X-Embodiment (OXE) 数据集 Kim 等人 (2024), $\pi_{0.5}$ 利用多样化的机器人和多模态数据 Intelligence 等人 (2025b)，而 GR00T 则依赖大规模仿真数据集 Bjorck 等人 (2025)。这种预训练被广泛认为对取得优异性能至关重要。然而，我们的 StarVLA- α 基线仅基于预训练的视觉-语言模型 (Qwen3-VL-4B)，未使用任何动作特定数据，就已取得具有竞争力的结果。这一观察引出一个关键问题：在拥有强大视觉-语言模型骨干的情况下，额外的动作特定预训练是否能带来进一步的益处？

实验设置。 为回答这一问题，我们采用 StarVLA- α 架构并固定所有超参数。我们比较四种预训练设置，并在 RoboCasa-GR1 和 RoboTwin 上进行评估：（1）

StarVLA- α (基于视觉-语言模型)：不进行额外预训练；预训练的 Qwen3-VL 模型直接在任务特定数据上微调。（2）**+OXE**：预训练的 Qwen3-VL 模型先在 OXE 数据集 Collaboration 等人 (2023) 上训练，然后在任务特定数据上微调。（3）**+InternData-A1**：预训练的 Qwen3-VL 模型先在 InternData-A1 数据集 contributors (2025) 上训练，该数据集与 RoboTwin 共享重叠的机器人形态（且部分对齐的动作接口），然后在任务特定数据上微调。（4）**+RoboTwin-Rand**：Qwen3-VL 模型在 RoboTwin 随机化数据 Chen 等人 (2025a)（同一领域内）上预训练，然后在任务特定数据上微调。

结果。 如表 3 所示，当有足够的任务特定数据时，StarVLA- α 基线取得接近最佳的性能，在 RoboTwin 2.0 和 RoboCasa-GR1 上分别达到 88.2 和 53.8。添加大规模预训练数据并未持续提升性能；域外数据（如 OXE）甚至可能降低结果。尽管使用 InternData-A1 或 RoboTwin 数据进行预训练有所改善

表 3：额外机器人数据预训练的效果。

Mid-Pretraining	Traj. Num.	RoboTwin-Clean			RoboCasa-GR1		
		Clean 50×50	+Random $\times 100$	+Random $\times 500$	24×10	24×100	24×1000
StarVLA- α	-	50.3	78.5	88.2	9.8	39.4	53.8
+ OXE	232.6k	30.2	40.6	83.6	1.2	17.7	27.8
+ InternData-A1	630k	63.6	80.4	88.6	2.8	27.6	35.4
+ RoboTwin-Rand	25k	79.7	84.1	88.8	2.2	27.3	33.3

表 4：跨基准与数据规模的数据工程消融实验。

Mid-Pretraining	LIBERO avg	RoboTwin-2.0			RoboCasa-GR1		
		Clean 50×50	+Random $\times 100$	+Random $\times 500$	24×10	24×100	24×1000
StarVLA- α	98.8	50.3	78.5	88.2	9.8	39.4	53.8
+ Proprioception	98.5	60.8	79.6	88.0	12.5	42.1	54.2
+ History frames	97.8	44.8	76.2	87.4	10.2	33.2	52.6
+ Delta action	98.1	48.7	77.8	85.6	15.8	43.2	54.8
+ Relative action	98.7	51.1	77.9	87.3	13.6	40.6	55.5

RoboTwin 的性能，尤其是在低数据量情况下，仍然会降低 RoboCasa 上的性能，这表明即使在领域内的提升也可能无法跨实施例或任务迁移。

要点：当预训练数据与目标任务高度匹配时，额外的动作特定预训练能够提升性能，但可能损害对未见领域的泛化能力。强大的视觉语言模型基线已奠定坚实基础；因此，进一步预训练犹如双刃剑，应谨慎应用。

3.3 数据工程是否必要？

动机。除架构与预训练之外，许多视觉-语言-动作（VLA）模型依赖各类数据工程技术以提升性能。这些技术包括感知相关输入，如本体感受状态与堆叠历史帧，以及动作表示，如绝对、增量或相对动作。尽管这些技术被广泛使用，但其必要性仍不明确，尤其是在具备强大视觉-语言模型（VLM）主干的情况下。本节中，我们系统性地考察 StarVLA- α 框架内一组常见的数据工程选择。我们在多个基准与数据规模上对其进行评估，以判断它们是否能带来一致的改进。

实验设置。我们研究了四种常用的数据工程选择：（1）本体感知黑盒

et al. (2024a); Bjorck et al. (2025)：将机器人关节状态作为输入，在动作头之前与视觉语言模型特征拼接。（2）历史帧 Li et al. (2025)：堆叠前两帧以提供时序上下文。（3）增量动作 Feng et al. (2026)：预测相对于当前关节位置的变化。（4）相对动作 Feng et al. (2026)：在参考坐标系（例如，以末端执行器为中心）中预测动作。

每种修改均应用于 StarVLA- α ，同时保持所有其他训练超参数不变。我们在三个代表性基准上报告结果：LIBERO（四个任务的平均值）、RoboTwin 2.0 和不同数据规模下的 RoboCasa-GR1。对于 RoboTwin 2.0，数据设置包括 Clean 50×50 ，+Random 100 和 +Random 500。对于 RoboCasa，我们分别使用 24×10 ， 24×100 和 24×1000 次演示进行评估。

结果。如表 4 所示，当数据集较小时，例如 RoboTwin 2.0 上的 Clean 50×50 或 RoboCasa-GR1 上的 24×10 ，某些数据工程技术能带来适度提升。然而，一旦获得足够的任务特定数据，这些技巧几乎不再带来额外收益，其表现与未使用数据工程的基线相似。

要点。当基于强大的视觉语言模型和干净的代码库构建时，数据工程技术在任务特定数据有限的情况下能带来适度收益。然而，一旦获得足够的任务特定数据，其影响便微乎其微。

4 作为通才的一体化评估

在第 2 节中，我们构建了一个干净的视觉语言动作框架，在多个独立基准上取得了强劲性能。在第 3 节中，我们进一步反思了若干现有技巧，并分析了它们对模型训练的影响。因此，在考察了影响训练的因素之后，我们在本节中更进一步，探讨：什么是评估模型是否真正具备泛化能力的有效评估范式？

现有评估模式。具身智能（Embodied AI）社区怀有统一的愿景：开发一种能够在多样化任务、环境和机器人之间无缝协作的通用智能体。然而，在实践中，研究格局仍然碎片化。若干最先进的系统需要在特定基准数据集上进行微调，才能在单个基准上取得优异结果，但在其他基准上性能急剧下降。这导致了该领域一个令人担忧的趋势：新提出的策略在一个基准上表现出色，但迁移到另一个基准时往往性能大幅下降，使得展示真正的泛化能力变得困难。

作为通用智能体的一体化评估。近年来，大语言模型（Large Language Model）取得了显著成功，展现出跨多样化任务的泛化能力。一种统一的评估范式——要求单一模型同时处理多个基准——推动了该领域泛化能力的进步。这表明，恰当的评估范式能够有意义地塑造模型发展和领域的整体方向。因此，直观上，具身智能应当经历类似的范式转变：在广泛多样的基准上评估单一模型，以确保其能力不局限于任何特定环境。

4.1 任务设置

在此设置中，我们利用所有数据集联合训练单一模型，并直接在多个基准上进行评估，无需在特定基准数据集上进行额外微调。具体而言，我们选择 LIBERO、SimplerEnv、RoboTwin 2.0 和 RoboCasa-GR1 作为统一基准套件，并在这些基准的合并训练集上训练模型。

4.2 实验

实现细节。我们将学习率设置为 1×10^{-4} ，批量大小为 256，并在 5 个数据集上进行训练。此外，为解决不同机器人动作维度的差异，我们不引入任何任务特定设计。相反，我们对自由度较低的机器人的动作空间进行填充，使所有动作向量在我们的设置中统一扩展至 32 维。

基线。为进一步证明我们方法及所提设置的有效性，我们报告了专家结果（模型仅在单个数据集上训练）和通用训练设置下的结果。除了与我们的模型比较外，我们还评估了若干最先进的方法，如 $\pi_{0.5}$ 和 GR00T-N1.6。

结果。如表 5 所示，我们将通用设置下训练的模型（所有数据集联合用于训练）与在单个基准上训练的专家模型进行比较。我们的通用模型在大多数基准上持续达到最先进或具有竞争力的性能。特别是在具有 24 个子任务的具有挑战性的 RoboCasa-GR1 基准上，我们联合训练的模型性能提升了 3.5%。这些结果表明，单一模型能够有效处理多样化任务和机器人形态，支持为具身智能开发更统一的评估范式。

4.3 讨论与分析

我们的方法简单：直接将所有动作填充到相同维度，并使用 Qwen3-VL 作为预训练模型，却取得了强劲的性能。因此，在本节中，我们讨论并分析在这种通用设置中最关键的因素是什么，以及为什么如此简单的方法表现如此出色。我们从多个角度审视这个问题，包括动作处理、模型大小、模型初始化以及批大小的影响。

我们真的需要为每种形态设计特定的动作吗？先前的研究，如 ABot-VLA Yang 等人（2026）和 LingBot-VLA Wu 等人（2026），提出了复杂的、针对特定机器人的解决方案，包括

表 5：通用设置与专家设置的性能比较。专家表示在各自基准特定数据集上分别训练的多个模型，而通用表示在所有数据集上联合训练的单一模型。

Settings	Method	LIBERO					SimplerEnv			RoboTwin 2.0			RoboCasa-GR1 (avg of 24 tasks)
		Spatial	Object	Goal	Long	avg	WidowX	Google VA	Google VM	clean	clean*	random*	
Specialist	$\pi_{0.5}$	98.8	98.2	98.0	92.4	96.9	46.9	68.4	72.7	60.2	82.7	76.8	37.0
	GR00T-N1.6	97.5	98.5	97.5	94.4	94.1	67.8	41.5	35.2	—	—	—	47.6
	StarVLA- α - π	98.0	99.2	98.2	93.6	98.1	65.9	72.8	76.6	50.8	88.1	88.8	48.9
	StarVLA- α -GR00T	98.9	99.6	98.4	95.3	98.7	65.3	70.7	75.3	48.8	88.0	88.5	52.8
	StarVLA- α	99.0	99.8	98.5	94.1	98.8	64.6	70.2	76.0	53.4	88.2	88.3	53.8
Generalist	StarVLA- α	98.7	99.7	98.6	94.2	97.8	65.2	69.8	74.3	—	88.7	87.8	57.3




图 4：多形态动作参数化比较。左：RDT 动作。中：多动作头。右：简单填充策略。

统一动作空间和针对每种机器人形态定制的多动作头。然而，现代视觉-语言模型（VLM）拥有足够的智能和参数容量来处理多样化任务。因此，我们能否采用简单的填充策略，让 VLA 模型自身识别和管理跨多形态的任务？如表 6 所示，我们将简单填充策略与 RDT 动作和多动作头（图 4）进行比较。我们的方法在 LIBERO 和 RoboTwin 2.0 上取得了可比的性能，同时在 Google Robot VM 和 RoboCasa-GR1 上分别提升了 2.9% 和 4.8%。这些结果表明，对于具有挑战性的跨形态任务，复杂的专家设计可能并非必要。

模型规模的影响是什么？为了进一步探究模型规模在这一通用一体化设定下对视觉-语言-动作（VLA）性能的影响，我们在相同实验设置下评估了三个预训练的 Qwen3-VL 模型（2B、4B 和 8B）。如图 5 所示，与 2B 模型相比，4B 模型在 Simpler 上取得了显著的性能提升。附录 D 中的额外结果进一步表明，这种提升超越了单一基准，在 WidowX 上带来了 18.1% 的增益，在 RoboCasa-GR1 上带来了 6.6% 的增益。然而，与 4B 模型相比，8B 模型并未展现出显著的额外改进，增益保持在 1% 以内。这些结果表明，在当前训练规模和场景下，模型规模不应过小，但 4B 参数量级已经足够。




图 5：VLA 训练的扩展趋势。左：性能随模型规模的变化。右：性能随总批大小的变化。

表 6：多具身动作参数化的性能比较。

Method	LIBERO	SimplerEnv			RoboTwin 2.0		RoboCasa-GR1
	Avg	WidowX	Google VA	Google VM	clean	random	avg
RDT action Liu et al. (2024c)	97.2	63.9	68.2	71.4	87.2	86.6	52.3
Multi Action Header Wang et al. (2024a)	97.2	60.6	66.3	67.8	85.6	86.1	53.5
Simple Padding Black et al. (2024a)	97.8	65.2	69.8	74.3	88.7	87.8	57.3

表 7：RoboChallenge 中作为通才的真实世界评估。SR 表示成功率，score 表示进度得分。

Robot	Task	StarVLA- α		$\pi_{0.5}$		π_0	
		SR	score	SR	score	SR	score
ARX5	arrange flowers	40.0	66.5	0.0	30.5	0.0	13.5
	arrange paper cups	20.0	63.0	0.0	31.0	0.0	15.0
	fold dishcloth	0.0	3.5	0.0	0.0	0.0	0.0
	open the drawer	20.0	60.0	50.0	80.0	0.0	20.0
	place shoes on rack	50.0	70.0	0.0	20.0	0.0	16.5
	put cup on coaster	100.0	98.0	70.0	63.0	0.0	0.0
	search green boxes	60.0	58.5	0.0	3.0	0.0	0.0
	sort electronic products	20.0	39.4	0.0	22.5	0.0	22.5
	turn on light switch	50.0	59.0	10.0	25.0	20.0	29.0
	water potted plant	10.0	32.0	0.0	0.0	0.0	0.0
	wipe the table	0.0	44.5	10.0	28.0	0.0	29.0
	Avg.	33.6	54.5	12.7	27.6	3.6	14.7

批大小在通才设定中重要吗？绝对重要！如图 5 所示，附录 D 中提供了额外结果，我们在相同总训练规模下评估了 64、128、256、512 和 1024 的批大小。随着批大小的增加，性能持续提升。批大小为 512 时，模型已经取得了强劲的性能，例如在 RoboCasa-GR1 上达到 57.3，在 RoboTwin-Clean 上达到 57.2。这些结果表明，较大的批大小能够确保训练过程中足够的多样性，是一个关键因素。它有助于防止模型陷入局部极小值，从而实现更好的泛化。

5 真实世界实验

在本节中，我们验证了所提出的极简框架在实体机器人实验中仍具有竞争力。我们在公开的真实世界基准 **RoboChallenge** Yakefu 等人 (2025) 上评估了模型，该基准提供了标准化任务，便于与现有模型直接比较。额外的真实世界分布外实验见附录。

基准。RoboChallenge 是一个大规模真实机器人评估平台，旨在以标准化和可复现的方式评估实体硬件上学习到的机器人控制策略。我们在 RoboChallenge 套件上进行评估，该套件包含多个桌面操作任务（例如物体重定向、插入和多阶段操作）。遵循基准协议，每个任务执行多次以减少真实机器人试验中的随机性，性能通过预定义任务成功标准下的平均成功率来衡量。更多实现细节见附录。

结果。如表 7 所示，在 ARX5 机器人上，我们执行了标准的 11 项任务。结果表明，我们的 StarVLA- α 达到了 33.6 的成功率和 54.5 的进度分数，显著超过了 $\pi_{0.5}$ 所达到的 12.7 和 27.6。这些结果证明了我们的 StarVLA- α 在真实世界环境中的有效性。

6 相关工作

视觉-语言-动作（视觉语言动作（VLA））模型。大型视觉语言模型（VLMs）Beyer 等人 (2024)；Liu 等人 (2023)；Wang 等人 (2024b) 的快速发展推动了向端到端视觉-

语言-动作 (VLA) 策略 Brohan 等人 (2022, 2023)。在此基础上, 近期工作迅速扩展了 VLA 范式, 探索了多样的架构设计, 包括解耦的视觉编码器-大语言模型流水线 Liu 等人 (2023); Kim 等人 (2024)、原生多模态模型 Bai 等人 (2025) 以及专门的动作解码机制 Intelligence 等人 (2025b); Bjorck 等人 (2025)。同时, 各工作的训练策略差异显著, 涵盖机器人数据集 Zheng 等人 (2025b,a)、人类视频演示 Ye 等人 (2024); Li 等人 (2024b) 以及网络数据协同训练 Intelligence 等人 (2025b)。随着架构变体 Song 等人 (2025); Li 等人 (2024c); Qu 等人 (2025) 和训练方案 Kim 等人 (2025); Wang 等人 (2025); Zheng 等人 (2025b) 的不断增多, 这些设计选择在 VLA 系统间引入了显著的异质性, 使得难以将性能提升归因于特定的算法创新。

机器人数据工程与动作参数化。用于机器人学习的数据集 Collaboration 等人 (2023); Khazatsky 等人 (2024) 需要大量预处理, 以协调控制频率、相机视角和动作格式的差异 Wu 等人 (2024)。多样的动作参数化策略, 从离散化标记预测 Brohan 等人 (2022, 2023); Kim 等人 (2024) 和连续自回归控制 Kim 等人 (2025) 到动作分块 Zhao 等人 (2023) 以及基于扩散的策略 Intelligence 等人 (2025b); Chi 等人 (2024), 已在不同模型中得到广泛探索。此外, 各种数据处理策略已被证明会影响下游性能 Wang 等人 (2025), 包括归一化方案 Kim 等人 (2024)、本体感受状态条件化 Reuss 等人 (2025) 以及跨具身填充机制 Octo Model Team 等人 (2024); Liu 等人 (2024c)。对异构数据流水线的依赖将算法设计与工程选择紧密耦合, 掩盖了性能提升的真正来源。

7 结论

我们提出了 **StarVLA- α** , 一个简单的视觉-语言-动作 (VLA) 基线, 它结合了强大的视觉-语言模型 (VLM) 主干与轻量级多层感知机 (MLP) 动作头以及最少的数据处理, 在多个基准测试和真实世界机器人任务中取得了强劲的性能。通过 **StarVLA- α** 进行的对照实验表明, 许多复杂技术, 例如复杂的动作头设计、繁重的数据工程或任务特定的预训练, 对于通用机器人开发并非严格必要。这种简化的设计降低了架构复杂度, 减少了数据工程, 并为未来的 VLA 研究提供了一个可复现且可泛化的框架。

参考文献

- AgiBot (2025). Agibot official website. <https://www.agibot.com/>.
- Bai, S., Cai, Y., Chen, R., Chen, K., Chen, X., Cheng, Z., Deng, L., Ding, W., Gao, C., Ge, C., et al. (2025). Qwen3-vl technical report. *arXiv preprint arXiv:2511.21631*.
- Belkhale, S., Ding, T., Xiao, T., Sermanet, P., Vuong, Q., Tompson, J., Chebotar, Y., Dwibedi, D., and Sadigh, D. (2024). Rt-h: Action hierarchies using language. *arXiv preprint arXiv:2403.01823*.
- Beyer, L., Steiner, A., Pinto, A. S., Kolesnikov, A., Wang, X., Salz, D., Neumann, M., Alabdulmohsin, I., Tschannen, M., Bugliarello, E., et al. (2024). Paligemma: A versatile 3b vlm for transfer. *arXiv preprint arXiv:2407.07726*.
- Bjorck, J., Castañeda, F., Cherniadev, N., Da, X., Ding, R., Fan, L., Fang, Y., Fox, D., Hu, F., Huang, S., et al. (2025). Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*.
- Black, K., Brown, N., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., Groom, L., Hausman, K., Ichter, B., et al. (2024a). π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*.
- Black, K., Brown, N., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., Groom, L., Hausman, K., Ichter, B., et al. (2024b). π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*.
- Brohan, A., Brown, N., Carbajal, J., Chebotar, Y., Chen, X., Choromanski, K., Ding, T., Driess, D., Dubey, A., Finn, C., et al. (2023). Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*.
- Brohan, A., Brown, N., Carbajal, J., Chebotar, Y., Dabis, J., Finn, C., Gopalakrishnan, K., Hausman, K., Herzog, A., Hsu, J., et al. (2022). Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*.
- Bu, Q., Yang, Y., Cai, J., Gao, S., Ren, G., Yao, M., Luo, P., and Li, H. (2025). Univla: Learning to act anywhere with task-centric latent actions. *arXiv preprint arXiv:2505.06111*.

- Cai, J., Cai, Z., Cao, J., Chen, Y., He, Z., Jiang, L., Li, H., Li, H., Li, Y., Liu, Y., et al. (2026). Internvla-a1: Unifying understanding, generation and action for robotic manipulation. *arXiv preprint arXiv:2601.02456*.
- Cen, J., Yu, C., Yuan, H., Jiang, Y., Huang, S., Guo, J., Li, X., Song, Y., Luo, H., Wang, F., et al. (2025). Worldvla: Towards autoregressive action world model. *arXiv preprint arXiv:2506.21539*.
- Chen, D., Zhang, J., Mu, T., Tan, Q., Li, Y., Mao, J., Liu, X., Li, K., Qiao, Y., Xiao, F., Ling, Z., and Su, H. (2025a). Robotwin 2.0: Towards general robot policies with active data generation. *arXiv preprint arXiv:2504.13059*.
- Chen, X., Chen, Y., Fu, Y., Gao, N., Jia, J., Jin, W., Li, H., Mu, Y., Pang, J., Qiao, Y., et al. (2025b). Internvla-m1: A spatially guided vision-language-action framework for generalist robot policy. *arXiv preprint arXiv:2510.13778*.
- Chi, C., Xu, Z., Feng, S., Cousineau, E., Du, Y., Burchfiel, B., Tedrake, R., and Song, S. (2024). Diffusion policy: Visuomotor policy learning via action diffusion.
- Collaboration, O. X.-E., O’Neill, A., Rehman, A., Gupta, A., Maddukuri, A., Gupta, A., Padalkar, A., Lee, A., Pooley, A., Gupta, A., Mandlekar, A., Jain, A., Tung, A., Bewley, A., Herzog, A., Irpan, A., Khazatsky, A., Rai, A., Gupta, A., Wang, A., Kolobov, A., Singh, A., Garg, A., Kembhavi, A., Xie, A., Brohan, A., Raffin, A., Sharma, A., Yavary, A., Jain, A., Balakrishna, A., Wahid, A., Burgess-Limerick, B., Kim, B., Schölkopf, B., Wulfe, B., Ichter, B., Lu, C., Xu, C., Le, C., Finn, C., Wang, C., Xu, C., Chi, C., Huang, C., Chan, C., Agia, C., Pan, C., Fu, C., Devin, C., Xu, D., Morton, D., Driess, D., Chen, D., Pathak, D., Shah, D., Büchler, D., Jayaraman, D., Kalashnikov, D., Sadigh, D., Johns, E., Foster, E., Liu, F., Ceola, F., Xia, F., Zhao, F., Frujeri, F. V., Stulp, F., Zhou, G., Sukhatme, G. S., Salhotra, G., Yan, G., Feng, G., Schiavi, G., Berseth, G., Kahn, G., Yang, G., Wang, G., Su, H., Fang, H.-S., Shi, H., Bao, H., Amor, H. B., Christensen, H. I., Furuta, H., Bharadhwaj, H., Walke, H., Fang, H., Ha, H., Mordatch, I., Radosavovic, I., Leal, I., Liang, J., Abou-Chakra, J., Kim, J., Drake, J., Peters, J., Schneider, J., Hsu, J., Vakil, J., Bohg, J., Bingham, J., Wu, J., Gao, J., Hu, J., Wu, J., Wu, J., Sun, J., Luo, J., Gu, J., Tan, J., Oh, J., Wu, J., Lu, J., Yang, J., Malik, J., Silvério, J., Hejna, J., Booher, J., Tompson, J., Yang, J., Salvador, J., Lim, J. J., Han, J., Wang, K., Rao, K., Pertsch, K., Hausman, K., Go, K., Gopalakrishnan, K., Goldberg, K., Byrne, K., Oslund, K., Kawaharazuka, K., Black, K., Lin, K., Zhang, K., Ehsani, K., Lekkala, K., Ellis, K., Rana, K., Srinivasan, K., Fang, K., Singh, K. P., Zeng, K.-H., Hatch, K., Hsu, K., Itti, L., Chen, L. Y., Pinto, L., Fei-Fei, L., Tan, L., Fan, L. J., Ott, L., Lee, L., Weihs, L., Chen, M., Lepert, M., Memmel, M., Tomizuka, M., Itkina, M., Castro, M. G., Spero, M., Du, M., Ahn, M., Yip, M. C., Zhang, M., Ding, M., Heo, M., Srirama, M. K., Sharma, M., Kim, M. J., Kanazawa, N., Hansen, N., Heess, N., Joshi, N. J., Suenderhauf, N., Liu, N., Palo, N. D., Shafiuallah, N. M. M., Mees, O., Kroemer, O., Bastani, O., Sanketi, P. R., Miller, P. T., Yin, P., Wohlhart, P., Xu, P., Fagan, P. D., Mitrano, P., Sermanet, P., Abbeel, P., Sundaresan, P., Chen, Q., Vuong, Q., Rafailov, R., Tian, R., Doshi, R., Mart’ in-Mart’ in, R., Bajjal, R., Scalise, R., Hendrix, R., Lin, R., Qian, R., Zhang, R., Mendonca, R., Shah, R., Hoque, R., Julian, R., Bustamante, S., Kirmani, S., Levine, S., Lin, S., Moore, S., Bahl, S., Dass, S., Sonawani, S., Tulsiani, S., Song, S., Xu, S., Haldar, S., Karamcheti, S., Adebola, S., Guist, S., Nasiriany, S., Schaal, S., Welker, S., Tian, S., Ramamoorthy, S., Dasari, S., Belkhale, S., Park, S., Nair, S., Mirchandani, S., Osa, T., Gupta, T., Harada, T., Matsushima, T., Xiao, T., Kollar, T., Yu, T., Ding, T., Davchev, T., Zhao, T. Z., Armstrong, T., Darrell, T., Chung, T., Jain, V., Kumar, V., Vanhoucke, V., Zhan, W., Zhou, W., Burgard, W., Chen, X., Chen, X., Wang, X., Zhu, X., Geng, X., Liu, X., Liangwei, X., Li, X., Pang, Y., Lu, Y., Ma, Y. J., Kim, Y., Chebotar, Y., Zhou, Y., Zhu, Y., Wu, Y., Xu, Y., Wang, Y., Bisk, Y., Dou, Y., Cho, Y., Lee, Y., Cui, Y., Cao, Y., Wu, Y.-H., Tang, Y., Zhu, Y., Zhang, Y., Jiang, Y., Li, Y., Li, Y., Iwasawa, Y., Matsuo, Y., Ma, Z., Xu, Z., Cui, Z. J., Zhang, Z., Fu, Z., and Lin, Z. (2023). Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>.
- Community, S. (2026). Starvla: A lego-like codebase for vision-language-action model developing.
- contributors, I.-A. (2025). Interndata-a1. <https://github.com/InternRobotics/InternManip>.
- Dai, W., Li, J., Li, D., Tiong, A. M. H., Zhao, J., Wang, W., Li, B., Fung, P., and Hoi, S. (2023). Instructblip: Towards general-purpose vision-language models with instruction tuning. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 49250–49267.
- Fei, S., Wang, S., Shi, J., Dai, Z., Cai, J., Qian, P., Ji, L., He, X., Zhang, S., Fei, Z., Fu, J., Gong, J., and Qiu, X. (2025). Libero-plus: In-depth robustness analysis of vision-language-action models.
- Feng, Y., Zheng, J., Wang, Z., Liu, D., Li, J., Pang, J., Wang, T., and Zhan, X. (2026). Demystifying action space design for robotic manipulation policies. *arXiv preprint arXiv:2602.23408*.
- Fourier Intelligence (2025). Fourier gr-1. <https://www.fftai.com/products-gr1>.
- Franka Emika (2025). Franka research 3. <https://franka.de/franka-research-3>.
- Galaxea (2025). Galaxea official website. <https://galaxea-ai.com/cn/about>.
- Galbot (2025). Galbot official website. <https://www.galbot.com/>.

- Gao, N., Chen, Y., Yang, S., Chen, X., Tian, Y., Li, H., Huang, H., Wang, H., Wang, T., and Pang, J. (2025). Genmanip: Llm-driven simulation for generalizable instruction-following manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- Generalist AI (2025). Gen-0: Embodied foundation models that scale with physical interaction. <https://generalistai.com/blog/nov-04-2025-GEN-0>. Generalist AI Blog.
- Gu, J., Xiang, F., Li, X., Ling, Z., Liu, X., Mu, T., Tang, Y., Tao, S., Wei, X., Yao, Y., Yuan, X., Xie, P., Huang, Z., Chen, R., and Su, H. (2023). Maniskill2: A unified benchmark for generalizable manipulation skills. In *International Conference on Learning Representations*.
- Hung, C.-Y., Sun, Q., Hong, P., Zadeh, A., Li, C., Tan, U.-X., Majumder, N., and Poria, S. (2025). Nora: A small open-sourced generalist vision language action model for embodied tasks.
- Intelligence, P., Black, K., Brown, N., Darpinian, J., Dhabalia, K., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., et al. (2025a). Pi0.5: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*.
- Intelligence, P., Black, K., Brown, N., Darpinian, J., Dhabalia, K., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., et al. (2025b). *pi0.5*: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*.
- Khazatsky, A., Pertsch, K., Nair, S., Balakrishna, A., Dasari, S., Karamcheti, S., Nasiriany, S., Srirama, M. K., Chen, L. Y., Ellis, K., et al. (2024). Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*.
- Kim, M. J., Finn, C., and Liang, P. (2025). Fine-tuning vision-language-action models: Optimizing speed and success. *arXiv preprint arXiv:2502.19645*.
- Kim, M. J., Pertsch, K., Karamcheti, S., Xiao, T., Balakrishna, A., Nair, S., Rafailov, R., Foster, E., Lam, G., Sanketi, P., et al. (2024). Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*.
- Li, B., Zhang, Y., Guo, D., Zhang, R., Li, F., Zhang, H., Zhang, K., Zhang, P., Li, Y., Liu, Z., et al. (2024a). Llava-onevision: Easy visual task transfer. *arXiv preprint arXiv:2408.03326*.
- Li, C., Zhang, R., Wong, J., Gokmen, C., Srivastava, S., Martín-Martín, R., Wang, C., Levine, G., Lingelbach, M., Sun, J., et al. (2023a). Behavior-1k: A benchmark for embodied ai with 1,000 everyday activities and realistic simulation. In *Conference on Robot Learning*, pages 80–93. PMLR.
- Li, H., Yang, S., Chen, Y., Tian, Y., Yang, X., Chen, X., Wang, H., Wang, T., Zhao, F., Lin, D., et al. (2025). Cronusvla: Transferring latent motion across time for multi-frame prediction in manipulation. *arXiv preprint arXiv:2506.19816*.
- Li, J., Zheng, J., Zheng, Y., Mao, L., Hu, X., Cheng, S., Niu, H., Liu, J., Liu, Y., Liu, J., et al. (2024b). Decisionnnc: embodied multimodal representations via implicit preference learning. In *Proceedings of the 41st International Conference on Machine Learning*, pages 29461–29488.
- Li, Q., Liang, Y., Wang, Z., Luo, L., Chen, X., Liao, M., Wei, F., Deng, Y., Xu, S., Zhang, Y., et al. (2024c). Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*.
- Li, X., Hsu, K., Gu, J., Pertsch, K., Mees, O., Walke, H. R., Fu, C., Lunawat, I., Sieh, I., Kirmani, S., et al. (2024d). Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941*.
- Li, X., Liu, M., Zhang, H., Yu, C., Xu, J., Wu, H., Cheang, C., Jing, Y., Zhang, W., Liu, H., Li, H., and Kong, T. (2023b). Vision-language foundation models as effective robot imitators. *arXiv preprint arXiv:2311.01378*.
- Liu, B., Zhu, Y., Gao, C., Feng, Y., Liu, Q., Zhu, Y., and Stone, P. (2024a). Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36.
- Liu, H., Li, C., Li, Y., Li, B., Zhang, Y., Shen, S., and Lee, Y. J. (2024b). Llava-next: Improved reasoning, ocr, and world knowledge.
- Liu, H., Li, C., Wu, Q., and Lee, Y. J. (2023). Visual instruction tuning. *Advances in neural information processing systems*, 36:34892–34916.
- Liu, S., Wu, L., Li, B., Tan, H., Chen, H., Wang, Z., Xu, K., Su, H., and Zhu, J. (2024c). Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*.
- Mees, O., Hermann, L., Rosete-Beas, E., and Burgard, W. (2022). Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters*, 7(3):7327–7334.

- Minderer, M., Gritsenko, A., Stone, A., Neumann, M., Weissenborn, D., Dosovitskiy, A., Mahendran, A., Arnab, A., Dehghani, M., Shen, Z., et al. (2022). Simple open-vocabulary object detection. In *European Conference on Computer Vision*, pages 728–755. Springer.
- Mu, T., Mao, J., Tan, Q., Chen, D., Li, Y., Li, K., Huang, Z., Xie, P., Liu, X., Liu, X., Wang, H., Liu, X., Ling, Z., Tao, S., Jiang, F., Xu, H., and Su, H. (2025). Robotwin 1.0: Sim-to-real robot benchmarks are solvable by pre-trained large models as generalist policies. In *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*, pages 32851–32863.
- Nasiriany, S., Maddukuri, A., Zhang, L., Parikh, A., Lo, A., Joshi, A., Mandekar, A., and Zhu, Y. (2024). Robocasa: Large-scale simulation of everyday tasks for generalist robots. *arXiv preprint arXiv:2406.02523*.
- Octo Model Team, Ghosh, D., Walke, H., Pertsch, K., Black, K., Mees, O., Dasari, S., Hejna, J., Xu, C., Luo, J., Kreiman, T., Tan, Y., Sanketi, P., Vuong, Q., Xiao, T., Sadigh, D., Finn, C., and Levine, S. (2024). Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, Delft, Netherlands.
- Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., et al. (2023). Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*.
- Pertsch, K., Stachowicz, K., Ichter, B., Driess, D., Nair, S., Vuong, Q., Mees, O., Finn, C., and Levine, S. (2025). Fast: Efficient action tokenization for vision-language-action models. *arXiv preprint arXiv:2501.09747*.
- Pumacay, W., Singh, I., Duan, J., Krishna, R., Thomason, J., and Fox, D. (2024). The colosseum: A benchmark for evaluating generalization for robotic manipulation. *arXiv preprint arXiv:2402.08191*.
- Qu, D., Song, H., Chen, Q., Yao, Y., Ye, X., Ding, Y., Wang, Z., Gu, J., Zhao, B., Wang, D., et al. (2025). Spatialvla: Exploring spatial representations for visual-language-action model. *arXiv preprint arXiv:2501.15830*.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., et al. (2021). Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PMLR.
- Reuss, M., Zhou, H., Rühle, M., Yağmurlu, Ö. E., Otto, F., and Lioutikov, R. (2025). FLOWER: Democratizing generalist robot policies with efficient vision-language-action flow policies. In *7th Robot Learning Workshop: Towards Robots with Human-Level Abilities*.
- Song, W., Zhou, Z., Zhao, H., Chen, J., Ding, P., Yan, H., Huang, Y., Tang, F., Wang, D., and Li, H. (2025). Reconvla: Reconstructive vision-language-action model as effective robot perceiver. *arXiv preprint arXiv:2508.10333*.
- Tan, S., Dou, K., Zhao, Y., and Krähenbühl, P. (2025). Interactive post-training for vision-language-action models.
- Team, X.-S. R. (2025). WALL-OSS: Igniting vlms toward the embodied space. *arXiv preprint arXiv:2509.06087*. Code: <https://github.com/X-Square-Robot/wall-x>.
- Unitree Robotics (2025). Unitree h1 humanoid robot. <https://www.unitree.com/h1/>.
- Universal Robots (2025). Universal robots cb3 series (ur5). <https://www.universal-robots.com/cb3/>.
- Wang, L., Chen, X., Zhao, J., and He, K. (2024a). Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers. *Advances in Neural Information Processing Systems*, 37:124420–124450.
- Wang, P., Bai, S., Tan, S., Wang, S., Fan, Z., Bai, J., Chen, K., Liu, X., Wang, J., Ge, W., et al. (2024b). Qwen2-vl: Enhancing vision-language model’s perception of the world at any resolution. *arXiv preprint arXiv:2409.12191*.
- Wang, Y., Ding, P., Li, L., Cui, C., Ge, Z., Tong, X., Song, W., Zhao, H., Zhao, W., Hou, P., Huang, S., Tang, Y., Wang, W., Zhang, R., Liu, J., and Wang, D. (2025). Vla-adapter: An effective paradigm for tiny-scale vision-language-action model. *arXiv preprint arXiv:2509.09372*.
- Wu, K., Hou, C., Liu, J., Che, Z., Ju, X., Yang, Z., Li, M., Zhao, Y., Xu, Z., Yang, G., Fan, S., Wang, X., Liao, F., Zhao, Z., Li, G., Jin, Z., Wang, L., Mao, J., Liu, N., Ren, P., Zhang, Q., Lyu, Y., Liu, M., He, J., Luo, Y., Gao, Z., Li, C., Gu, C., Fu, Y., Wu, D., Wang, X., Chen, S., Wang, Z., An, P., Qian, S., Zhang, S., and Tang, J. (2024). Robomind: Benchmark on multi-embodiment intelligence normative data for robot manipulation. *arXiv preprint arXiv:2412.13877*.
- Wu, W., Lu, F., Wang, Y., Yang, S., Liu, S., Wang, F., Zhu, Q., Sun, H., Wang, Y., Ma, S., et al. (2026). A pragmatic vla foundation model. *arXiv preprint arXiv:2601.18692*.
- Yakefu, A., Xie, B., Xu, C., Zhang, E., Zhou, E., Jia, F., Yang, H., Fan, H., Zhang, H., Peng, H., et al. (2025). Robochallenge: Large-scale real-robot evaluation of embodied policies. *arXiv preprint arXiv:2510.17950*.

- Yang, J., Tan, R., Wu, Q., Zheng, R., Peng, B., Liang, Y., Gu, Y., Cai, M., Ye, S., Jang, J., et al. (2025a). Magma: A foundation model for multimodal ai agents. *arXiv preprint arXiv:2502.13130*.
- Yang, S., Li, H., Chen, Y., Wang, B., Tian, Y., Wang, T., Wang, H., Zhao, F., Liao, Y., and Pang, J. (2025b). Instructvla: Vision-language-action instruction tuning from understanding to manipulation. *arXiv preprint arXiv:2507.17520*.
- Yang, Y., Zeng, S., Lin, T., Chang, X., Qi, D., Xiao, J., Liu, H., Chen, R., Chen, Y., Huo, D., et al. (2026). Abot-m0: Vla foundation model for robotic manipulation with action manifold learning. *arXiv preprint arXiv:2602.11236*.
- Ye, J., Wang, F., Gao, N., Yu, J., Zhu, Y., Wang, B., Zhang, J., Jin, W., Fu, Y., Zheng, F., Chen, Y., and Pang, J. (2026). St4vla: Spatially guided training for vision-language-action models. In *International Conference on Learning Representations (ICLR)*.
- Ye, S., Jang, J., Jeon, B., Joo, S., Yang, J., Peng, B., Mandlekar, A., Tan, R., Chao, Y.-W., Lin, B. Y., et al. (2024). Latent action pretraining from videos. *arXiv preprint arXiv:2410.11758*.
- Zhai, X., Mustafa, B., Kolesnikov, A., and Beyer, L. (2023). Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11975–11986.
- Zhao, T. Z., Kumar, V., Levine, S., and Finn, C. (2023). Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*.
- Zheng, J., Li, J., Liu, D., Zheng, Y., Wang, Z., Ou, Z., Liu, Y., Liu, J., Zhang, Y.-Q., and Zhan, X. (2025a). Universal actions for enhanced embodied foundation models.
- Zheng, J., Li, J., Wang, Z., Liu, D., Kang, X., Feng, Y., Zheng, Y., Zou, J., Chen, Y., Zeng, J., et al. (2025b). X-vla: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. *arXiv preprint arXiv:2510.10274*.

Supplementary Material for “StarVLA- α : Reducing Complexity in Vision-Language-Action Systems”

The supplementary material is organized as follows.

1. **Related works.** Related works on VLA models, robotic data engineering, and action parameterization are described in Sec. A.
2. **Benchmark details.** Detailed descriptions of all benchmarks, including LIBERO, SimplerEnv, RoboTwin 2.0, RoboCasa-GR1, and RoboChallenge, are described in Sec. B.
3. **Training details.** Default training setup, optimization hyperparameters, compute resources, and architecture details are described in Sec. C.
4. **More ablation studies.** Additional ablations on model initialization, model size, and batch size in the all-in-one setting are described in Sec. D.
5. **Large-scale real-world evaluations on RoboChallenge.** Large-scale real-world evaluation results on the RoboChallenge benchmark Yakefu et al. (2025) across multiple robot embodiments as a Generalist are described in Sec. E.
6. **Real-world OOD experiments.** Experimental setup and results for real-world out-of-distribution evaluation are described in Sec. F.
7. **Detailed benchmarks results.** Full benchmark results and supplementary quantitative comparisons are described in Sec. G.
8. **Qualitative results across simulation benchmarks.** Visualizations of simulation benchmarks, RoboChallenge, and real-world deployment settings are described in Sec. H.
9. **Robustness evaluation on LIBERO-Plus.** Additional robustness evaluation results on the LIBERO-Plus benchmark are described in Sec. I.

A 相关工作

视觉-语言-动作（视觉语言动作（VLA））模型。大型视觉语言模型（Large Vision-Language Models, VLMs）的快速发展 Beyer et al. (2024); Liu et al. (2023); Wang et al. (2024b) 从根本上重塑了机器人模型的发展，推动了向端到端视觉-语言-动作（Vision-Language-Action, VLA）框架的范式转变。通过直接将多模态观测映射为可部署的控制信号，开创性工作如 RT 系列 Brohan et al. (2022, 2023) 证明了利用 VLM 推理实现通用具身智能体的可行性。在此基础上，社区见证了 VLA 方法的大量涌现。Octo Octo Model Team et al. (2024) 和 OpenVLA Kim et al. (2024) 等倡议探索了不同的骨干网络及特定的动作注入方法，而近期进展如 π -系列 Black et al. (2024a); Intelligence et al. (2025b) 和 GR00T-系列 Bjorck et al. (2025) 引入了专门的动作解码机制和更大规模的机器人预训练。然而，该领域的快速迭代带来了大量异构的结构设计 Song et al. (2025); Li et al. (2024c); Qu et al. (2025) 和迥异的训练方案 Kim et al. (2025); Wang et al. (2025); Zheng et al. (2025b)。例如，VLM 骨干网络的选择在不同模型间差异巨大，从解耦的视觉编码器加 LLM 流水线 Liu et al. (2023); Kim et al. (2024) 到原生多模态架构 Bai et al. (2025)，而预训练方案在跨具身 Zheng et al. (2025b,a)、人类视频 Ye et al. (2024); Li et al. (2024b) 甚至视觉-语言数据联合训练 Intelligence et al. (2025b) 之间也存在显著分歧。此外，许多方法严重依赖特定评估方案的特殊工程实践 Kim et al. (2025); Wang et al. (2025)，导致方法论格局高度碎片化且评估不可靠。本文构建了一个清晰简洁的框架来抽象掉这种结构复杂性，建立严格受控的基线以隔离 VLA 性能的真正驱动因素。

机器人数据工程与动作参数化。机器人学习的发展格局已被数据工程技术的进步显著推动。为有效利用异构数据集 Collaboration et al. (2023); Khazatsky et al. (2024) 并提升学习效率，社区引入了多种专门技术。核心挑战在于将不兼容的控制频率、相机视角和动作表示转换为与基于视觉语言模型（VLM）的策略兼容的格式 Wu et al. (2024)，这通常需要大量针对特定数据集的预处理。同时，动作参数化的设计仍是一个活跃争论的话题 Feng et al. (2026)。实现方式涵盖广泛：从通过均匀分箱将连续控制信号离散化为语言标记 Brohan

et al. (2022, 2023); Kim et al. (2024), 到连续自回归预测 Kim et al. (2025)、动作分块 Zhao et al. (2023) 以及高频扩散过程 Intelligence et al. (2025b); Chi et al. (2024)。除动作建模外, 辅助数据处理选择——从数据集特定的归一化方案 Kim et al. (2024) 和本体感受状态的条件注入 Reuss et al. (2025), 到用于跨具身对齐的复杂填充机制 Octo Model Team et al. (2024); Liu et al. (2024c)——已在多项研究中相继被证明对下游性能有显著影响 Wang et al. (2025)。这种对异构数据流水线和动作建模的深度依赖, 使算法创新与经验调优深度纠缠, 掩盖了性能提升究竟源于核心架构进步还是仅仅优化了配方。本文通过建立一个干净、统一的基线, 在严格受控条件下隔离并严格评估这些个体工程选择的真实影响, 从而系统性地解开这些混杂因素。

B 基准测试详情

我们在多种基准上评估 StarVLA- α , 这些基准覆盖机器人操作 (robot manipulation) 的互补方面, 包括组合多任务学习 Liu et al. (2024a); Fei et al. (2025)、真实世界策略的仿真评估 Li et al. (2024d)、双臂协调 Chen et al. (2025a)、人形桌面操作 Nasiriany et al. (2024) 以及标准化真实机器人测试 Yakefu et al. (2025)。这些基准共同涵盖不同的机器人形态、任务结构和评估协议, 为研究视觉-语言-动作 (VLA) 系统中的专业化与泛化提供了广泛的测试平台。

- **LIBERO: LIBERO** 是一个广泛使用的基准, 用于语言条件下的机器人操作和终身机器学习 Liu et al. (2024a)。该基准包含 130 个操作任务, 分为四个任务套件: 空间 (Spatial)、物体 (Object)、目标 (Goal) 和长程 (Long)。前三个套件旨在隔离空间关系、物体身份和任务目标在受控偏移下的迁移, 而 **LIBERO-Long** 包含更大规模的操作任务集, 其变化更加纠缠。文献中常见的训练协议使用每个任务 50 条专家演示, 在整个基准上产生约 6.5K 条轨迹。**LIBERO** 提供标准化的评估协议, 已成为研究语言条件下操作场景中的指令遵循、组合泛化和多任务策略学习的常见测试平台。我们还在 **LIBERO-Plus** Fei et al. (2025) 上评估了我们的模型, 这是一个基于 **LIBERO** 构建的面向鲁棒性的基准, 用于在受控分布偏移下系统评估 VLA 策略。

- **SimplerEnv: SimplerEnv** 是一个仿真框架, 旨在仿真中评估真实世界操作策略 Li et al. (2024d)。它不侧重于仿真中的策略学习, 而是为真实世界评估提供标准化且可扩展的代理, 其结果已被证明与物理机器人性能相关。该基准包含与常见真实机器人设置相对应的仿真环境, 特别是 RT 系列中使用的 Google Robot 环境和 WidowX / BridgeData V2 设置。因此, **SimplerEnv** 被广泛用于评估在真实世界机器人数据上训练的策略是否能够泛化到标准化评估场景, 而无需为每个实验进行直接的真实机器人测试。

- **RoboTwin 2.0:** RoboTwin 2.0 是一个面向双臂机器人操作的大规模基准, 专注于多样交互场景下的双臂协调 (Chen et al. (2025a))。我们为每个任务使用 50 条干净数据进行标准干净评估, 并遵循多任务训练协议, 每个任务使用 50 条干净演示以及 500 条随机化演示, 总计每个任务约 550 条轨迹, 全部 50 个任务约 27.5K 条轨迹。随机化轨迹通过结构化领域随机化生成, 通常包括杂乱场景、背景变化、桌面高度扰动、光照变化以及其他环境变化等因素。因此, 该基准为评估细粒度双臂协调以及对环境多样性的鲁棒性提供了一个具有挑战性的测试平台。

- **RoboCasa-GR1: RoboCasa-GR1** 是一个建立在 RoboCasa 仿真框架之上的桌面操作基准, 常用于评估人形风格的操作策略 (Nasiriany et al. (2024); Bjorck et al. (2025))。与标准的单臂桌面基准相比, 它引入了更具挑战性的具身形态以及涉及关节物体和多阶段操作的家庭交互场景。该基准包含 24 个桌面任务, 近期工作中常用的相关数据发布为每个任务提供 1000 条演示, 总计约 24K 条轨迹。因此, **RoboCasa-GR1** 是研究跨具身迁移、长时程桌面操作以及面向人形的视觉运动控制的有用基准。

• **RoboChallenge:** RoboChallenge 是一个大规模真实机器人评估平台，用于在物理世界中基准测试具身控制策略（Yakefu et al. (2025)）。其初始基准套件 **Table-30** 包含 30 个真实世界桌面操作任务，平台报告描述了初始部署包含 10 台托管机器。与仿真基准不同，RoboChallenge 直接在真实传感噪声、执行器不确定性以及物理环境可变性下评估策略。因此，它作为一个重要的测试平台，用于验证强大的仿真性能是否能够迁移到标准化的真实世界机器人部署。

C 训练细节

默认设置。除非另有说明，视觉语言模型（VLM）骨干网络从公开可用的 Qwen3-VL-4B 检查点初始化，而动作头则随机初始化。所有模型均在目标基准数据上直接进行单阶段训练，无需任何动作特定的预训练。

训练范式。本文研究了专家模型（**Specialist**）和通用模型（**Generalist**）两种训练方式。专家模型仅使用单一具身智能体的数据进行训练。相比之下，通用模型则使用来自多个具身智能体和基准套件的合并数据进行联合训练。本文中，所有基准的联合训练均对应通用模型设置。

优化。视觉语言模型骨干网络和动作头采用不同的学习率：骨干网络为 1×10^{-5} ，动作头为 1×10^{-4} ，并使用余弦学习率调度。所有模型最多训练 100k 步，每 GPU 批大小为 16。

计算资源。本文的训练设置随数据集规模扩展，同时保持所有其他超参数与基准无关。具体如表 8 所示：

表 8：各基准套件的计算资源。

Training Data	#GPUs	Training Data	#GPUs
LIBERO	8× A100	SimplerEnv	16× A100
RoboCasa-GR1	16× A100	RoboTwin-Clean	16× A100
RoboTwin-Clean + Rand.	48× A100	RoboChallenge Table 30	32× A100
Real-World OOD	16× A100	All benchmarks jointly	64× A100

架构细节。关于不同动作头（FAST、OFT、PI、GR00T）的实现细节，请读者参阅我们的代码：
https://github.com/starVLA/starVLA/tree/starVLA/starVLA/model/modules/action_model.

D 更多消融研究

除第 4 节的分析外，我们进一步研究了可能影响通用视觉语言动作模型训练的若干实用因素：模型初始化、模型大小和批大小。与第 3 节的主要消融不同，这些实验聚焦于一体化训练设置，旨在更好地理解在统一训练流程下，哪些因素对实现强大的跨基准性能最为关键。

D.1 模型初始化的影响

动机。通用设置中的一个关键问题是，性能提升主要来自统一的训练方案本身，还是关键取决于骨干网络的初始化。由于我们的框架建立在预训练视觉语言模型之上，量化初始化质量的作用非常重要。

实验设置。我们保持一体化训练方案不变，仅改变骨干网络的初始化。具体而言，我们比较随机初始化、Qwen2.5-VL 和 Qwen3-VL，所有情况下使用相同的动作头和训练流程。

结果。表 9 显示，初始化质量在通用策略训练中起着至关重要的作用。随机初始化在所有基准上表现显著较差，表明仅靠统一训练不足以从头学习强大的通用策略。相比之下，从预训练视觉语言模型初始化

表 9：不同视觉语言模型初始化下的性能比较。

VLM Initial	LIBERO	SimplerEnv			RoboTwin 2.0		RoboCasa-GR1
	Avg	WidowX	Google VA	Google VM	clean	random	Avg
Random	77.5	24.8	45.4	52.8	65.6	59.8	28.8
Florence-2	93.2	53.4	63.6	65.7	77.8	79.1	39.2
Qwen2.5-VL	95.5	65.6	70.7	77.1	87.2	85.6	53.6
Qwen3-VL	97.8	70.2	73.8	79.3	88.7	87.8	57.3
Qwen3.5	98.2	71.3	76.8	80.0	88.3	88.4	56.1

一致地提升性能。在预训练骨干网络中，更强的模型通常带来更好的结果。Qwen2.5-VL 已比 Florence-2 有大幅提升，而 Qwen3-VL 在大多数基准上进一步提高了性能。使用更强的 Qwen3.5 骨干网络在 LIBERO 和 SimplerEnv 上取得最佳结果，并在 RoboTwin 2.0 上达到最高平均性能，表明改进的多模态先验可以进一步增强下游机器人控制。

要点。这些结果表明，强大的视觉语言模型初始化是通用视觉语言动作模型训练的关键要素。骨干网络不仅是起点：更好的预训练多模态表示直接转化为更强的跨基准泛化能力。

D.2 模型规模的影响

动机。除了初始化之外，模型容量也可能影响单一策略吸收来自多个基准和具身形态的异构数据的能力。因此，我们研究在通用设置下扩大骨干网络规模是否能提升性能。

实验设置。我们在相同的全合一训练设置下评估了三种 Qwen3-VL 模型规模：2B、4B 和 8B。所有其他设置，包括动作头、优化器和统一动作填充策略，均保持不变。

表 10：通用设置下不同视觉语言动作模型规模的性能。

Method	LIBERO	SimplerEnv			RoboTwin 2.0		RoboCasa-GR1
	Avg	WidowX	Google VA	Google VM	clean*	random*	Avg
2B	97.8	52.1	61.5	65.4	76.8	79.1	50.7
4B	97.8	70.2	73.8	79.3	88.7	87.8	57.3
8B	98.2	71.5	72.9	80.3	88.6	88.8	58.2

结果。如表 10 所示，将模型规模从 2B 增加到 4B 带来了明显且一致的提升，尤其是在更具挑战性的基准上。这表明即使训练方案固定，容量不足也会限制统一多基准学习。然而，从 4B 到 8B 的提升要小得多且不一致，表明一旦骨干网络达到中等规模，就会出现明显的收益递减趋势。

要点。这些结果表明，在通才设定下，模型规模不应过小，但超过中等规模后的扩展并非主导因素。在我们的设置中，4B 已能捕获大部分可获得的增益，并在容量与效率之间提供了有利的权衡。

D.3 批大小的影响

动机。在“一体化”设定下，每个批次可能包含来自不同任务、机器人和环境的样本。因此，批大小直接影响模型在每个优化步骤中观察到的多样性程度，这对于跨基准泛化可能尤为重要。

实验设置。我们将总批大小从 64 变化到 1024，同时保持其余训练设置不变。模型架构和统一动作表示保持不变，因此效果可单独归因于批大小。

表 11：不同批大小下的性能比较。

Batch Size	LIBERO	SimplerEnv			RoboTwin 2.0		RoboCasa-GR1
	Avg	WidowX	Google VA	Google VM	clean	random	Avg
64	95.8	35.4	63.2	76.8	80.4	81.3	40.0
128	97.4	55.4	63.8	77.2	80.8	83.8	44.6
256	97.9	62.3	70.6	78.3	86.4	86.5	48.3
512	98.1	65.8	70.7	79.7	88.8	88.7	57.3
1024	98.8	70.2	71.3	80.1	88.8	89.2	59.2

结果。表 11 显示了较大批大小带来的明确且一致的益处。随着批大小的增加，性能稳步提升，在更具挑战性的基准（如 SimplerEnv、RoboTwin 2.0 和 RoboCasa-GR1）上增益尤为显著。这一趋势表明，在统一设定下，让模型在每个步骤中接触更多多样化的监督对于稳定优化和更强的泛化至关重要。

要点。这些结果表明，批大小是通才 VLA 训练中最重要的优化因素之一。其影响比模型扩展更广泛且更一致，凸显了在一体化训练中多样化梯度信号的重要性。

E RoboChallenge

为进一步评估 StarVLA- α 在真实世界中的性能，本文报告了其在 RoboChallenge Table-30 基准上的结果。RoboChallenge 是一个标准化的真实机器人基准，涵盖多种机器人本体上的广泛家庭操作任务。在本评估中，该基准包含四个代表性平台，即 UR5、Franka、ARX5 和 ALOHA，以及难度各异的一组任务，包括短时程抓取放置、精确物体操作和长时程多步交互。因此，该基准提供了一个强有力的测试平台，不仅用于衡量原始任务成功率，还用于衡量跨不同真实世界操作设置的本体级迁移和鲁棒性。

表 ?? 总结了四个机器人平台上的完整评估结果。每个任务使用两个互补度量进行评估：成功率（SR）和进度分数。成功率衡量完整任务是否成功完成，而进度分数捕捉部分完成情况，从而为长时程或困难任务上的策略行为提供更细粒度的视角，在这些任务中，仅靠二元成功可能掩盖有意义的差异。

总体而言，StarVLA- α 在大多数平台和任务组上，在成功率和进度分数方面均一致优于 $\pi_{0.5}$ 和 π_0 。在需要精确接地、顺序推理或稳定长时程控制的挑战性任务上，增益尤为明显，表明 StarVLA- α 不仅在端到端完成任务方面更强，而且在难以完全完成时也能更可靠地取得稳定进展。这些结果验证了 StarVLA- α 在真实世界操作中的有效性，并表明即使是一个简单的统一框架也能在不同机器人本体和多样化任务分布上良好泛化。

F 真实世界分布外实验

为进一步评估 StarVLA- α 在实际部署中的鲁棒性，本文使用物理机器人进行了一组真实世界分布外（OOD）实验。与第 5 节中标准化真实世界基准结果相比，这些实验旨在明确测试 StarVLA- α 在现实分布偏移下能否泛化，包括新物体、未见颜色、物体位置偏移和未见空间坐标。目标是评估同一个简单的 StarVLA- α 框架在基准特定设置之外的真实世界指令跟随任务中是否仍然可靠。

实验设置。 所有真实世界实验均使用固定于桌面的 Franka Research 3 机械臂。观测由两幅 RGB 图像组成：一幅来自固定的第三人称相机，另一幅来自腕部安装的第一人称相机。两幅图像在输入模型前均被调整为 224×224 。我们考虑三项具有代表性的真实世界操作任务，以探究分布外泛化的不同方面。第一项是垃圾分类任务，机器人需根据语义类别将物体放入正确的箱子；分布外设置包含新物体。第二项是拾取彩色鸡蛋任务，指令如“拾取红色鸡蛋”；该任务包含未见颜色和未见位置的分布外设置。第三项是鸡蛋盒放置任务，机器人根据语言指令（如“第 2 行，第 4 列”）将鸡蛋放入 4×4 蛋盒网格的指定单元格；分布外设置包含未见行列组合。对于具有多个分布外设置的任务，我们报告平均分布外性能。

表 12: StarVLA- α 真实世界分布外实验总结。我们报告三项真实世界任务在域内和分布外设置下的性能。对于具有多个分布外设置的任务，我们报告平均分布外性能。

Metric	Pick colored egg		Egg carton placement		Waste-sorting		Average	
	ID	OOD	ID	OOD	ID	OOD	ID	OOD
Success rate (%)	77.1	75.0	91.3	68.8	87.5	85.0	85.3	76.3

结果。 结果总结于表 12。总体而言，StarVLA- α 在三项真实世界任务中均保持鲁棒，并在多种分布偏移形式下保持强劲性能。值得注意的是，尽管 StarVLA- α 有意保持简单，不依赖复杂的数据工程、重度数据增强或任务特定的训练技巧，其分布外性能在所有任务中仍与独立同分布性能基本相当。平均而言，成功率仅从独立同分布设置下的 85.3% 降至分布外设置下的 76.3%，这表明 StarVLA- α 的鲁棒性主要来自所学策略本身，而非数据集特定的工程手段。

在垃圾分类任务中，新物体的分布外性能与域内结果非常接近（85.0% 对比 87.5%），这表明模型学习的是类别级别的语义关联，而非仅仅记忆物体外观。在拾取彩色鸡蛋任务中，StarVLA- α 同样对未见颜色和未见位置均表现出良好的泛化能力，成功率分别达到 68.0% 和 81.9%。这一结果表明，模型能够在分布偏移下可靠地将语言属性绑定到视觉实例上，同时保持空间鲁棒性。在鸡蛋盒放置任务中，StarVLA- α 取得了较强的域内性能，并且在未见坐标组合上仍然有效，尽管组合式空间泛化相比其他分布外设置更具挑战性。即使在这种更困难的情况下，分布外结果相对于独立同分布性能仍然具有合理的竞争力，进一步证明了该框架在实际真实场景中的稳定性。

讨论。 这些真实世界的结果补充了主文中的基准评估。除了在标准化基准上取得强大性能外，StarVLA- α 还在实际机器人操作任务中展示了稳定的指令遵循能力和非平凡的分布外鲁棒性。更重要的是，这种鲁棒性是通过一个简单且统一的框架获得的，无需复杂的数据策展流程、额外的增强策略或复杂的任务特定工程。从独立同分布到分布外的差距相对较小，这表明 StarVLA- α 学习到了一种可迁移的视觉运动策略，具有真正的泛化能力，而不是过拟合于确切的训练分布。综合来看，这些实验进一步支持了我们的主要结论：一个简单的基于视觉语言模型的策略已经可以在不增加额外架构复杂度的情况下提供强大的真实世界泛化能力。

G 完整基准结果

由于主文篇幅限制，我们在正文中仅报告了基准级别的平均结果。在本附录中，我们提供了若干基准的完整任务级结果，以便进行更详细的比较和复现。具体来说，我们包含了 **SimplerEnv**、**RoboTwin-2.0** 和 **RoboCasa-GR1** 的详细结果。所有结果均遵循各基准的官方评估协议。

G.1 SimplerEnv

表 13 报告了在 WidowX 机器人视觉匹配设置下 SimplerEnv 基准的详细结果。该基准包含四个操作任务，我们报告每个任务的成功率以及平均性能。结果展示了代表性的先前视觉语言动作方法以及我们具有不同动作头和骨干网络的 StarVLA- α 变体。

表 13: WidowX 机器人（视觉匹配）下 SimplerEnv 的详细结果。我们报告了先前方法和 StarVLA- α 变体的每个任务成功率及跨任务平均值。

WidowX Robot	Method	Put Spoon on Towel	Put Carrot on Plate	Stack Green Block on Yellow Block	Put Eggplant in Yellow Basket	Average
Visual Matching	RT-1-X Brohan et al. (2022)	0.0	4.2	0.0	0.0	1.1
	Octo-Base Octo Model Team et al. (2024)	15.8	12.5	0.0	41.7	17.5
	Octo-Small Octo Model Team et al. (2024)	41.7	8.2	0.0	56.7	26.7
	OpenVLA Kim et al. (2024)	4.2	0.0	0.0	12.5	4.2
	CogACT Li et al. (2024c)	71.7	50.8	15.0	67.5	51.3
	SpatialVLA Qu et al. (2025)	16.7	25.0	29.2	100.0	42.7
	π_0 Black et al. (2024a)	29.1	0.0	16.6	62.5	27.1
	π_0 -FAST Pertsch et al. (2025)	29.1	21.9	10.8	66.6	48.3
	GR00T N1.5 Bjorck et al. (2025)	75.3	54.3	57.0	61.3	61.9
	Magma Yang et al. (2025a)	37.5	31.0	12.7	60.5	35.8
	StarVLA-α(Specialist)	90.3	38.5	29.7	100	64.6
	StarVLA-α(Generalist)	79.7	59.8	22.8	98.5	65.2

G.2 RoboTwin-2.0

表 15 展示了 StarVLA- α 在 RoboTwin-2.0 上的完整任务级结果。该基准包含 50 个双臂操作任务，每个任务均在简单和困难两种设置下评估。我们报告每个任务的成功率以及所有任务的整体平均值。

G.3 RoboCasa-GR1

表 16 展示了 RoboCasa-GR1 桌面基准的详细评估结果。该基准包含 24 个任务，每个模型在所有任务上联合训练。我们报告每个任务的成功率以及整体平均性能。

表 14: SimplerEnv 谷歌机器人基准的详细结果。带下划线的分数表示排除我们方法后的最佳结果。数字为官方报告，除非标有 *，该标记表示我们的重新实现。

Google Robot	Models	Pick Coke Can	Move Near	Open/Close Drawer	Open Top Drawer and Place Apple	Avg
Visual Matching	RT-1 Brohan et al. (2022)	85.7	44.2	73.0	6.5	52.4
	RT-1-X Collaboration et al. (2023)	56.7	31.7	59.7	21.3	42.4
	RT-2-X Brohan et al. (2023)	78.7	77.9	25.0	3.7	46.3
	OpenVLA Kim et al. (2024)	18.0	56.3	63.0	0.0	34.3
	CogACT Li et al. (2024c)	91.3	85.0	71.8	50.9	74.8
	SpatialVLA Qu et al. (2025)	86.0	77.9	57.4	-	75.1
	π_0 Black et al. (2024a)	72.7	65.3	38.3	-	58.8
	π_0 -FAST Pertsch et al. (2025)	75.3	67.5	42.9	-	61.9
	GR00T N1.5* Bjorck et al. (2025)	51.7	54.0	27.8	7.4	35.2
	Magma Yang et al. (2025a)	83.7	65.4	56.0	6.4	52.9
	StarVLA-α (Specialist)	95.3	75.0	68.8	66.1	76.0
	StarVLA-α (Generalist)	90.1	82.6	56.3	68.7	74.3
Variant Aggregation	RT-1 Brohan et al. (2022)	89.8	50.0	32.3	2.6	43.7
	RT-1-X Collaboration et al. (2023)	49.0	32.3	29.4	10.1	30.2
	RT-2-X Brohan et al. (2023)	82.3	79.2	35.3	20.6	54.4
	OpenVLA Kim et al. (2024)	60.8	67.7	28.8	0.0	39.3
	CogACT Li et al. (2024c)	89.6	80.8	28.3	46.6	61.3
	SpatialVLA Qu et al. (2025)	88.0	82.5	41.8	-	70.7
	π_0 Black et al. (2024a)	75.2	63.7	25.6	-	54.8
	π_0 -FAST Pertsch et al. (2025)	77.6	68.2	31.3	-	59.0
	GR00T N1.5 Bjorck et al. (2025)	69.3	68.7	35.8	4.0	44.5
	Magma Yang et al. (2025a)	68.8	65.7	53.4	18.5	51.6
	StarVLA-α (Specialist)	91.3	75.1	55.0	59.4	70.2
	StarVLA-α (Generalist)	88.8	78.8	56.1	55.5	69.8

表 15: StarVLA- α 在 RoboTwin 2.0 专家设置下的详细结果。我们报告了简单和困难设置下每个任务的成功率。

RoboTwin-2.0								
Task	Easy	Hard	Task	Easy	Hard	Task	Easy	Hard
Adjust Bottle	100	99	Open Microwave	28	39	Place Object Stand	99	98
Beat Block Hammer	93	92	Pick Diverse Bottles	87	86	Place Phone Stand	86	95
Blocks Ranking RGB	99	98	Pick Dual Bottles	91	93	Place Shoe	96	100
Blocks Ranking Size	79	80	Place A2B Left	90	95	Press Stapler	99	96
Click Alarmclock	58	51	Place A2B Right	88	95	Put Bottles Dustbin	90	85
Click Bell	23	27	Place Bread Basket	91	78	Put Object Cabinet	89	91
Dump Bin Bigbin	91	94	Place Bread Skillet	89	80	Rotate QRcode	88	90
Grab Roller	100	100	Place Burger Fries	100	100	Scan Object	94	91
Handover Block	97	93	Place Can Basket	75	75	Shake Horizontally	100	100
Handover Mic	98	96	Place Cans Plasticbox	100	99	Shake Bottle	100	100
Hanging Mug	34	29	Place Container Plate	99	99	Stack Blocks Three	94	86
Lift Pot	100	100	Place Dual Shoes	91	89	Stack Blocks Two	100	100
Move Can Pot	91	90	Place Empty Cup	100	100	Stack Bowls Three	95	91
Move Pillbottle Pad	98	100	Place Fan	94	95	Stack Bowls Two	99	100
Move Playingcard Away	100	98	Place Mouse Pad	87	94	Stamp Seal	86	90
Move Stapler Pad	74	90	Place Object Basket	93	94	Turn Switch	65	62
Open Laptop	98	100	Place Object Scale	93	93	Average	88.2	88.3

表 16: RoboCasa-GR1 桌面基准上的评估结果。单一模型在全部 24 个任务上联合训练，结果基于每个任务 200 次运行报告。

Task	GR00T-N1.6	StarVLA- α (Specialist)	StarVLA- α (Generalist)
PnPbottleToCabinetClose	51.5	35.0	52.0
PnPCanToDrawerClose	13.0	81.0	86.0
PnPCupToDrawerClose	8.5	50.0	38.0
PnPMilkToMicrowaveClose	14.0	49.0	56.0
PnPPotatoToMicrowaveClose	41.5	37.0	46.0
PnPWineToCabinetClose	16.5	42.0	46.0
PnPNovelFromCuttingboardToBasket	58.0	55.0	56.0
PnPNovelFromCuttingboardToCardboardbox	46.5	45.0	48.0
PnPNovelFromCuttingboardToPan	68.5	75.0	80.0
PnPNovelFromCuttingboardToPot	65.0	59.0	60.0
PnPNovelFromCuttingboardToTieredbasket	46.5	43.0	42.0
PnPNovelFromPlacematToBasket	58.5	38.0	60.0
PnPNovelFromPlacematToBowl	57.5	63.0	74.0
PnPNovelFromPlacematToPlate	63.0	57.0	74.0
PnPNovelFromPlacematToTieredshelf	28.5	29.0	28.0
PnPNovelFromPlateToBowl	57.0	65.0	72.0
PnPNovelFromPlateToCardboardbox	43.5	55.0	44.0
PnPNovelFromPlateToPan	51.0	71.0	70.0
PnPNovelFromPlateToPlate	78.7	73.0	74.0
PnPNovelFromTrayToCardboardbox	51.5	49.0	48.0
PnPNovelFromTrayToPlate	71.0	61.0	72.0
PnPNovelFromTrayToPot	64.5	67.0	67.0
PnPNovelFromTrayToTieredbasket	57.0	59.0	58.0
PnPNovelFromTrayToTieredshelf	31.5	33.0	24.0
Average	47.6	53.8	57.3

H 仿真基准上的结果可视化

为更清晰地概述本文所用的评估环境，我们可视化了论文中所有基准的代表性场景。这些可视化有助于说明不同基准中机器人形态、任务布局和操作场景的多样性。由于我们的实验跨越多个数据集，涉及不同的机器人平台和环境，这些图提供了对策略在评估期间所遇到的视觉观测的直观理解。

图 6 展示了我们实验中使用的仿真基准的示例帧。从上到下，该图依次展示了使用 WidowX 机器人的 SimplerEnv 场景、RoboCasa-GR1、使用 Google Robot 形态的 SimplerEnv 以及 Hard 设置下的 RoboTwin 2.0。这些环境涵盖了广泛的操作设置，包括单臂桌面操作、类人形交互场景和双臂协调任务。尽管形态和环境结构存在差异，所有基准都遵循语言条件操作协议，并共享类似的基于 RGB 的观测。




图 6：仿真基准上的结果可视化。从上到下：SimplerEnv WidowX、RoboCasa-GR1、SimplerEnv Google Robot 和 RoboTwin 2.0（Hard）。

图 7 展示了我们评估中使用的 RoboChallenge 真实世界基准的代表性场景。与仿真环境相比，RoboChallenge 引入了额外的挑战，如真实世界传感噪声、光照变化和执行不确定性。这些可视化为用于真实世界评估的物理机器人设置和任务环境提供了一个示例。

图 8 进一步展示了我们在弗兰卡研究 3 号机器人上进行真实世界部署实验的代表性场景。与强调在托管机器人平台上进行标准化大规模评估的机器人挑战赛不同，这些实验旨在研究我们自身部署设置下的真实世界指令遵循和分布外泛化。该图展示了物理桌面环境、相机视角以及我们评估中使用的代表性操作任务，包括垃圾分类、彩色鸡蛋拾取和鸡蛋盒放置。与基于基准的评估相比，这些真实世界任务涉及更不受约束的物体外观、空间变化和语言条件目标规格，为星 VLA- α 在实际部署场景中的表现提供了补充视角。




图 7：机器人挑战赛上大规模真实世界基准的结果可视化。更多视频请参见补充网页。

I LIBERO-Plus 上的鲁棒性评估

LIBERO-Plus 是一个基于标准 LIBERO 数据集构建的扩展基准，用于评估机器人操作模型在多种扰动下的鲁棒性。它引入了相机视角、机器人配置、语言指令、光照条件、背景杂乱、传感器噪声和物体布局方面的变化。

在我们的评估中，我们严格遵循官方设置：所有模型均在标准 LIBERO 训练数据上训练，并直接在 LIBERO-Plus 上进行评估，无需任何额外适应。因此，该基准衡量的是从标准 LIBERO 学习到的策略能否迁移到扰动环境，而不是能否拟合特定的面向鲁棒性的训练分布。

表 17 显示，星 VLA- α 在多种扰动下从标准 LIBERO 到 LIBERO-Plus 的迁移表现良好。专家变体和通用变体均保持鲁棒，并优于先前的基线，尽管它们仅在标准 LIBERO 上训练，未进行任何针对基准的鲁棒性增强。




图 8：弗兰卡研究 3 号机器人上的真实世界部署任务。从上到下：鸡蛋盒放置、垃圾分类和彩色鸡蛋拾取。

表 17：在相机、机器人、语言、光照、背景、噪声和布局扰动下 LIBERO-Plus 基准上的性能比较。所有模型均在标准 LIBERO 上训练并在 LIBERO-Plus 上评估，每列最佳分数以粗体显示。

Model	Camera	Robot	Language	Light	Background	Noise	Layout	Total
OpenVLA Kim et al. (2024)	0.8	3.5	23.0	8.1	34.8	15.2	28.5	15.6
OpenVLA-OFT Kim et al. (2025)	56.4	31.9	79.5	88.7	93.3	75.8	74.2	69.6
NORA Hung et al. (2025)	2.2	37.0	65.1	45.7	58.6	12.8	62.1	39.0
WorldVLA Cen et al. (2025)	0.1	27.9	41.6	43.7	17.1	10.9	38.0	25.0
UniVLA Bu et al. (2025)	1.8	46.2	69.6	69.0	81.0	21.2	31.9	43.9
π_0 Black et al. (2024a)	13.8	6.0	58.8	85.0	81.4	79.0	68.9	53.6
π_0 -Fast Pertsch et al. (2025)	65.1	21.6	61.0	73.2	73.2	74.4	68.8	61.6
RIPT-VLA Tan et al. (2025)	55.2	31.2	77.6	88.4	91.6	73.5	74.2	68.4
StarVLA- α (Specialist)	48.7	63.4	86.8	95.8	94.6	75.0	80.2	77.8
StarVLA- α (Generalist)	52.5	64.3	86.2	97.8	98.1	80.2	79.1	79.7

值得注意的是，StarVLA- α 在语言、光照、背景和布局扰动下均表现出一致的良好性能，这表明强大的视觉语言模型（VLM）骨干提供了鲁棒的多模态表示。该通用模型与专用模型相比具有竞争力，有时甚至略胜一筹，这支持了我们的主要发现，即跨基准的联合训练可以提高鲁棒性。总体而言，这些结果表明，强大的初始化和统一的训练流程无需额外的架构复杂度即可带来显著的鲁棒性。