

EventVLA: 面向长时程视觉-语言-动作策略的事件驱动视觉证据记忆

Ganlin Yang^{1,2*}, Zhangzheng Tu^{4,3*}, Yuqiang Yang^{2*}, Sitong Mao⁵, Junyi Dong⁵
Tianxing Chen⁶, Jiaqi Peng^{7,2}, Jing Xiong^{8,2}, Jiafei Cao², Jifeng Dai⁷, Wengang Zhou¹
Yao Mu^{3,2,6†}, Tai Wang^{2†}

¹University of Science and Technology of China ²Shanghai AI Laboratory
³Shanghai Jiao Tong University ⁴Dalian University of Technology ⁵Huawei Technologies Co., Ltd.
⁶The University of Hong Kong ⁷Tsinghua University ⁸Peking University

Project Page: [EventVLA](#)

摘要: 记忆仍是长时程机器人操作的关键瓶颈, 因为标准的视觉-语言-动作 (VLA) 策略在任务相关线索随时间被遮挡或不可观测时往往失效。尽管现有的记忆增强方法利用历史上下文, 但它们要么存在严重的信息瓶颈, 要么通过解耦的双系统引入高延迟, 要么依赖无选择性的缓冲区积累大量视觉冗余。为解决这些局限性, 本文提出 **EventVLA**, 一个基于稀疏视觉证据记忆概念的端到端框架, 包含两个核心组件: 用于保留初始和短期上下文的基础视觉锚点, 以及动态关键帧证据记忆 (KEM) 模块。具体而言, KEM 直接从 VLA 的潜在嵌入中预测未来关键帧概率, 以自主捕获和存储稀疏的、任务关键的视觉事件。这种前瞻驱动的机制使策略能够动态评估当前观测的未来因果效用, 在瞬态视觉证据变得不可观测之前将其保留。此外, 本文提出 **RoboTwin-MeM**, 一个专门设计用于评估具有交互式视觉证据的非马尔可夫操作任务的诊断基准。大量评估表明, 在 17 个需要记忆的仿真任务和 4 个真实世界双臂任务中, **EventVLA** 相比最先进的记忆增强 VLA 平均成功率提升 +40%。代码、模型和数据集可在 <https://github.com/InternRobotics/EventVLA> 获取。

关键词: 记忆, 机器人操作, 机器人基准

1 引言

近期视觉-语言-动作 (Vision-Language-Action, VLA) 策略在可泛化与精细操作方面表现卓越 [1, 2, 3, 4, 5], 然而其运行主要基于严格的马尔可夫假设。该假设隐含地认为所有与任务相关的信息始终可见。实际上, 物理工作空间动态变化, 智能体必须持续保留中间状态, 例如被移动物品的原始位置, 以指导后续动作。为应对这一非马尔可夫挑战, 具备记忆能力的 VLA 已在三种范式下涌现 [6]。首先, 双系统记忆 VLA [7, 8, 9] 将认知与控制解耦, 但存在高延迟与严重的误差传播问题。其次, 循环架构 [10, 11] 将历史压缩至隐藏状态, 形成信息瓶颈, 丢弃了细粒度视觉细节。第三, 记忆缓冲区 [12, 13] 保持视觉保真度, 但盲目累积冗余帧, 缺乏选择性机制。

* 同等贡献。 † 通讯作者。




图 1: EventVLA 概览。EventVLA 通过存储稀疏的、任务关键的视觉证据来处理长时程、需要记忆的操作任务。该图展示了 (a) 非马尔可夫挑战, (b) 我们提出并评估的基准, (c) 事件驱动的记忆设计, 以及 (d) 在仿真与真实世界任务中的显著提升。

因此, 一个关键问题仍然存在: VLA 究竟应在何时、保留何种视觉证据, 以在不超出计算极限的前提下最大化执行成功率?

为避免标准记忆缓冲区 [12, 14] 的大量冗余, 我们发现一组稀疏的历史关键帧可为许多长时程任务提供充分上下文。我们将这些定义为**基础视觉锚点**: 初始帧 (捕获不变的全局布局) 与短期历史窗口 (提供局部运动线索)。尽管这些启发式锚点能高效解决结构简单的记忆需求任务, 但在复杂交互场景中却根本失效, 因为任务关键证据会意外出现并随后消失。例如, 机器人可能在揭开不透明盖子时短暂观察到物体颜色, 或需要跟踪随后被遮挡的指定目标。此类瞬态视觉证据无法从初始帧或近期帧中恢复; 它表现为一种交互式稀疏事件, 必须被主动捕获并保留。

基于这一洞见, 本文提出事件视觉语言动作框架 (**EventVLA**), 一种以稀疏视觉证据记忆为核心的端到端框架。**EventVLA** 通过无缝结合基础视觉锚点与动态关键帧证据记忆模块 (KEM), 消除了历史冗余。与僵化的规则式启发方法不同, KEM 建立了一种自主、数据驱动的机制, 旨在主动捕捉瞬态的、由交互驱动的事件。具体而言, KEM 通过对未来执行视野进行前瞻性关键帧预测, 使视觉语言动作策略能够主动调度稀疏记忆写入, 以记录关键中间状态。这种预测策略确保瞬态视觉证据在任务明确需要之前就被捕获, 从而无缝弥补其短暂出现与后续执行中最终使用之间的时间间隔。为了在不依赖繁重人工标注的情况下学习这一能力, 本文开发了一种基于 Qwen3-VL 的离线 [15] 自动标注流程, 从演示中提取精确的关键帧监督。

除算法设计外, 评估记忆增强策略还需要能够准确反映现实操作中非马尔可夫动态的基准, 其中任务关键证据往往仅在中间交互过程中短暂显现。由于现有基准如 RMBench [8] 在很大程度上仅凭基础视觉锚点即可解决, 本文引入 **RoboTwin-MeM**,

一个明确包含此类真正非马尔可夫场景的诊断性仿真基准。该基准包含 8 项具有挑战性的任务，所需中间关键帧数量从 1 到 5 系统性地递增。大量评估证明了 EventVLA 在不同领域的优越性。它在传统记忆导向任务上达到了新的最先进水平（RMBench 上 67.8%），并在新提出的需要瞬态记忆的 RoboTwin-MeM 上取得了 75.2% 的平均成功率，大幅超越现有基于记忆的视觉语言动作模型。此外，在要求严苛的真实世界双臂任务中，EventVLA 显著优于反应式（ $\pi_{0.5}$ [1]）和记忆增强（ π_{MEM} [9]）基线，成功率高达 80%，证实了其鲁棒的非马尔可夫情境感知能力。

2 相关工作

2.1 面向长程操作任务的记忆增强策略

近期视觉-语言-动作（Vision-Language-Action, VLA）基础模型 [1, 2, 16, 17, 5, 3, 4, 18, 19, 20, 21, 22, 23, 24, 25] 展现出卓越的泛化能力，但本质上不具备记忆功能。在严格的马尔可夫假设下运行，它们难以处理关键视觉信息瞬时出现或被遮挡的非马尔可夫任务。为解决这一问题，记忆增强型 VLA 已在三种范式中涌现。首先，双系统记忆 VLA [7, 8, 9, 26, 27] 采用高层视觉语言模型进行规划，但存在误差传播和推理延迟高的问题。其次，循环记忆架构 [10, 11, 28, 29, 30] 将历史压缩为隐藏状态，形成信息瓶颈，丢弃细粒度视觉细节。第三，记忆缓冲区 [31, 12, 13, 32, 33, 34, 14] 保留历史帧以绕过压缩；然而，现有方法盲目累积冗余帧，淹没稀疏关键证据并带来沉重开销。EventVLA 通过仅保留稀疏视觉证据来优化该范式。通过结合静态视觉锚点与动态关键帧证据记忆（Keyframe Evidence Memory, KEM），EventVLA 选择性地捕获瞬态状态，在稳健任务执行与实时计算效率之间取得平衡。

2.2 面向记忆的操作基准

标准仿真套件 [35, 36, 37, 38, 39] 强调长时程执行而非显式记忆推理，因为任务相关信息通常持续可见。尽管近期以记忆为中心的基准 [40, 41, 42, 43, 44] 试图解决这一问题，但它们往往规模有限、专为强化学习定制，或仍包含可观测状态。与我们的工作最接近的套件 RMBench [8] 和 RoboMME [6] 系统性地划分了记忆需求，但大多可仅凭静态视觉锚点解决，严格非马尔可夫的中间状态仍未得到充分探索。为弥合这一方法学空白，我们提出 **RoboTwin-MeM**。与现有基准不同，**RoboTwin-MeM** 隔离了真正非马尔可夫的操作任务，其中关键视觉证据在交互过程中瞬时出现并随后消失，为评估 VLA 策略对中间状态保持能力提供了严格的诊断平台。

3 EventVLA 框架

3.1 问题表述与基础视觉锚点

本文将长时程机器人操作形式化为一个非马尔可夫决策过程。标准的反应式视觉-语言-动作策略将当前观测 o_t 和语言指令 l 直接映射为动作，即 $a_t = \pi(o_t, l)$ ，当关键信息随时间推移被遮挡或不可观测时，这种策略从根本上失效。为解决这一问题，EventVLA 引入了一个显式的外部稀疏视觉证据记忆缓冲区 M_t ，与即时观测一起用于条件化动作生成：

$$a_t = \pi(o_t, M_{t-1}, l) \quad (1)$$

其中 M_{t-1} 选择性地存储关键历史帧，以保留必要的视觉证据，同时最小化信息和计算冗余。

记忆缓冲区结构为 $M_t = A_t \cup E_t$ ，无缝结合了基础视觉锚点 A_t 和交互驱动的事件关键帧 E_t 。视觉锚点 A_t 代表一种确定性的、基于规则的基线，旨在捕获永久场景布局和即时时间上下文。具体而言，时间步 t 处的视觉锚点由初始工作空间配置 o_0 和大小为 K 的短期历史滑动窗口组成：

$$A_t = o_0 \cup o_{t-K}, \dots, o_{t-1} \quad (2)$$

此处，初始帧 o_0 作为永久空间锚点，使视觉-语言-动作模型能够在任何位移发生之前保持对原始场景布局的不变记忆。同时，短期历史 o_{t-i} 为模型提供关键的运动和任务进展线索，从而实现平滑连续的动作生成。然而，由于这些刚性锚点无法捕获复杂交互过程中途出现的不可预测的瞬态证据，它们由关键帧证据记忆模块生成的 E_t 动态增强，详见第 3.2 节，整体框架如图 2 所示。

3.2 关键帧证据记忆模块

为了主动捕捉基础视觉锚点固有缺失的瞬态、交互驱动事件，

例如被遮挡物体的短暂暴露，本文引入了关键帧证据记忆 (Keyframe Evidence Memory, KEM) 模块。为高效实现该机

制，KEM 被设计为轻量级并行预测头，直接与主要动作头并行运行。关键帧预测头并非利用孤立特征，而是摄取从视觉语言动作模型 (VLA) 自回归变换器最终层提

取的精确隐藏状态 $h_t \in \mathbb{R}^{H \times d}$ ，用于动作时域 H 。由 Unified VLA Policy

于 h_t 自然封装了视觉观测与动作条件查询令牌的联合嵌入，关键帧头继承了模型未来执行计划的主动感

知能力。具体而言，关键帧头将这些共享隐藏状态 h_t 投影到跨越未来块时域 H

的关键帧概率向量 $\hat{\mathbf{p}}_t$ ：




图 2: EventVLA 框架。 EventVLA 维护一个由基础视觉锚点和交互驱动的事件关键帧组成的稀疏视觉证据记忆，并使用关键帧证据记忆模块主动将任务关键的未来关键观测提交到记忆中。

$$\hat{\mathbf{p}}_t = \sigma(\text{KEM}_{\text{mlp}}(h_t)) = [\hat{p}_t^1, \hat{p}_t^2, \dots, \hat{p}_t^H]^T \in [0, 1]^H \quad (3)$$

其中 $\sigma(\cdot)$ 表示逐元素 Sigmoid 函数，每个标量 $\hat{p}_t^i \in [0, 1]$ 明确表示第 i 个未来执行步骤为任务关键帧的预测概率。这种逐块预测的理由很直接：纯逐步分类器会完全错过在执行窗口中途短暂出现并消失的任务关键事件（例如在步骤 $t+i$ 处，其中 $0 < i < H$ ）。这一局限性促使 KEM 采用前瞻驱动的逐块范式 $\hat{\mathbf{p}}_t$ ，使 VLA 策略能够主动规划整个即将到来的执行时域上的“记忆调度”。

在该预测向量 $\hat{\mathbf{p}}_t$ 的驱动下，每当预测概率 $\hat{p}_t^i$ 超过阈值 (τ_{commit}) 时，EventVLA 触发稀疏记忆写入事件，动态提交原始图像




图 3: RoboTwin-MeM 基准中 8 项评估任务概览。为严格评估中间视觉证据保留能力，每项任务均显式参数化为 n （范围从 1 到 5），表示成功完成任务所必须记忆的瞬态、交互驱动关键帧的精确数量。这些任务关键的中间事件以蓝色边框突出显示。

将 $t + i$ 添加至事件缓冲区 E_t 。为满足实时性约束， E_t 受限于最大容量 $N_{\max}$ ，并通过先进先出（First-In-First-Out, FIFO）淘汰策略进行管理。在任意执行步骤 t ，这些动态累积的事件关键帧 E_{t-1} 与基础视觉锚点 A_t 及即时观测 o_t 无缝组合为单一的时间有序序列：

$$I_{\text{input}} = \text{concatenate}([A_t, E_{t-1}, o_t]) \quad (4)$$

将该统一序列直接输入视觉语言模型（VLM）的视觉编码器，使自注意力层能够动态提取稀疏历史帧之间的复杂时间相关性，从而原生地赋予模型面向长时程操作的鲁棒情境感知能力。

3.3 端到端训练与推理细节

为训练关键事件记忆（KEM）模块而不产生高昂的人工标注成本，我们采用离线 Qwen3-VL[15] 自动化流程提取任务关键事件的真值时间戳。为缓解物理交互固有的时间模糊性，我们通过序列平均二元交叉熵（BCE）目标（ L_{kem} ），利用时间平滑软标签监督分块关键帧预测。该框架与标准动作生成损失（ L_{action} ）一起进行端到端优化。

$$L = L_{\text{action}} + \lambda L_{\text{kem}} \quad (5)$$

为弥合训练与测试之间的分布偏移，同时保持早期训练稳定性，我们采用一种从真值到自主预测逐步过渡记忆构建的教师-学生课程策略。在线推理期间，连续关键帧概率自然聚集于展开的语义事件周围。为强制严格的内存稀疏性并防止冗余缓冲区泛滥，我们使用一维非极大值抑制（Non-Maximum Suppression, NMS）和时间冷却流程，将这些密集预测蒸馏为离散写入事件。关于软标签、课程策略、NMS 算法及自动标注流程的完整数学表述详见附录 A。此外，完整的网络结构与训练配置详见附录 B.3。

4 RoboTwin-MeM 基准

为系统评估视觉-语言-动作（VLA）策略捕获并保留瞬态视觉证据的能力，我们引入 RoboTwin-MeM，一个诊断性仿真基准。该基准在 RoboTwin 2.0[35] 仿真平台内开发，并构建于 SAPIEN[45] 物理引擎之上，

RoboTwin-MeM 在统一流程中同时支持自动化数据综合与集成策略评估。该基础设施确保了可扩展的数据生成，并为机器人操作提供了一致且可复现的基准测试。此外，我们提供了细粒度的语言标注，这些标注与每个动作-观测对严格对齐。这些标注为低级交互和状态转换赋予了明确的语言描述，提供了结构化且密集的监督信号，对训练下游记忆模块极为有益。

RoboTwin-MeM 与现有以记忆为核心的套件的核心区别在于，它明确隔离并量化了中间记忆需求。以往基准测试通常允许策略仅依赖初始静态锚点或短期历史即可成功，而 RoboTwin-MeM 迫使模型主动记忆执行过程中途产生的不可预测的视觉证据。为了严格诊断这一能力，我们使用 n : 必须动态保留的中间事件关键帧的确切数量来显式参数化任务复杂度。如图 3 所示，RoboTwin-MeM 包含 8 个真正非马尔可夫的任务，具有极长的执行视野，平均每个回合 430 至 1544 步。在整个基准测试中，所需的中间关键帧数量 n 系统性地从 1 到 5 变化，为非马尔可夫控制建立了分层难度体系。详细的任务统计和语言指令见表 4。

关键的是，这种 n 参数化设计使 RoboTwin-MeM 能够评估超越简单历史拼接的多样化记忆能力。首先，诸如“拾取未隐藏方块”($n = 3$) 和“困难覆盖方块”($n = 4$) 等任务要求瞬时记忆；关键视觉证据在盖子被揭开时短暂暴露，一旦关闭便完全消失，要求策略即时锚定这一稍纵即逝的信息。其次，该基准通过“按键关键帧”($n \in [2, 5]$) 等任务评估序列跟踪与计数逻辑，其中每次按键代表一个执行关键事件，必须被顺序记录以决定任务成败。最后，“复现路径”任务 ($n = 4$) 测试模型的上下文学习能力，要求智能体观察演示、提取随机空间关键点，并在上下文中利用这些线索复制路径。这种对瞬时识别、事件计数和上下文模仿的覆盖，使 RoboTwin-MeM 成为评估记忆增强机器人策略的严格基准。

5 实验

5.1 仿真基准上的性能

To thoroughly assess the efficacy of EventVLA, we benchmark our framework against a comprehensive suite of state-of-the-art baselines, categorized into two major paradigms. For standard, reactive (non-memory-based) VLA policies, we select DP [3], ACT [5], $\pi_{0.5}$ [1], X-VLA [17], and QwenOFT [46]. For memory-augmented methods, we evaluate dual-system architectures, including MemER [7] and Mem-0 [8], as well as the end-to-end MemoryVLA [12] framework, where we reproduce its variants based on both the official OpenVLA-OFT [47] and QwenOFT [46] implementations. Our proposed EventVLA is also constructed upon the identical open-source QwenOFT backbone as its foundational base model.

Evaluation on RMBench and the Efficacy of Visual Anchors: First, we evaluate our method on RMBench [8], as shown in Table 1. Because tasks in this suite primarily rely on persistent spatial layouts and fixed motion style rather than hidden intermediate states, we deploy a streamlined version of EventVLA utilizing solely foundational visual anchors. Experimental results demonstrate that this configuration achieves an average success rate of 67.8%, securing state-of-the-art performance and proving that rule-based anchors provide sufficient context

表 1: RMBench 上的总体平均成功率。逐任务详细分解见附录表 8。

Methods	Average (%)
<i>Non Memory-based VLAs</i>	
DP	5.8
ACT	5.9
$\pi_{0.5}$	10.4
X-VLA	9.8
QwenOFT	5.6
<i>Dual-system Memory-VLAs</i>	
MemER	8.7
Mem-0	42.0
<i>End-to-end Memory-VLAs</i>	
MemoryVLA (OpenVLA)	19.4
MemoryVLA (QwenOFT)	41.7
<i>EventVLA & Ablations</i>	
EventVLA (w/o initial)	33.7
EventVLA (w/o short-term)	23.8
EventVLA (VA only)	67.8

表 2: RoboTwin-MeM 基准结果。（粗体：最佳；下划线：次佳）。

Tasks	n=1	n=2	n=3		n=4			n=5	Total average
	Rearrange Blocks Hard	Put Back Block Hard	Pick Objects in Order	Pick the Unhidden Block	Cover Blocks Hard	Find Seal Stamp	Reproduce Route	Press Button Keyframe	
▼ Non Memory-based Vision-language-action Models:									
$\pi_{0.5}$	20%	19%	1%	14%	0%	8%	0%	0%	7.8%
QwenOFT	3%	26%	0%	0%	0%	0%	0%	1%	3.8%
▼ Dual-system Memory-based Vision-language-action Models:									
MemER	32%	4%	12%	2%	0%	26%	3%	5%	10.5%
Mem-0	0%	0%	0%	0%	0%	0%	0%	0%	0.0%
▼ End-to-end Memory-based Vision-language-action Models:									
MemoryVLA (OpenVLA)	12%	0%	0%	1%	0%	10%	2%	14%	4.9%
MemoryVLA (QwenOFT)	39%	0%	1%	9%	1%	11%	0%	25%	10.8%
EventVLA (VA only)	62%	13%	5%	20%	0%	26%	0%	18%	18.0%
EventVLA (VA+KEM)	62%	93%	90%	54%	94%	63%	98%	48%	75.2%
EventVLA (implicit memory bank)	51%	9%	16%	37%	1%	68%	2%	15%	24.9%
EventVLA (hard label)	59%	77%	28%	62%	85%	36%	6%	37%	48.8%
EventVLA (w/o NMS)	62%	93%	49%	36%	10%	35%	97%	45%	53.4%
EventVLA ($N_{\max} = 2$)	51%	35%	28%	33%	39%	53%	0%	17%	32.0%
EventVLA (chunk size=30)	22%	98%	18%	28%	16%	29%	0%	38%	31.1%
EventVLA (chunk size=15)	16%	30%	2%	17%	6%	16%	10%	12%	13.6%

针对需要简单记忆的长时程操作。为验证这些组件的结构必要性，我们进行了两项消融研究。移除初始帧（EventVLA 无初始帧）或丢弃短期历史（EventVLA 无短期历史）导致总体成功率分别骤降至 33.7% 和 23.8%。这证实了初始全局空间参考和短期运动线索对于有效视觉锚定均不可或缺。

在 RoboTwin-MeM 上的评估及关键帧证据记忆（KEM）的必要性：虽然固定的视觉锚点在人民币基准上表现出色，但在罗博特温-记忆模块（RoboTwin-MeM）这一专门用于测试中间状态记忆的诊断套件上，其局限性变得尤为明显。如表 2 所示，仅依赖规则驱动的视觉锚点（仅视觉锚点）的平均成功率仅为 18.0%。这一急剧下降表明，对于需要视觉-语言-动作策略保留执行过程中生成的瞬态视觉证据的任务，固定的历史窗口从根本上是不足的。为了克服这一非马尔可夫瓶颈，完整的 EventVLA 框架通过动态关键帧证据记忆模块（KEM）增强了这些视觉锚点（视觉锚点+关键帧证据记忆）。实验结果显示质的飞跃：完整的 EventVLA 达到了 75.2% 的成功率，大幅超越所有基线模型。这一显著的性能差距（从 18.0% 到 75.2%）有力地证明了关键帧证据记忆的动态事件捕获和前瞻驱动写入机制对于解决依赖瞬态中间记忆的复杂长时程任务是不可或缺的。

标准马尔可夫基准评估：为了验证 EventVLA 保留了基本的反应式控制能力，我们在罗博特温-2.0[35] 的标准马尔可夫任务上对其进行了评估（表 3）。我们的记忆机制不仅没有降低性能，反而相比无记忆的 QwenOFT 基线略微提高了成功率（简单任务从 80.0% 提升至 83.8%；困难任务从 78.0% 提升至 81.6%），无缝补充了标准的闭环执行。

表 3: 罗博特温 2.0 基准结果。EventVLA 在马尔可夫任务上超越了其基线基础模型 QwenOFT。

Tasks	π_0	$\pi_{0.5}$	X-VLA	QwenFast	QwenOFT	EventVLA
Easy	65.9%	82.7%	72.8%	72.5%	80.0%	83.8%
Hard	58.4%	76.8%	72.8%	83.2%	78.0%	81.6%

5.2 EventVLA 的消融分析

为了系统验证关键帧证据记忆模块的结构设计，我们在具有挑战性的罗博特温-记忆模块套件上进行了消融研究（表 2，底部灰色部分）。

核心机制：我们观察到，用隐式潜在记忆库替代显式原始图像拼接会使成功率从 75.2% 急剧下降至 24.9%，造成严重的信息瓶颈。同样，用刚性二元目标替代时间平滑软标签会破坏预测头部的稳定性，使性能降至 48.8%。

缓冲区与视野管理：移除非极大值抑制后处理或限制缓冲区容量（ $N_{\max} = 2$ ）会导致冗余帧泛滥，并过早地以先进先出方式驱逐关键早期证据，




图 4: ARX ACONE 双臂机器人的真实实验设置与结果。我们评估了四个内存密集型操作任务：找积木（简单）、找积木（困难）、按次数抓取和按顺序抓取。

使成功率分别下降至 53.4% 和 32.0%。最后，将执行块大小从 50 缩小到 30 或 15 会严重截断 KEM 的预见窗口，阻碍主动事件调度，使性能骤降至 31.1% 和 13.6%。

这些消融模式的全面深入分析以及实时推理速度剖析详见附录 C.2。

5.3 真实机器人评估

为了在物理环境中评估 EventVLA，我们将框架部署在 ARX ACONE 双臂机器人上，执行四个非马尔可夫操作任务，每个任务进行 20 次独立试验。这些任务明确评估了真实环境下多样化的认知记忆能力：

1) 找积木（简单）而“寻找隐藏方块（困难）”要求模型仅在短暂视觉暴露后记住隐藏方块的空间位置。2) “拾取指定次数”测试计数逻辑，要求机器人读取随机数字并相应地操作方块。3) “按顺序拾取”通过要求机器人复现最初由棍子指出的随机序列来评估上下文记忆。我们将事件视觉语言动作模型与最先进的非记忆模型 $\pi_{0.5}$ [1] 以及复现的记忆增强基线 π_{MEM} [9] 进行基准对比。

如图 4 所示，纯反应式 $\pi_{0.5}$ 策略在所有任务中几乎完全失败（成功率仅为 0% 至 10%），因为它从根本上缺乏推断遮挡状态所需的历史上下文。虽然记忆增强 π_{MEM} 基线表现出部分改进（例如，“寻找隐藏方块（简单）”成功率为 50%），但在需要多个事件的更复杂任务（如“拾取指定次数”30% 和“按顺序拾取”40%）上，其性能显著下降，原因在于长期历史的有损压缩。与此形成鲜明对比的是，事件视觉语言动作模型在四项任务中分别取得了 90%、60%、90% 和 75% 的显著成功率。这一稳健的物理性能验证了关键事件记忆模块能够有效提取并保留关键的瞬态视觉线索，赋予视觉语言动作模型在真实世界中的长时程记忆感知能力。

6 局限性

虽然事件视觉语言动作模型能有效捕捉瞬态视觉证据，但其有界事件缓冲区限制了在事件密度极高的超长时程任务（例如 > 10 分钟）中的可扩展性。此类场景存在缓冲区饱和及早期历史线索被过早逐出的风险。未来工作将探索分层记忆或压缩表示以管理海量事件序列。

7 结论

本文提出了事件视觉语言动作模型，这是一个端到端框架，通过稀疏视觉证据记忆解决非马尔可夫长时程操作问题。通过将基于规则的视觉锚点与前瞻驱动的关键帧证据记忆模块相结合，事件视觉语言动作模型主动捕捉任务关键的瞬态事件，完全避免了密集记忆的冗余。此外，本文还提出了机器人孪生记忆基准，这是一个用于评估中间记忆能力的诊断基准。在 17 项仿真任务和 4 项真实世界任务上的广泛评估表明，事件视觉语言动作模型显著优于最先进的记忆增强视觉语言动作模型，确保了需要记忆的长时程物理执行的稳健性。

致谢

本工作由上海人工智能实验室资助。

参考文献

- [1] P. Intelligence, K. Black, N. Brown, J. Darpinian, K. Dhabalia, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [2] P. Intelligence, A. Amin, R. Aniceto, A. Balakrishna, K. Black, K. Conley, G. Connors, J. Darpinian, K. Dhabalia, J. DiCarlo, et al. $\pi_{0.6}^*$: a vla that learns from experience. *arXiv preprint arXiv:2511.14759*, 2025.
- [3] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 44(10-11):1684–1704, 2025.
- [4] Y. Ze, G. Zhang, K. Zhang, C. Hu, M. Wang, and H. Xu. 3d diffusion policy: Generalizable visuomotor policy learning via simple 3d representations. *arXiv preprint arXiv:2403.03954*, 2024.
- [5] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- [6] Y. Dai, H. Fu, J. Lee, Y. Liu, H. Zhang, J. Yang, C. Finn, N. Fazeli, and J. Chai. Robomme: Benchmarking and understanding memory for robotic generalist policies. *arXiv preprint arXiv:2603.04639*, 2026.
- [7] A. Sridhar, J. Pan, S. Sharma, and C. Finn. Memer: Scaling up memory for robot control via experience retrieval. *arXiv preprint arXiv:2510.20328*, 2025.
- [8] T. Chen, Y. Wang, M. Li, Y. Qin, H. Shi, Z. Li, Y. Hu, Y. Zhang, K. Wang, Y. Chen, et al. Rmbench: Memory-dependent robotic manipulation benchmark with insights into policy design. *arXiv preprint arXiv:2603.01229*, 2026.
- [9] M. Torne, K. Pertsch, H. Walke, K. Vedder, S. Nair, B. Ichter, A. Z. Ren, H. Wang, J. Tang, K. Stachowicz, et al. Mem: Multi-scale embodied memory for vision language action models. *arXiv preprint arXiv:2603.03596*, 2026.
- [10] L. Xiao, J. Li, J. Gao, F. Ye, Y. Jin, J. Qian, J. Zhang, Y. Wu, and X. Yu. Ava-vla: Improving vision-language-action models with active visual attention. *arXiv preprint arXiv:2511.18960*, 2025.
- [11] A. Bulatov, Y. Kuratov, and M. Burtsev. Recurrent memory transformer. *Advances in Neural Information Processing Systems*, 35:11079–11091, 2022.

- [12] H. Shi, B. Xie, Y. Liu, L. Sun, F. Liu, T. Wang, E. Zhou, H. Fan, X. Zhang, and G. Huang. Memoryvla: Perceptual-cognitive memory in vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2508.19236*, 2025.
- [13] H. Li, S. Yang, Y. Chen, Y. Tian, X. Yang, X. Chen, H. Wang, T. Wang, F. Zhao, D. Lin, et al. Cronusvla: Transferring latent motion across time for multi-frame prediction in manipulation. *arXiv e-prints*, pages arXiv–2506, 2025.
- [14] X. Wang, X. Gao, J. Fu, Z. Li, D. Fortier, G. Mullins, A. Kolobov, and B. Guo. Lola: Long horizon latent action learning for general robot manipulation. *arXiv preprint arXiv:2512.20166*, 2025.
- [15] S. Bai, Y. Cai, R. Chen, K. Chen, X. Chen, Z. Cheng, L. Deng, W. Ding, C. Gao, C. Ge, et al. Qwen3-vl technical report. *arXiv preprint arXiv:2511.21631*, 2025.
- [16] S. Liu, B. Li, K. Ma, L. Wu, H. Tan, X. Ouyang, H. Su, and J. Zhu. Rdt2: Exploring the scaling limit of umi data towards zero-shot cross-embodiment generalization. *arXiv preprint arXiv:2602.03310*, 2026.
- [17] J. Zheng, J. Li, Z. Wang, D. Liu, X. Kang, Y. Feng, Y. Zheng, J. Zou, Y. Chen, J. Zeng, et al. X-vla: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. *arXiv preprint arXiv:2510.10274*, 2025.
- [18] T. Chen, Y. Mu, Z. Liang, Z. Chen, S. Peng, Q. Chen, M. Xu, R. Hu, H. Zhang, X. Li, et al. G3flow: Generative 3d semantic flow for pose-aware and generalizable object manipulation. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 1735–1744, 2025.
- [19] J. Wen, Y. Zhu, J. Li, Z. Tang, C. Shen, and F. Feng. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025.
- [20] M. Lin, P. Ding, S. Wang, Z. Zhuang, Y. Liu, X. Tong, W. Song, S. Lyu, S. Huang, and D. Wang. Hif-vla: Hindsight, insight and foresight through motion representation for vision-language-action models. *arXiv preprint arXiv:2512.09928*, 2025.
- [21] Z. Liang, Y. Li, T. Yang, C. Wu, S. Mao, T. Nian, L. Pei, S. Zhou, X. Yang, J. Pang, et al. Discrete diffusion vla: Bringing discrete diffusion to action decoding in vision-language-action policies. *arXiv preprint arXiv:2508.20072*, 2025.
- [22] G. Yang, T. Zhang, H. Hao, W. Wang, Y. Liu, D. Wang, G. Chen, Z. Cai, J. Chen, W. Su, et al. Vlaser: Vision-language-action model with synergistic embodied reasoning. *arXiv preprint arXiv:2510.11027*, 2025.
- [23] W. Shen, Y. Liu, Y. Wu, Z. Liang, S. Gu, D. Wang, T. Nian, L. Xu, Y. Qin, J. Pang, et al. Expertise need not monopolize: Action-specialized mixture of experts for vision-language-action learning. *arXiv preprint arXiv:2510.14300*, 2025.
- [24] J. Wen, Y. Zhu, M. Zhu, Z. Tang, J. Li, Z. Zhou, X. Liu, C. Shen, Y. Peng, and F. Feng. Diffusionvla: Scaling robot foundation models via unified diffusion and autoregression. In *Forty-second International Conference on Machine Learning*, 2025.
- [25] J. Wen, Y. Zhu, J. Li, M. Zhu, Z. Tang, K. Wu, Z. Xu, N. Liu, R. Cheng, C. Shen, et al. Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation. *IEEE Robotics and Automation Letters*, 2025.
- [26] R. Zheng, Y. Liang, S. Huang, J. Gao, H. Daumé III, A. Kolobov, F. Huang, and J. Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. In *International Conference on Learning Representations*, volume 2025, pages 54277–54296, 2025.

- [27] H. Tan, P. Co, Y. Xu, S. Rong, Y. Ji, C. Chi, X. Chen, Q. Zhang, Z. Zhao, P. Wang, et al. Action-sketcher: From reasoning to action via visual sketches for long-horizon robotic manipulation. *arXiv preprint arXiv:2601.01618*, 2026.
- [28] H. Wang, Z. Jing, J. Ao, S. Song, X. Li, G. Huang, and C. Bai. Beyond short-horizon: Vq-memory for robust long-horizon manipulation in non-markovian simulation benchmarks. *arXiv preprint arXiv:2603.09513*, 2026.
- [29] M. Torne, A. Tang, Y. Liu, and C. Finn. Learning long-context diffusion policies via past-token prediction. *arXiv preprint arXiv:2505.09561*, 2025.
- [30] Y.-L. Wei, H. Liao, Y. Lin, P. Wang, Z. Liang, G. Liu, and W.-S. Zheng. Cyclemanip: Enabling cyclic task manipulation via effective historical perception and understanding. *arXiv preprint arXiv:2512.01022*, 2025.
- [31] H. Jang, S. Yu, H. Kwon, H. Jeon, Y. Seo, and J. Shin. Contextvla: Vision-language-action model with amortized multi-frame context. *arXiv preprint arXiv:2510.04246*, 2025.
- [32] M. Lin, X. Liang, B. Lin, L. Jingzhi, Z. Jiao, K. Li, Y. Ma, Y. Liu, S. Zhao, Y. Zhuang, et al. Echovla: Robotic vision-language-action model with synergistic declarative memory for mobile manipulation. *arXiv preprint arXiv:2511.18112*, 2025.
- [33] Y. Lei, Z. Liang, H. Zhang, and P. Luo. Vpwem: Non-markovian visuomotor policy with working and episodic memory. *arXiv preprint arXiv:2603.04910*, 2026.
- [34] L. Tan, J. Li, and G. Jing. Memoact: Atkinson-shiffrin-inspired memory-augmented visuomotor policy for robotic manipulation. *arXiv preprint arXiv:2603.18494*, 2026.
- [35] T. Chen, Z. Chen, B. Chen, Z. Cai, Y. Liu, Z. Li, Q. Liang, X. Lin, Y. Ge, Z. Gu, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025.
- [36] S. Nasiriany, A. Maddukuri, L. Zhang, A. Parikh, A. Lo, A. Joshi, A. Mandlekar, and Y. Zhu. Robocasa: Large-scale simulation of everyday tasks for generalist robots. *arXiv preprint arXiv:2406.02523*, 2024.
- [37] S. Tao, F. Xiang, A. Shukla, Y. Qin, X. Hinrichsen, X. Yuan, C. Bao, X. Lin, Y. Liu, T.-k. Chan, et al. Maniskill3: Gpu parallelized robotics simulation and rendering for generalizable embodied ai. *arXiv preprint arXiv:2410.00425*, 2024.
- [38] C. Li, R. Zhang, J. Wong, C. Gokmen, S. Srivastava, R. Martín-Martín, C. Wang, G. Levine, M. Lingelbach, J. Sun, et al. Behavior-1k: A benchmark for embodied ai with 1,000 everyday activities and realistic simulation. In *Conference on Robot Learning*, pages 80–93. PMLR, 2023.
- [39] X. Li, K. Hsu, J. Gu, K. Pertsch, O. Mees, H. R. Walke, C. Fu, I. Lunawat, I. Sieh, S. Kirmani, et al. Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941*, 2024.
- [40] H. Fang, M. Grotz, W. Pumacay, Y. R. Wang, D. Fox, R. Krishna, and J. Duan. Sam2act: Integrating visual foundation model with a memory architecture for robotic manipulation. *arXiv preprint arXiv:2501.18564*, 2025.
- [41] E. Cherepanov, N. Kachaev, A. K. Kovalev, and A. I. Panov. Memory, benchmark & robots: A benchmark for solving complex tasks with reinforcement learning. *arXiv preprint arXiv:2502.10550*, 2025.
- [42] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36: 44776–44791, 2023.

- [43] S. Han, B. Qiu, Y. Liao, S. Huang, C. Gao, S. Yan, and S. Liu. Robocerebra: A large-scale benchmark for long-horizon robotic manipulation evaluation. *Advances in Neural Information Processing Systems*, 38, 2026.
- [44] H. Lei, W. Song, H. Zhang, J. Pei, J. Chen, H. Yan, H. Zhao, P. Ding, Z. Zhang, L. Huang, et al. Robomemarena: A comprehensive and challenging robotic memory benchmark. *arXiv preprint arXiv:2605.10921*, 2026.
- [45] F. Xiang, Y. Qin, K. Mo, Y. Xia, H. Zhu, F. Liu, M. Liu, H. Jiang, Y. Yuan, H. Wang, et al. Sapien: A simulated part-based interactive environment. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 11097–11107, 2020.
- [46] S. Community. Starvla: A lego-like codebase for vision-language-action model developing. *arXiv preprint arXiv:2604.05014*, 2026.
- [47] M. J. Kim, C. Finn, and P. Liang. Fine-tuning vision-language-action models: Optimizing speed and success. *arXiv preprint arXiv:2502.19645*, 2025.
- [48] W. Kwon, Z. Li, S. Zhuang, Y. Sheng, L. Zheng, C. H. Yu, J. E. Gonzalez, H. Zhang, and I. Stoica. Efficient memory management for large language model serving with pagedattention. In *Proceedings of the ACM SIGOPS 29th Symposium on Operating Systems Principles*, 2023.

附录

A 事件视觉语言动作模型的实现细节

A.1 训练公式与课程策略

为获取真实关键帧监督，本文利用由通义千问视觉语言模型驱动的离线自动标注流程 [15]。通过解析原始演示视频与任务描述，该视觉语言模型提取任务关键中间事件的精确时间戳，记为 t^* 。然而，在物理机器人执行中，关键帧语义固有地存在时间模糊性——紧邻 t^* 之前或之后的帧通常同样能有效捕捉视觉证据。为防止刚性二值监督导致噪声梯度，本文利用升余弦核函数将标注平滑为软目标向量 $\mathbf{y}_t \in [0, 1]^H$ 。具体而言，对于真实事件 t^* 膨胀半径 R 内的未来步 i ，软目标定义为 y_t^i 。为监督分块关键帧预测与这些时间平滑标注的对齐，本文将关键帧证据记忆损失 L_{kem} 公式化为序列平均的二值交叉熵目标。该目标在整个未来动作时域 H 上，显式地将每个预测标量概率 $\hat{p}_t^i \in [0, 1]$ 与其对应的软目标 $y_t^i \in [0, 1]$ 对齐：

$$L_{\text{kem}} = -\frac{1}{H} \sum_{i=1}^H [y_t^i \log(\hat{p}_t^i) + (1 - y_t^i) \log(1 - \hat{p}_t^i)] \quad (6)$$

整个框架随后通过联合目标进行端到端优化，该目标将记忆感知与精确运动控制相结合：

$$L = L_{\text{action}} + \lambda L_{\text{kem}} \quad (7)$$

其中 L_{action} 表示标准的连续动作生成损失（例如回归或流匹配）， λ 作为平衡系数，用于适当缩放记忆监督。

在训练过程中，早期阶段仅依赖模型自身预测动态构建事件缓冲区 E_t 会导致严重的训练不稳定，而完全依赖真值关键帧则会引入关键的训练-测试分布偏移，因为真值关键帧在测试时不可用。为弥合这一差距，我们实施了一种有计划的教师到学生课程。我们引入一个退火参数 α ，在训练期间从 1 线性衰减到 0。在每一步，框架以概率 α 决定是否使用真值关键帧将观测提交到 E_t （教师强制），或以概率 $1 - \alpha$ 依赖自身的阈值化预测（ $\hat{p}_t^i \geq \tau_{\text{commit}}$ ）。这种渐进式过渡确保了初始收敛的稳定性，同时迫使视觉-语言-动作策略最终适应其自身的自主记忆更新节奏。

A.2 在线推理与后处理

在在线推理过程中，逐块预测 $\hat{\mathbf{p}}_t$ 自然会在展开的语义事件周围产生聚类且时间连续的高概率分数。为防止同一视觉事件的冗余帧淹没有界缓冲区 E_t ，我们通过严格的后处理提取流程将 H 维概率向量压缩为离散、稀疏的写入事件。

首先，我们通过应用置信度阈值 τ_{commit} 并结合一维非极大值抑制（NMS）算法来识别一组局部概率峰值 $\mathcal{K}_t$ 。具体而言，如果未来步骤索引 i 的概率超过阈值，并且在半径为 w 的滑动时间窗口内代表局部最大值，则将其选为候选峰值：

$$\mathcal{K}_t = \left\{ i \in \{1, \dots, H\} \mid \hat{p}_t^i \geq \tau_{\text{commit}} \wedge \hat{p}_t^i = \max_{j \in \mathcal{N}_w(i)} \hat{p}_t^j \right\} \quad (8)$$

其中 $\mathcal{N}_w(i) = [\max(1, i - w), \min(H, i + w)]$ 表示非极大值抑制邻域。

虽然非极大值抑制能有效隔离局部峰值，但快速连续的事件仍可能触发过多的内存写入。为严格保证操作稀疏性，对候选者顺序评估时间冷却期 C

。候选峰值 $i \in \mathcal{K}_t$ 当且仅当 $(t + i) - t_{\text{last}} > C$ 时才被正式验证并提交到 E_t ，其中 t_{last} 表示最近提交的关键帧的绝对物理时间戳。通过这种级联提取机制，框架在数学上将密集的预测景观提炼为最优且高度稀疏的子集。这保证了内存分配严格与新颖的交互证据相关联，在最大化信息保留的同时无缝满足实时执行约束和有界内存缓冲区大小 N_{max} 。

A.3 自动化关键帧标注流程

为规避长时程任务中密集人工帧标注带来的高昂成本，本文开发了一套由大型视觉语言模型（Large Vision-Language Models, VLMs）驱动的自动化、高度可扩展的关键帧标注流程。具体而言，本文在配备 8 块 NVIDIA A800 图形处理器的本地服务器上，利用 vLLM [48]s 框架部署了最先进的 **Qwen3-VL-235B-A22B-Instruct-FP8** [15] 模型。

数据预处理与上下文学习。为避免将难以处理的长连续视频流直接输入视觉语言模型，本文将时间范围均匀采样为离散帧集合（例如，每个回合 128 帧）。为确保稳健的空间感知能力，尤其是在存在严重遮挡的场景中，本文对每个采样时间步提取并拼接多视角观测（例如，全局头部相机和腕部相机）。关键之处在于，为使视觉语言模型的输出与本文对瞬态视觉证据的特定定义保持一致，本文采用了上下文学习

（In-Context Learning, ICL）策略。提示中包含来自相同或相似任务的少样本演示，其中包含采样帧及其真实关键帧步骤，为时间对齐和 JSON 格式输出建立了严格的模板。

自动化流程所使用的确切系统提示如下所示：

System Prompt for VLM-based Keyframe Annotation

System Prompt:

You are an expert robot-video keyframe annotator.

CRITICAL REQUIREMENT:

- The annotation MUST strictly follow `task_instruction`.
- Treat `task_instruction` as the primary objective definition; if visuals are ambiguous, prioritize consistency with it.

Episode metadata:

- `episode_id`: `<episode_id>`
- `task_instruction`: `<task_instruction>`
- `total_frames`: `<total_frames>`
- `required_keyframe_count`: `<num_keyframes>`
- `provided_views`: `<selected_views>`

What to annotate:

1. Find key state transitions for this task (e.g., stable grasp acquired, object placed, cycle transition).
2. Keep keyframes representative and temporally ordered across the full task progress.
3. For repeated pick/place cycles, pick the most stable and recognizable moments per cycle.

Output format constraints:

1. Return JSON only. No markdown, no explanations.
2. Format: `{ "keyframe_steps": [int, int, ...] }`
3. `keyframe_steps` must:
 - have length exactly `<num_keyframes>`
 - be strictly increasing
 - be in `[0, <total_frames - 1>]`
 - contain no duplicates

标注可靠性与误差分析。为严格验证该自动化流程的可靠性，本文进行了全面的交叉验证研究。在仿真环境中，本文将 Qwen3-VL-235B 模型自动标注的关键帧与直接从 RoboTwin 2.0 [35] 物理引擎获取的精确算法真实状态进行了比较。结果表明，视觉语言模型的预测平均绝对时间误差小于 10 个时间步。此外，在四个复杂的真实世界双臂任务中部署时，与人工标注的真实值相比，预测误差保持在 50 个时间步以内。鉴于本文的评估回合具有极长的时程（通常超过 1500 至 2000 步），这种可忽略的时间方差（由本文的时间平滑软

标签自然容纳) 有力地证实了本文由视觉语言模型驱动的自动化标注流程具有高度可靠性、精确性, 并已准备好进行可扩展部署。

B 实验设置与基准

B.1 RoboTwin-MeM 基准详情

表 4: 我们提出的 RoboTwin-MeM 基准的详细统计。

Task Name	Episodes	Avg. #Steps	Intermediate Keyframes	Task Instruction
Press Button Keyframe	50	430	[2,5]	Read the two number cards, press the left button as many times as the left card shows, press the middle button as many times as the right card shows, then press the right button once.
Pick the Unhidden Block	50	699	3	Open the covers one by one to identify the hidden colors, close them after inspection, then pick up the visible block whose color is not hidden.
Rearrange Blocks Hard	50	879	1	Move a chosen block from its mat to the center and press the button, return the same block to its mat and press again, then move the other block to the center and press once more.
Pick Objects in Order	50	1124	3	Open the covers one by one to observe the objects inside, close them after inspection, then pick up the objects in the observed order.
Find Seal and Seal Stamp	50	1338	[1,4]	Open the covers one by one to find and take out the seal, close the cover after inspection, stamp with it, then return it under its original cover.
Reproduce Route	50	1417	4	Move the center red block to the four blue pads in a random order, returning it to the center. Then use the outside red block to repeat the same pad order.
Put Back Block Hard	50	1468	2	For each row, move the center block to a randomly selected outer pad in the same row, move the arm back, return the block to the center, move the arm back again, and press the button. Finally, move both blocks back to the same outer pads they first visited, then press the button.
Cover Blocks Hard	50	1544	4	Open the covers one by one, close them after inspection, then reopen them in the order: red, green, blue, yellow.

如正文第 4 节所述, RoboTwin-MeM 是一个诊断性仿真套件, 专门设计用于隔离和评估真正非马尔可夫的机器人操作。与工作空间状态持续可见的传统长时域环境不同, RoboTwin-MeM 强制执行严格的视觉遮挡和时间延迟。在这些任务中, 关键的视觉证据, 例如方块的隐藏颜色、遮盖物下物体的身份, 或随机生成的空间序列, 仅在中间交互过程中短暂显现, 随后便完全不可观测。

为了系统地量化记忆容量, RoboTwin-MeM 涵盖了 8 个复杂的双臂操作任务, 具有极长的执行时域, 平均每回合 430 至 1,544 步。每个任务的难度由 $n \in [1, 5]$ 显式参数化, 该参数定义了




图 5: EventVLA 在四个操作任务上的扩展真实世界执行序列。策略自主捕获并提交到记忆中的任务关键中间关键帧以蓝色边框突出显示。

机器人必须自主捕获并保留以成功完成指令的中间关键帧事件的确切数量。

例如，诸如 Cover Blocks Hard ($n = 4$) 和 Pick Objects in Order ($n = 3$) 等记忆密集型任务要求机器人抬起不透明遮盖物以检查隐藏属性，在遮盖物关闭后记住这些属性，并基于存储的记忆执行后续的抓取和放置动作。类似地，Press Button Keyframe 要求机器人读取随机数字卡片，并将其转化为顺序计数和按压逻辑。如图 3 所示，这些瞬态的、交互驱动的关键帧（以蓝色边框突出显示）充当了过去观察与未来动作之间的关键信息桥梁。

综合任务统计信息，包括平均步数、所需中间关键帧数量 n ，以及所有 8 项评估任务的具体语言指令，详见

表 4。

B.2 真实世界任务详情

为补充图 4 中提供的单帧任务概览，图 5 展示了四个真实世界操作任务的逐步时序扩展序列。这些完整的执行过程精确说明了在物理交互过程中瞬态视觉证据何时出现。任务关键中间关键帧（策略必须自主捕获并提交至其动态事件缓冲区，例如短暂暴露隐藏方块、读取随机数字或观察由指示棒指出的特定序列）均以蓝色边框明确高亮。通过成功隔离并保留这些稀疏状态，EventVLA 有效弥合了非马尔可夫控制所需的时间间隔。

B.3 网络架构与超参数

对于 RMBench 和 RoboTwin-MeM，我们的 EventVLA 框架构建于开源的 QwenOFT[46] 架构之上，该架构以 Qwen3-VL-4B-Instruct 作为基础视觉-语言模型（VLM）。视觉观测在输入视觉编码器之前被调整为 224×224 。

在训练阶段，整个框架使用 AdamW 优化器进行端到端优化，共训练 80,000 步。我们采用差异化学习率策略以确保稳定收敛：预训练的 VLM 骨干网络以较低学习率 1×10^{-5} 进行微调，而新初始化的组件（动作头和关键帧证据记忆预测头）以较高学习率 1×10^{-4} 进行训练。所有任务的动作预测范围（ H ）设置为 50 步。

为明确反映所评估基准的不同内存需求，我们对内存模块进行了差异化配置。对于主要评估基础视觉锚定且无需中间瞬态内存的 **RMBench**，策略仅使用初始和短期视觉锚进行训练。**RMBench** 的详细网络架构和训练超参数总结于表 5。

表 5: RMBench 的网络架构与训练超参数。

Configurations	Values
<i>Network Architecture</i>	
Base VLM	Qwen3-VL-4B-Instruct
Action Model Type	Optimized Fine-Tuning (OFT)
Action Dimension	14
Action Horizon (H)	50
Image Resolution	224×224
<i>Training Hyper-parameters</i>	
Optimizer	AdamW
Training Steps	80,000
Base VLM Learning Rate	1×10^{-5}
Action Head Learning Rate	1×10^{-4}
Per-Device Batch Size	4
Gradient Accumulation Steps	1
Memory Module Status	Visual Anchors Only
Visual Anchors A_t	o_0, o_{t-30}, o_{t-15}

Conversely, for the strictly non-Markovian

RoboTwin-MeM，则激活完整的键帧证据

内存（Keyframe Evidence Memory, KEM）

模块。为确保早期训练稳定性并弥合训练与

测试分布偏移，我们采用教师到学生的课程

式调度，其中教师强制概率 α 在训练期间从 1.0 线性衰减

至 0.0。如表 6 所述，我们还引入了特定超参数来管理在线内存提取流程。

分块键帧预测使用提交置信度阈值 $\tau_{\text{commit}} = 0.55$ 进行过滤。为强制严格的

内存稀疏性，我们应用半径为 $w = 8$ 的一维非极大值抑制

（Non-Maximum Suppression, NMS）滑动窗口，并在连续内存写入之间设置

$C = 10$ 步的时间冷却期。最后，动态事件缓冲区的最大容量限制为

$N_{\text{max}} = 5$ ，采用先进先出（FIFO）淘汰策略以满足实时计算约束。

为在真实机器人平台上进行物理部署，我们调整框架，利用 $\pi_{0.5}$ [1] 作为基础视觉-语言-动作模型。动作头配置为在 $H = 50$ 步的视野内预测 32 维连续动作。在真实世界演示上进行微调时，整个框架使用 AdamW 优化器以 bfloat16 精度联合优化 60,000 步，全局批大小为 32。基础视觉语言模型（VLM）和新初始化头均采用 5×10^{-5} 的统一峰值学习率，遵循余弦衰减调度，包含 2,000 个预热步骤。为在物理执行期间管理键帧证据内存（KEM）模块，我们保持提交置信度阈值 $\tau_{\text{commit}} = 0.55$ 、最大事件缓冲区容量 $N_{\text{max}} = 5$ 、NMS 时间窗口半径 $w = 8$ 以及提交冷却期 $C = 10$ 。键帧损失权重 λ 设为 0.1，同时采用教师到学生的课程式调度，其中 α 从 1.0 线性衰减至 0.0。真实世界任务的综合网络架构和训练细节总结于表 7。

表 6: RoboTwin-MeM 的网络架构与 KEM 超参数。

Configurations	Values
<i>Network Architecture & Basic Training</i>	
Base VLM	Qwen3-VL-4B-Instruct
Action Model Type	Optimized Fine-Tuning (OFT)
Action Horizon (H)	50
Optimizer	AdamW
Training Steps	80,000
Base VLM Learning Rate	1×10^{-5}
KEM & Action Head Learning Rate	1×10^{-4}
Per-Device Batch Size	4
Gradient Accumulation Steps	1
<i>Keyframe Evidence Memory (KEM) Settings</i>	
Memory Module Status	Full EventVLA (VA + KEM)
Visual Anchors A_t	o_0, o_{t-30}, o_{t-15}
Teacher-Forcing Annealing (α)	Linear decay ($1.0 \rightarrow 0.0$)
Commit Confidence Threshold (τ_{commit})	0.55
Max Event Buffer Size (N_{max})	5
NMS Temporal Window Radius (w)	8
Commit Cooldown Period (C)	10
Keyframe Loss Weight (λ)	0.1

表 7: 真实机器人实验的网络架构与密钥封装机制 (KEM) 超参数。

Configurations	Values
<i>Network Architecture & Basic Training</i>	
Base VLM	PaliGemma ($\pi_{0.5}$)
Image Resolution	224×224
Text Sequence Length	200
Action Horizon (H)	50
Action Dimension	32
Optimizer	AdamW
Optimizer Hyper-parameters	$\beta_1 = 0.9, \beta_2 = 0.95, eps = 1e - 8$
Weight Decay	0.01
Training Steps	60,000
Warm-up Steps	2,000
Base VLM Learning Rate	5×10^{-5}
KEM & Action Head Learning Rate	5×10^{-5}
Minimum Learning Rate	5×10^{-6}
Learning Rate Schedule	cosine decay with minimum LR
Global Batch Size	32
Numerical Precision	bfloat16
<i>Keyframe Evidence Memory (KEM) Settings</i>	
Memory Module Status	Full EventVLA (VA + KEM)
Visual Anchors A_t	$o_0, o_{t-60}, o_{t-40}, o_{t-20}$
Teacher-Forcing Annealing (α)	linear decay ($1.0 \rightarrow 0.0$)
Commit Confidence Threshold (τ_{commit})	0.55
Max Event Buffer Size (N_{max})	5
NMS Temporal Window Radius (w)	8
Commit Cooldown Period (C)	10
Keyframe Loss Weight (λ)	0.1

C 扩展实验结果与分析

表 8: RMBench 基准测试结果。（**粗体**: 最优; 下划线: 次优）。

Tasks	Observe and Pick Up	Rearrange Blocks	Put Back Block	Swap Blocks	Swap T	Battery Try	Blocks Ranking Try	Cover Blocks	Press Button	Total average
▼ Non Memory-based Vision-language-action Models:										
DP	1%	0%	0%	11%	20%	10%	10%	0%	0%	5.8%
ACT	1%	29%	0%	2%	2%	19%	0%	0%	0%	5.9%
$\pi_{0.5}$	9%	13%	11%	24%	15%	16%	6%	0%	0%	10.4%
X-VLA	9%	13%	18%	16%	3%	26%	1%	2%	0%	9.8%
QwenOFT	0%	0%	0%	0%	0%	14%	37%	0%	0%	5.6%
▼ Dual-system Memory-based Vision-language-action Models:										
MemER	7%	17%	0%	14%	7%	27%	0%	6%	0%	8.7%
Mem-0	4%	89%	90%	67%	14%	28%	18%	68%	0%	42.0%
▼ End-to-end Memory-based Vision-language-action Models:										
MemoryVLA (OpenVLA)	0%	22%	50%	17%	9%	25%	12%	40%	0%	19.4%
MemoryVLA (QwenOFT)	2%	53%	81%	<u>76%</u>	9%	33%	53%	<u>69%</u>	0%	41.7%
EventVLA (w/o initial)	10%	64%	63%	16%	8%	39%	87%	15%	<u>2%</u>	33.7%
EventVLA (w/o short-term)	15%	34%	20%	18%	94%	16%	14%	4%	0%	23.8%
EventVLA (visual anchors only)	21%	96%	95%	96%	<u>87%</u>	<u>35%</u>	<u>81%</u>	97%	3%	67.8%

C.1 RMBench 逐任务详细分解

由于正文篇幅所限，本文在表 8 中给出了 RMBench 套件上所有基线和消融模型的全面任务级细分结果，该表是表 1 按任务展开的版本。

详细的分解清晰地表明，我们精简的配置，即仅使用视觉锚点的 EventVLA，在绝大多数任务上显著优于无记忆和先前的记忆增强基线。值得注意的是，在记忆密集型的结构操作任务上，如重新排列积木（96%）、放回积木（95%）、交换积木（96%）和覆盖积木（97%），EventVLA 达到了接近完美的成功率。这表明我们基于规则的视觉锚定机制有效地捕捉了传统面向记忆场景所需的持久空间布局和固定运动风格，而无需复杂的状态压缩。此外，消融变体（无初始锚点和无短期锚点）在几乎所有任务上都表现出严重的性能下降，证实了初始全局空间参考和短期运动线索都是视觉锚点不可或缺的组成部分。

C.2 扩展消融分析与推理效率

扩展消融分析。为深入理解关键帧证据记忆（Keyframe Evidence Memory, KEM）模块中各个设计选择的贡献，我们在 RoboTwin-McM 套件上扩展了消融实验（总结于正文第 5.2 节和表 2）。

- **记忆表示（显式图像与隐式记忆库）**：在隐式记忆库变体中，捕获的关键帧被聚合为压缩的潜在嵌入，而非作为显式原始图像追加。当处理需要保留多个不同事件的复杂任务时（例如， $n \geq 3$ ），将不同的历史特征压缩到单个潜在向量中会造成严重的信息瓶颈。显式原始图像拼接避免了这种有损压缩，为视觉语言动作模型的多帧注意力机制提供了完整、无损的上下文证据。

- **监督策略（软标签与硬标签）**：物理关键帧事件自然跨越连续的时间窗口。用严格的二值目标替换我们的升余弦软标签会导致极端的标签稀疏性，并严重惩罚有效的相邻帧。这种僵化的监督会破坏预测头部的稳定性，最终导致其无法触发必要的记忆写入。软标签为在具有执行方差的环境中实现鲁棒的事件捕获提供了必要的时间容差。

- **缓冲区管理（非极大值抑制（NMS）和容量的必要性）**：如果没有一维非极大值抑制（NMS）后处理算法，冗余的相邻帧

表 9: EventVLA 推理速度的消融研究。延迟表示生成每个块所需的平均时间（秒/块），而吞吐量表示每秒生成的平均块数（块/秒）。

Tasks		n=1	n=2	n=3		n=4		n=5	Total average
		Rearrange Blocks Hard	Put Back Block Hard	Pick Objects in Order	Pick the Unhidden Block	Cover Blocks Hard	Find Seal Stamp	Reproduce Route	Press Button Keyframe
QwenOFT	Latency	0.31	0.36	0.36	0.39	0.41	0.39	0.30	0.32
	Throughput	3.21	2.82	2.82	2.56	2.57	2.62	3.46	3.20
EventVLA (visual anchors only)	Latency	0.92	0.78	1.08	0.83	1.05	1.02	0.95	1.08
	Throughput	1.11	1.35	0.93	1.21	0.96	1.02	1.07	0.94
EventVLA (VA+KEM)	Latency	0.90	0.88	1.20	0.97	1.22	1.11	1.25	1.22
	Throughput	1.13	1.16	0.84	1.03	0.83	0.92	0.81	0.83

迅速淹没有界动态事件缓冲区。相反，严格最小的缓冲区 (e.g., $N_{\max} = 2$) 本质上缺乏复杂多阶段任务所需的结构容量。两种情况都会导致缓冲区过早饱和，并触发早期先进先出 (FIFO) 驱逐，从而在基础历史证据（如首次观察到的隐藏颜色）被利用之前就错误地将其丢弃。这凸显了非极大值抑制 (NMS) 驱动的事件稀疏性与充足的内存容量都至关重要。

- **前瞻视野（动作块大小的影响）**：执行块大小决定了键事件记忆 (KEM) 的前瞻窗口。缩小这一视野会截断模型的预测能力，使关键帧头无法有效预测和调度即将到来的瞬态事件，从而抵消 KEM 主动记忆承诺的能力。

推理效率。为验证事件视觉语言动作 (EventVLA) 模型能够有效部署在实体机器人上，我们细致评估了其实时推理速度。表 9 详细列出了我们的框架在 RoboTwin-MeM 基准上的延迟和吞吐量。

纯反应式 QwenOFT 基线实现了平均 2.91 赫兹的吞吐量和 0.36 秒的延迟。引入外部视觉锚点会因扩展的多帧输入序列而略微增加计算开销，导致平均吞吐量为 1.07 赫兹。当部署完整的 EventVLA 框架（包含动态 KEM）时，其平均吞吐量维持在 0.94 赫兹（延迟 1.09 秒）。鉴于视觉语言动作 (VLA) 策略通常作为高层规划器与低层高频控制器协同工作，这一吞吐量完全满足现实世界机器人部署的操作约束。这证实了我们的稀疏记忆承诺策略在鲁棒的非马尔可夫推理与实用的实时执行效率之间取得了最佳平衡。

D 定性可视化

D.1 RoboTwin-MeM 中的仿真推演

为了直观理解 EventVLA 的动态记忆调度与执行过程，本文可视化了 RoboTwin-MeM 基准中全部 8 个严格非马尔可夫任务的定性运行轨迹。图 6 展示了四个记忆密集型任务的成功执行序列：困难重排积木、拾取未隐藏积木、困难放回积木和困难覆盖积木。图 7 展示了其余四个任务的执行流程：按键关键帧、按顺序拾取物体、寻找印章并盖章以及复现路径。

在这些多样化的场景中，可视化结果清晰地展示了 KEM 模块如何在瞬态视觉证据出现的精确时刻主动触发稀疏记忆写入（例如，在提起不透明盖子后立即观察积木的隐藏颜色，或读取随机机数字）。通过在关键中间状态变得不可观测之前将其锁定到事件缓冲区中，EventVLA 有效地弥合了时间间隙，并无缝引导后续的长时程操作。



图 6: EventVLA 在四个 RoboTwin-MeM 仿真任务上的定性运行轨迹：困难重排积木、拾取未隐藏积木、困难放回积木和困难覆盖积木。

D.2 真实世界机器人执行序列

为了进一步验证本文框架的实用有效性，提供了部署在真实 ARX ACONE 双臂机器人上的 EventVLA 的定性执行序列。图 8 展示了四个记忆密集型操作任务的成功完成：简单寻找积木、拾取 X 次、困难寻找积木和按顺序拾取。

可视化结果表明，尽管存在真实世界遮挡和随机空间布局，EventVLA 仍能稳健地捕获并保留关键的中间视觉线索。无论是从纸上读取随机数字以决定计数逻辑，还是观察指向瓶子的棍子以记忆上下文序列，该策略都成功地利用了其稀疏视觉证据记忆





图 7: EventVLA 在其余四个 RoboTwin-MeM 仿真任务上的定性运行轨迹：按键关键帧、按顺序拾取物体、寻找印章并盖章以及复现路径。

来执行复杂的多阶段物理任务，展现出强大的非马尔可夫记忆能力和空间泛化能力。


寻找方块（简单）： 用最近的杯子盖住方块，然后拿起盖住方块的杯子并拾取方块。



按指定次数拾取： Pick up and put down the block the number of times as shown on the paper.



寻找方块（困难）： 从左到右依次拿起桌上的杯子，检查下方是否藏有方块，然后放下杯子。最后，打开藏有方块的杯子并拾取方块。



按顺序拾取： 按照开始时棍子依次指向的顺序，逐一拿起并放下桌上的瓶子。



图 8：EventVLA 在四个任务上的定性真实世界机器人执行序列：寻找方块（简单）、寻找方块（困难）、按指定次数拾取和按顺序拾取。