

四种动作头到底是什么：FAST / OFT / PI / GR00T

从“VLM 输出 token”到“机器人要连续高频动作块”的四条路线

awesome_starvla 讲解模块 · 配套讲稿 reports/08

github.com/asimfish/awesome_starvla

2026 年 9 月

问题：VLM 会输出 token，机器人要的是连续、高频、多维的动作块

VLA = 看懂场景听懂指令的 VLM + 把表征变成控制量的动作头。动作头面对三个难点：

- **连续**：关节角、末端位姿、夹爪都是实数，VLM 原生输出是离散 token
- **高频且成块**：一次输出未来 H 步 $(8\sim50) \times D$ 维 $(7\sim14+)$ 个实数，10~50 Hz
- **多模态分布**：同一状态多种合理动作，点估计会取平均

路线	一句话
FAST OFT	不改 VLM，把动作块压缩成一串离散 token，像生成文字一样生成动作 在 VLM 末尾拼占位 token，小 MLP 把隐状态直接回归成连续动作，一次前向出整块
PI (π_0) GR00T	给 VLM 配独立权重的“动作专家”，用 flow matching 从噪声逐步生成动作块 同样 flow matching，但放进可独立高频运行的 DiT“快系统”，VLM 作“慢系统”只给条件

记号	含义
o_t	观测：多视角 RGB + 语言指令（部分头含本体状态 s_t ）
$A_t = (a_t, \dots, a_{t+H-1}), a \in \mathbb{R}^D$	动作块， H 为块长， D 为动作维度
H_t / z	VLM 隐状态序列 / 交给动作头的潜表征
$\tau \in [0, 1]$	flow matching 的“时间”，与机器人时刻 t 无关
$\epsilon \sim \mathcal{N}(0, I)$	与 A_t 同形状的高斯噪声

四个头的共同任务： $(o_t) \xrightarrow{\text{VLM}} H_t \xrightarrow{\text{动作头}} A_t$ 。区别只在最后一个箭头。

- 每个头讲四件事：想解决什么 · 核心机制 · 训练与推理 · 在 StarVLA 代码里长什么样
- 材料：四篇原论文 + 中译 PDF (FAST / OFT / GR00T N1 已入库, π_0 因许可只放链接)

FAST: 为什么“每步每维分箱”在高频数据上失效

朴素做法 (RT-2 / OpenVLA): 每个时刻、每个维度 256 个箱, 一箱一 token。7 维 $\times$ 50 步 = 350 个 token。**玩具实验的结论**: 同一条平滑曲线, 采样频率越高, 自回归模型的预测误差越大, 最终退化为**复制上一个 token**。**原因**: 自回归的学习信号 = 给定前文后下一个 token 的**边际信息**。信号平滑时, 相邻两步差别随频率升高而趋近零, token 序列高度冗余, 模型学不到东西。


直觉: JPEG

像素在空间上平滑 $\Rightarrow$ DCT 后能量集中在低频 $\Rightarrow$ 丢掉小系数就是压缩。

动作在时间上平滑 $\Rightarrow$ 对每个维度的时间序列做同样的事。

Pertsch et al., arXiv 2501.09747 (Physical Intelligence, 2025-01)

FAST: 五步流水线, 唯一要训练的是 BPE




$$\mathcal{L}_{\text{FAST}} = - \sum_{m=1}^M \log p_{\theta}(z_m | H_t, z_{<m}), \quad z_{1:M} = \text{Tok}_{\text{FAST}}(A_t)$$

- 1 秒动作块 $\approx$ 30 个 token/臂, 覆写 VLM 词表中最少用的 token
- 架构、训练目标完全不变: next-token 交叉熵
- FAST+: 约 100 万条真实轨迹训练的通用 tokenizer
- 训练 GPU 小时比 diffusion 版 π_0 少约 5 $\times$; DROID 15 Hz 首个零样本评测
- 推理慢: 几十个 token 自回归解码; 可能解出非法序列需兜底
- StarVLA: QwenFast, 2048 个 action token 占词表区间, generate() 后解码

OFT: 把三件显而易见的事一起做对

起点: OpenVLA (7B) 每步 7 个 token 串行解码, 3~5 Hz; ALOHA 需要 25 Hz。作者系统比较生成方式 / 动作表示 / 学习目标三组选择。



$$\hat{a}_{t+k} = g_{\phi}(h_{t,k}^{\text{act}}), \quad \mathcal{L}_{\text{OFT}} = \frac{1}{Kd_a} \sum_{k=0}^{K-1} \|\hat{a}_{t+k} - a_{t+k}\|_1$$

- **并行解码:** $K \times D$ 次串行前向 $\rightarrow$ 1 次; **动作块:** 多放 K 组占位, 吞吐 $\times K$ 、延迟几乎不变
- **连续 + L1:** 不再 softmax 选箱; 作者试过 diffusion 目标, 成功率相当而 L1 简单得多
- **FiLM (OFT+):** 多视角下策略忽略语言 $\Rightarrow$ 用语言嵌入对视觉特征做缩放/偏置

结果 (Kim, Finn, Liang, arXiv 2502.19645)

LIBERO 四套件平均 (原版 OpenVLA 76.5)	97.1
动作生成吞吐	26×
ALOHA 25 步块吞吐	43×

- 真机 ALOHA 双臂: 超过默认配方微调的 π_0 、RDT-1B, 以及从零训练的 ACT、Diffusion Policy
- LIBERO 用 $K=8$, ALOHA 用 $K=25$ (25 Hz 下的一秒)

StarVLA: QwenOFT.py

- 指令末尾拼”预测接下来 N 个动作”+ N 个占位字符
- 取最后一层隐状态中这 N 个位置 $\rightarrow$ 两层残差 MLP ($H \rightarrow 2H \rightarrow D$)
- 带 mask 的 L1: $(|\hat{a} - a| \cdot m).sum() / m.sum()$
- 单次前向; StarVLA- α 与 VLAct 的默认头

边界

输出是点估计: 多解任务会取平均。但在数据充足或低数据 + 强扰动下都不输生成式头 (RoboTwin Base/Random: OFT 41.5 vs GR00T 22.9)。

flow matching 的最小版本：把一团噪声”搬”到一段轨迹

在真实动作块 A 与噪声 ϵ 之间画一条直线，用 τ 标记位置：

$$A^\tau = \tau A + (1 - \tau) \epsilon, \quad u = A - \epsilon \quad (\text{沿直线每单位}\tau\text{的位移, 是常数})$$

训练网络 v_θ 预测这个位移（速度场），推理从噪声出发沿场走 N 步：

$$\mathcal{L} = \mathbb{E}_{A, \epsilon, \tau} \|v_\theta(A^\tau, \tau; o_t) - (A - \epsilon)\|_2^2, \quad A^{\tau+\delta} = A^\tau + \delta v_\theta(A^\tau, \tau; o_t)$$

两个实践细节

- τ 不均匀采样，从偏向小 τ （更接近噪声）的 Beta 分布采：多练”从很糟的起点纠正”
- 整个块一起去噪，块内双向注意力， H 步动作相互协调

与 diffusion 的关系

- 同一族：diffusion 预测噪声，flow matching 预测位移
- 直线路径，公式与采样更简单、步数更少（ π_0 10 步，StarVLA 4 步）
- StarVLA 里 PI 与 GR00T 两个头共用这一目标

动作专家 (action expert)

- 与 VLM 走同一个 transformer 的注意力，但**独立一套权重**，只处理状态与动作 token
- 相当于两成员的 MoE：按 token 类型路由权重；动作 token 的统计性质与语言差异太大
- PaliGemma 3B + 从零初始化的约 3 亿参数 = 3.3B
- $H = 50$ ，最高 50 Hz；推理 10 步前向欧拉

训练配方


- 预训练：约 1 万小时自有灵巧操作数据（7 种本体、68 任务）+ OXE
- ”广而杂”的预训练教纠错，”精而顺”的后训练教流畅，缺一不可

StarVLA: QwenPI_v3.py

- Qwen3-VL 最后 36 层隐状态各经 LayerNorm+Linear $\rightarrow$ 1024 维，逐层 cross-attn 到 36 层 DiT
- 状态量化 256 桶写进文本；Beta(1.5,1) 变换采样 τ ；4 步欧拉
- 4.44B 骨干 + 5.39 亿 DiT + 0.95 亿投影

Black et al., arXiv 2410.24164 (Physical Intelligence, 2024-10); VLAAct 表 8: OFT 单头预训练让 PI 微调 60.5 $\rightarrow$ 55.1

GR00T N1: 双系统里的 flow matching



$$\mathcal{L}_{\text{GR00T}} = \mathbb{E} \left\| v_{\theta}(A^{\tau}, \tau; H_t, s_t, e) - (A - \epsilon) \right\|_2^2 \quad (\text{比 } \pi_0 \text{ 多了状态 } s_t \text{ 与本体标识 } e)$$

- 总参数 2.2B; L40 上一块 16 步动作 63.9 ms; 两系统端到端联合训练, 推理可异步
- **数据金字塔**: 网页 / 人类视频 $\rightarrow$ 合成神经轨迹与仿真 $\rightarrow$ 真机; 无动作标签的视频用 VQ-VAE 学潜动作, 当作一种额外本体 (LAPA) 用同一 loss 训练

Bjorck et al., arXiv 2503.14734 (NVIDIA, 2025-03)

π_0 与 GR00T 的差别，以及 StarVLA 的复刻

	π_0 的动作专家	GR00T 的 System 1
与 VLM 的耦合 取哪层特征 运行频率 状态与本体	同一注意力、独立权重 (MoE 式) 与 VLM 逐层交互 与 VLM 同步 状态 token 进专家	独立 DiT, cross-attention 读 VLM 特征 单层 (论文第 12 层; StarVLA 用末层) 可异步, System 1 远快于 System 2 状态 + 本体标识经本体特定 MLP 进 DiT
块长 / 步数 跨本体	$H = 50$, 10 步 统一填充动作空间	$H = 16$, 4 步 每本体一对编解码 MLP

StarVLA: QwenGR00T.py——Qwen3-VL 最后一层隐状态作 cross-attn 的 K/V; DiT-B (768 维、12 头) 16 层交替 self/cross; 状态经 MLP 编码后拼在序列最前; 4 步欧拉; 每样本重复 8 次噪声 (repeated_diffusion_steps=8)。VLA 多头版以 state_dim: 0 构建、状态改走文本, 便于混合本体 batch。

- “取第 12 层而非末层”与 VLA 冻结下半层保护低层视觉表征”是同一件事的两面

横向对比：五个维度一眼分清四个头

维度	FAST	OFT	PI (π_0)	GR00T
与 VLM 的接口	复用词表, 动作 = token	占位 token 隐状态 $\rightarrow$ MLP	独立权重的动作专家	独立 DiT, cross-attn 读 VLM
动作表示	离散 (DCT + BPE)	连续, 点估计	连续, 分布	连续, 分布
训练目标	next-token 交叉熵	L1	flow matching MSE	flow matching MSE + 状态 / 本体条件
推理	自回归几十个 token	一次前向	N 步欧拉 (10 / 4)	N 步欧拉 (4)
新增参数	0	一个小 MLP	≈ 3 亿 (π_0)	DiT-B 16 层 + 本体 MLP
多模态动作分布	可以	不能	可以	可以
跨本体	统一 tokenizer	零填充 / mask	统一填充	本体特定 MLP
StarVLA 类	QwenFast	QwenOFT	QwenPI_v3	QwenGR00T

同一骨干、同一数据下的数字，以及两条边界

StarVLA- α 表 2 (Qwen3-VL-4B)	LIBERO avg	WidowX	RoboTwin clean*	RoboCasa-GR1
FAST	97.8	35.6	72.5	45.0
OFT (MLP)	98.8	64.6	88.2	53.8
PI	98.1	65.9	88.1	48.9
GR00T	98.7	65.3	88.0	52.8

- 离散头明显落后 (WidowX -29、RoboTwin -16)；三种连续头在数据充足时相当

VLAct 补的两条边界

- 低数据 + 强扰动：回归头领先生成式头 18 点 (RoboTwin Base/Random: OFT 41.5 vs GR00T 22.9 / PI 23.7)
- decoder lock-in: 单头预训练的骨干换头微调反而低于从零 (PI 60.5 $\rightarrow$ 55.1)；至少两个连续头共监督才得到对头不敏感的骨干 (+GR00T 头后 63.1)

选型：先问四个问题

你的情况	选	理由
单臂、几百条示教、求简单 任务有明显多解（从哪一侧抓）	OFT PI / GR00T	实现最小、推理最快、成功率不输 回归头输出条件均值，会落在两解之 间
只能复用现成 VLM，不加任何模块	FAST	唯一不改架构，接受推理慢与 15~30 点代价
多本体、要状态输入、运动模块独立部署	GR00T	状态与本体标识进 System 1，DiT 可 独立更新加速
做持续预训练、交付骨干给别人	≥ 2 个连续头共 监督	VLAct 表 8：单头 -5.4，双头 +2.6
关节角控制	任何头 + wrap- aware loss	VLAct 表 10：+5 点，零成本

常见问题：flow matching 与 diffusion 是同一族（预测位移 vs 预测噪声，直线路径更简单、步数更少）；GR00T 取 VLM 第 12 层是因为中间层保留更多空间细节。

三个 takeaway 与阅读顺序

- ① 四个头是同一个箭头 $H_t \rightarrow A_t$ 的四种写法：token 化、回归、生成、分离的生成。接口不同，任务相同。
- ② 连续 $\gg$ 离散，连续头之间在数据充足时相当；边界在低数据强扰动（回归领先）和骨干可复用性（需多头）。
- ③ 头的选择会反过来塑造骨干：单头预训练造成 decoder lock-in，这是 VLAct 多头共监督的出发点。

阅读顺序（中译 PDF 在 papers/zh/）

- ① OpenVLA-OFT §IV：三组设计决策的对照实验最直观
- ② FAST §IV-V：玩具实验 + 算法 1
- ③ π_0 §IV 与附录 B：只看公式与图 3（arXiv 非独占许可，仓库只放链接）
- ④ GR00T N1 §2 与 §3.1：模型、数据金字塔、潜动作
- ⑤ 回到 StarVLA 四个框架文件对照代码（reports/02 第 4 章）

References



K. Pertsch et al. *FAST: Efficient Action Tokenization for Vision-Language-Action Models*. arXiv:2501.09747, 2025.



M. J. Kim, C. Finn, P. Liang. *Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success*. arXiv:2502.19645, 2025.



K. Black et al. π_0 : *A Vision-Language-Action Flow Model for General Robot Control*. arXiv:2410.24164, 2024.



J. Bjorck et al. *GR00T N1: An Open Foundation Model for Generalist Humanoid Robots*. arXiv:2503.14734, 2025.



Y. Lipman et al. *Flow Matching for Generative Modeling*. arXiv:2210.02747, 2022.



M. J. Kim et al. *OpenVLA: An Open-Source Vision-Language-Action Model*. arXiv:2406.09246, 2024.



J. Ye et al. *StarVLA- α : Reducing Complexity in Vision-Language-Action Systems*. arXiv:2604.11757, 2026.



S. Yang et al. *Beyond Data Scaling: Representation-Centric Continued Pre-training for VLA Models*. arXiv:2608.27550, 2026.

谢谢

讲稿全文: `reports/08_action_heads_lecture.md`

仓库: `https://github.com/asimfish/awesome\_starvla`

备份页

头	前向	损失
FAST	$z_{1:M} = \text{BPE}(\text{round}(\gamma \text{DCT}(\text{norm}(A))))$	$-\sum_m \log p_\theta(z_m \mid H_t, z_{<m})$
OFT	$\hat{a}_{t+k} = g_\phi(h_{t,k}^{\text{act}})$	$\frac{1}{Kd_a} \sum_k \ \hat{a}_{t+k} - a_{t+k}\ _1$
PI	$A^\tau = \tau A + (1 - \tau)\epsilon$; 推理 $A \leftarrow A + \delta v_\theta$	$\mathbb{E} \ v_\theta(A^\tau, \tau; o_t) - (A - \epsilon)\ _2^2$
GR00T	同 PI, 条件多 s_t, e ; 本体 MLP 编解码	$\mathbb{E} \ v_\theta(A^\tau, \tau; H_t, s_t, e) - (A - \epsilon)\ _2^2$

π_0 原文写 $\tau A + (1 - \tau)\epsilon$, VLAct 写 $(1 - \tau)\epsilon + \tau A$, 是同一条直线。

Backup: StarVLA 中四个头的实现细节

类	实现
QwenFast	动作 $\rightarrow$ physical-intelligence/fast tokenizer $\rightarrow$ <robot_action_k> 字串进 assistant 回合; loss = VLM next-token CE; generate() 后按 2048 个 action token 的 id 区间抽出解码
QwenOFT	指令尾拼 N 个 占位; 取 hidden_states[-1] 对应位置 $\rightarrow$ MLPResNet(2 块, $H \rightarrow 2H \rightarrow D$); masked L1
QwenPI_v3	最后 36 层各经 LayerNorm+Linear (2560 $\rightarrow$ 1024) 逐层 cross-attn 到 36 层 DiT (全 cross); 状态量化 256 桶写进文本; $\tau = (0.999 - \text{Beta}(1.5, 1))/0.999$; 4 步欧拉
QwenGR00T	hidden_states[-1] 作 cross-attn K/V; DiT-B 16 层交错 self/cross; 状态 MLP 编码后前置; 同一 flow-matching MSE; 4 步欧拉; repeated_diffusion_steps=8

训练精度: VLM autocast(bf16), 动作头 autocast(float32)。四个类都继承 baseframework, 只在“如何从隐状态取动作”上不同。