

从 StarVLA 到 VLAct: VLA 持续预训练的表示中心路线

三篇论文 + 一个代码库的系统调研

awesome_starvla 调研汇报

github.com/asimfish/awesome_starvla

2026 年 9 月


开场：同一个骨干，预训练是双刃剑还是净收益？

同样是 Qwen3-VL-4B，同样含 InternData-A1 的机器人数据，两篇论文给出相反的结论。

论文	预训练方式	RoboCasa-GR1（预训练未见的人形）	结论
StarVLA- α （2026-04）	朴素动作拟合 + OXE	24×10 demos: 9.8 → 1.2	双刃剑
StarVLA- α （2026-04）	朴素动作拟合 + InternData-A1	24×1000: 53.8 → 35.4	双刃剑
VLAct（2026-08）	表示中心配方	全量 48.8 → 54.0; 20% 数据 49.5, 已超全量 GR00T-N1.6 (47.6)	净收益


- 差别不在数据量，在轨迹如何塑造骨干表征
- 本次汇报：StarVLA 代码库（基础设施）→ StarVLA- α （对照板）→ VLAct（配方）→ 下一步

三篇论文的关系



- 共同点：同一团队（HKUST / CUHK / SmartMore, Jiaya Jia 组）、同一骨干、同一代码
- 这让**动作头**、**预训练配方**、**动作空间**三个变量第一次可以被单独隔离
- 本仓库：3 篇论文中英 PDF、7 份精读报告、100 篇文献编目、本 PPT

StarVLA: 两条契约把 VLA 拆成可换部件



- 每个 framework 文件可单独运行 (smoke test); YAML + 点路径命令行覆盖 (`--framework.qwenvl.base_vlm`)
- 冻结 = 模块名正则; 分模块学习率 = `trainer.learning_rate` 字典
- 评测: WebSocket 策略服务器 + 基准侧薄适配器 (`model2libero_interface.py` 等), 仿真与真机共用

StarVLA：四种动作头，只在“如何从 z 取动作”上不同

头	接口	目标	推理
FAST	离散 token, LLM 词表	$-\sum_m \log p_\theta(z_m H_t, z_{<m})$	自回归 + 逆 tokenizer
OFT	K 个 action query	$\frac{1}{Kd_a} \sum_k \ g_\phi(h_{t,k}^{\text{act}}) - a_{t+k}\ _1$	一次前向
π	逐层 cross-DiT 流匹配	$\mathbb{E} \ v_\phi(A^\tau, \tau; H_t) - (A - \epsilon)\ _2^2$	N 步积分
GR00T	双系统：VLM 慢 + DiT 快	同上，额外条件于状态 s_t 、本体 e	N 步去噪

线性路径 $A^\tau = (1 - \tau)\epsilon + \tau A$ ，目标速度 $u = A - \epsilon$ ； π 与 GR00T 共享这一目标，差别是运动模块的耦合方式。

- **OFT** 同时是诊断工具：表现好 $\Rightarrow$ 骨干表征线性可读地暴露了连续控制信息
- **FAST** 是唯一不改架构的方案，代价是离散瓶颈 + 串行解码
- 新范式 = 实现并注册一个头；骨干、训练循环、评测管线不动

三种训练模式 = 三个脚本

模式	入口
行为克隆 SFT	<code>train_starvla.py</code>
多模态共训 (双 loader)	<code>train_starvla_cotrain.py</code>
跨本体混合	<code>datasets.vla_data.data_mix</code>
VLM 单独训练	<code>train_starvlm.py</code>

13 个仿真基准 LIBERO / LIBERO-plus / RoboTwin 2.0 / RoboDojo / VLA-Arena / DOMINO / RoboCasa (GR1, 365) / SimplerEnv / BEHAVIOR / CALVIN / MetaWorld / VLN-CE; **真机** Franka / Realman / Unitree G1 / RoboChallenge

多节点扩展效率 (GR00T 头, 每 GPU batch 8, A100)

GPU	秒/步	samples/s	效率
8	0.735	87	100%
32	0.899	285	81.9%
64	0.925	554	79.6%
256	0.931	2200	79.1%

跨节点一次性 +0.2 s/步, 之后平台化; 固定步数不会因加卡变快, 数据量驱动的训练可放心扩到数百卡。

StarVLA- α : 最简基线 = Qwen3-VL-4B + MLP 头

设计: 原始 RGB + 指令; 训练集 z-score 归一化; 无状态、无历史、无机器人预训练; 骨干 lr 1e-5、头 lr 1e-4、cosine、 $\leq 100k$ 步。

方法	LIBERO avg	WidowX	Google VM	RoboTwin clean* / random*	RoboCasa-GR1
OpenVLA-OFT	97.1	31.3	63.0	—	—
π_0	94.1	27.1	58.8	65.9 / 58.4	—
$\pi_{0.5}$	96.9	46.9	72.7	82.7 / 76.8	37.0
GR00T-N1.6	97.0	62.0	67.7	—	47.6
StarVLA-α (specialist)	98.8	64.6	76.0	88.2 / 88.3	53.8
StarVLA-α (generalist)	97.8	65.2	74.3	88.7 / 87.8	57.3

* clean + random 数据都用于训练。

- 唯一输掉的一格: RoboTwin Base (仅 50 clean/任务) $50.3 < \pi_{0.5}$ 60.2 —— 低数据 + 关节角控制是短板
- 四个基准数据合训一个 generalist, GR1 反而 +3.5

StarVLA- α : 常识一，动作头设计重要吗？

同一骨干、同一数据、同一训练协议，只换头：

头	LIBERO avg	WidowX	RoboTwin clean*	RoboCasa-GR1
MLP (OFT 式)	98.8	64.6	88.2	53.8
FAST (离散 token)	97.8	35.6	72.5	45.0
GR00T (双系统流匹配)	98.7	65.3	88.0	52.8
π (流匹配专家)	98.1	65.9	88.1	48.9

- **连续 $\gg$ 离散**：FAST 在 WidowX 落后 29 个点、RoboTwin 落后 16 个点
- **三种连续头相当**：LIBERO 与 RoboTwin 差距 < 1 个点
- **结论**：骨干够强时，动作头的额外复杂度不必要——但这是“同头微调”的结论，VLAct 会追问“骨干可复用吗”

StarVLA- α : 常识二，现有动作预训练重要吗？

中间预训练	轨迹数	RoboTwin 50×50	+Random×500	GR1 24×10	GR1 24×1000
无	—	50.3	88.2	9.8	53.8
+ OXE (跨域)	232.6k	30.2	83.6	1.2	27.8
+ InternData-A1 (同本体)	630k	63.6	88.6	2.8	35.4
+ RoboTwin-Rand (同域)	25k	79.7	88.8	2.2	33.3

双刃剑

跨域数据全面拖后腿；同域数据只在目标域低数据段有用，换到 GR1 一律掉点。作者建议”谨慎使用”。

这张表是 VLA^{act} 问题定义的直接来源：是数据不对，还是训练方式不对？

数据工程（本体感受 / 历史帧 / delta / relative）

- 低数据段 +1~10 点（proprio 在 RoboTwin 50×50 +10.5）
- 数据充足后全部归零；历史帧多数设定略降

多本体动作参数化（GR1 成功率）

RDT 物理统一空间	52.3
每本体独立头	53.5
零填充到 32 维	57.3

规模与优化（generalist 设定）

变量	设定	GR1
初始化	随机 / Florence-2 / Qwen3-VL	28.8 / 39.2 / 57.3
模型规模	2B / 4B / 8B	50.7 / 57.3 / 58.2
batch	64 / 256 / 1024	40.0 / 48.3 / 59.2

- 4B→8B 增益 <1 点，4B 是甜点
- batch 64→1024 使 GR1 +19 点，比模型规模影响更大
- 真机 RoboChallenge ARX5: SR 33.6 vs $\pi_{0.5}$ 12.7

固定 Qwen3-VL-4B, 只改预训练头与微调头 (LIBERO-Plus / RoboTwin-Clean):

(a) 离散监督能迁移, 但丢信息

- FAST 预训练 → GR00T 微调: 略好于从零
- 保留 FAST 头: 远低于任何连续头, 预训练补不回来
- 离散化丢掉了幅度与时序细节

(b) 单一连续头造成 head-specific 坍缩

- OFT 预训练 → OFT 微调: 大涨
- 同一骨干 → PI / GR00T 微调: 低于从零
- 动作信息还在, 但只有原头能解码


预训练头	下游 PI 微调	vs 从零
无	60.5	—
OFT	55.1	−5.4
OFT + GR00T	63.1	+2.6
OFT + PI + GR00T	77.0	+16.5

命名

decoder lock-in: 骨干把动作信息组织成预训练那个头的解码几何。同头成功率高估了骨干可复用性。

VLAct: 配方总览, 三个组件只在持续预训练阶段使用

持续预训练 (DROID + InternData-A1 + RoboCoin + MolmoAct + caption, 16 GPU)



$$\mathcal{L}_{\text{total}} = \underbrace{\mathcal{L}_{\text{OFT}} + \mathcal{L}_{\text{PI}} + \mathcal{L}_{\text{GR00T}}}_{\mathcal{L}_{\text{action}} \text{ (每头再加 } \mathcal{L}_{\text{wrap}})} + 0.5 \mathcal{L}_{\text{VLM-CE}}$$

- 所有对比中**唯一变量是骨干权重**: 7.6~21.4 个点的增益归因到配方
- 无新模块、无本体适配器、无路由: 可在 StarVLA 上直接复现

冻结策略 (预训练阶段)

更新范围	LIBERO-Plus	RoboTwin
全骨干	78.9	77.1
冻视觉编码器	81.3	79.3
冻视觉编码器 + 下半 LLM	82.6	80.5

辅助数据 (LIBERO-Plus)

- robot-only 75.0 $\rightarrow$ +caption 82.6
- Spatial-QA / Point-QA / BBox-QA 均有提升
- 纯文本指令数据也提升: 增益只能解释为“保住基础模型工作区间”
- 全混合 82.5: 固定步数下稀释了 caption

多头 vs 单头, 同头微调 (RoboTwin Base Clean)

下游头	从零	单头	三头	Δ
OFT	61.7	78.8	80.5	+1.7
PI	60.5	75.4	77.0	+1.6
GR00T	51.2	71.7	76.0	+4.3

- 头多样性 = 正则化: 同头也涨, GR00T 受益最大
- 三头共享一次骨干前向, 只多头本身的计算 (论文未给显存 / 吞吐数字)

20 维固定输出，按本体角色分配

维度	含义	表示
1-6	双臂左臂 (AgileX)	绝对关节角
7-12	双臂右臂	绝对关节角
13-18	单臂 (Franka)	delta 末端位姿
19	共享夹爪: Franka 单夹爪 = AgileX 左夹爪	[0,1]
20	双臂右夹爪	[0,1]

每个样本只在激活维上算 loss，其余 mask。

动作空间	RoboTwin	LIBERO-Plus
每本体独立头	78.5	81.1
朴素统一头	79.5	81.4
部分统一	80.5	82.6

周期关节角: 179° 与 -179° 物理上只差 2°

$$a_{\text{wrap}} = (a + \pi) \bmod 2\pi - \pi$$

$$\delta_{\text{wrap}} = ((\hat{a} - a) + \pi) \bmod 2\pi - \pi, \quad \mathcal{L}_{\text{wrap}} = |\delta_{\text{wrap}}|$$

加到每个头的目标上；对 PI / GR00T 作用于最终生成样本；只用于绝对关节角维度。

设定 (RoboTwin Base Clean)	成功率
原始回归	75.5
数据侧 wrap	78.6
+ wrap-aware loss	80.5

+5 个点，零成本，VLAct 单项消融里最大的一项。

VLAct: 主结果, 只换骨干权重

基准	设定	VLAct	同骨干基线	最强外部对手
LIBERO-Plus	7 类扰动均值	82.6	75.0	ABot-M0 80.5
VLA-Arena	11 套件加权	54.8	33.4	$\pi_{0.5}$ 44.3
RoboTwin 2.0 Base	Clean / Random	80.5 / 41.5	61.7 / 10.5	X-VLA 70.0 / 39.0
RoboTwin 2.0 Data Scaling	Clean / Random	92.5 / 90.8	88.2 / 88.3	HoloBrain-0 91.9 / 92.3
DOMINO (动态)	SR / MS	18.50 / 34.20	10.86 / 30.49	$\pi_{0.5}$ 9.63 / 26.17
RoboCasa-GR1 (未见本体)	全量	54.0	48.8	GR00T-N1.6 47.6
RoboCasa-GR1	20% 数据	49.5	–	超全量 GR00T-N1.6
RoboDojo (ARX X5, 未见)	分数 / 成功率	10.66 / 7.60	α 6.40 / 3.24	DM0.5 24.90 / 19.34
真机 Franka 单臂短程	4 任务	92.5	77.5	–
真机 Franka 双臂协调	5 任务	72.0	44.0	–

- LIBERO-Plus 增益集中在 Camera (+26.9) / Robot / Noise / Layout; Language 维度 -5.5
- 预训练只用单臂数据, 双臂协调 44.0 $\rightarrow$ 72.0 (叠裤子、叠毛巾各 +30)
- RoboDojo 35 策略中成功率第 6, 超过全部 4 个 WAM; Memory 0.66 / 0.56 接近零

对话：双刃剑 vs 配方

	StarVLA- α (2026-04)	VLAAct (2026-08)
骨干	Qwen3-VL-4B	Qwen3-VL-4B
预训练数据	OXE / InternData-A1 / RoboTwin-Rand	DROID + InternData-A1 + RoboCoin + MolmoAct + caption
预训练方式	单 MLP 头，全参数，动作-only	冻浅层，三头，部分统一空间，caption 混训
GR1 (未见本体)	53.8 $\rightarrow$ 35.4 (+A1)	48.8 $\rightarrow$ 54.0; 20% 数据 49.5
RoboTwin Base	50.3 $\rightarrow$ 63.6 (+A1)	61.7 $\rightarrow$ 80.5
Clean		
结论	预训练是双刃剑	预训练是否有效取决于配方

- "Beyond Data Scaling" 的实证含义：同样的数据源，配方决定符号
- 动作空间上两篇也叠加：零填充 > 独立头 / RDT (α 表 6); 零填充之上再做物理同义维对齐再 +1 (VLAAct 表 12)
- 共训保护先验一线：ST4VLA (StarVLA 报告 §6) Google VM 66.1 $\rightarrow$ 84.6, VLAAct 选 caption 作最强单源锚点

做得好

- 归因干净：头、初始化、数据、优化器、预
算全同，只换骨干
- 组件简单到可以被推翻：一个正则冻结、三
个已有头并联、一张 20 维表
- 把“哪个头最好”换成“如何让骨干对头不
敏感”
- 成本诚实：开源数据 + 16 GPU，与工业系
统差距明标

局限

- 只有 4B；持续预训练下的规模曲线空白
- Memory 接近零：单帧、无历史的架构假设
没被挑战
- “头无关”有边界：Base/Random 下 OFT
41.5 vs GR00T 22.9 / PI 23.7
- Language 维度掉 5.5 点
- Data Scaling 对比算力不可控；真机每任务
10 次 rollout
- 三头共训开销未量化；20 维布局手工设计，
人形 / 灵巧手如何扩展未讨论
- 同名基线不一致：RoboTwin Base OFT 61.7
(VLAct) vs 50.38 (StarVLA README)

目录	职责 / 关键类
model/framework/	28 个注册框架 (VLM4A 20、WM4A 6、VM4A 2) ; build_framework(cfg) 查注册表
modules/action_model/	11 个动作头文件: MLP(OFT)、FAST、Layerwise-FM(PI)、FM DiT(GR00T)
modules/vlm/	10 个接口, get_vlm_model 分派 9 个分支
dataloader/	GR00T LeRobot 管线移植; VLM LLaVA-json; UMI 适配
training/	4 个显式循环脚本 + trainer_utils (冻结 / 分组 lr / 加载)
examples/	25 个目录: 13 仿真基准、5 真机、6 模型扩展、1 human2robot
deployment/	WebSocket / ZMQ 策略服务器、Docker、HF 上传

实测规模

- 261 个 Python 文件, 57.6k 行; starVLA/ 139 个文件
- 12 个 model2*_interface.py 基准适配器
- 测试: 7 文件 / 40 用例 / 1,067 行, 无 CI
- 浅历史 131 次提交, 40 位作者

契约在代码中的落点

- baseframework (继承 PreTrainedModel) 软约束 forward / predict_action
- dataloader 的 collate_fn 就是 return batch: 样本 = {action, image, lang, robot_tag, state?}
- 每个框架文件末尾带 __main__ smoke

VLAct 配方在 StarVLA 代码中的状态

#	配方	状态	代码现状	需改动
a	冻视觉编码器 + LLM 下半层	部分	trainer.freeze_modules 只接受精确点路径; 4B 有 36 层	列 18 条路径即可; 建议加正则 / 区间语法
b	caption 共训 $0.5 \mathcal{L}_{\text{VLM-CE}}$	已有	train_starvla_cotrain.py + loss_scale.vlm; 已注册 sharegpt4v_coco	改 yaml; VLAct 的 caption 源需注册
c	OFT + PI + GR00T 三头共监督	缺失	28 个框架全部单头; 训练器只读 action_loss	新框架 QwenMultiHead: 一次骨干前向, 三头 loss 相加
d	20 维部分统一布局 + mask	部分	mask 消费端: masked_l1_loss; 生产端: UMI / MiniCPM 80 维; FM 头无 mask	新 transform + 两个 FM 头加 mask
e	周期关节 wrap-aware L1	缺失	无任何模 2π 逻辑	新 loss 函数 + 数据侧 wrap
f	丢预训练头、重初始化、全参解冻	已有	pretrained_checkpoint + reload_modules + freeze_modules: ''	注意 PI 的 project_layers

- 两项”已有”、两项”部分”、两项”缺失”：复现 VLAct 的工程量集中在 **多头框架与 动作空间 transform**
- 唯一的多 loss 先例：LangForce 在同一 GR00T 头上加权两支路 loss
- 完整的 diff 级改动建议见 `reports/02_starvla_codebase_analysis.md §9`

基准选择：研究”持续预训练 / 表示学习”该用哪几个

优先级	基准	考察的能力	理由
1	LIBERO-plus	零样本鲁棒性 (7 维扰动)	训练集固定, 提升只能来自骨干; 10,030 实例噪声小
2	RoboTwin 2.0 Base	少样本 + clean→random	50 条/任务放大表征价值; 必须同时报 clean 与 random
3	RoboCasa-GR1 数据比例曲线	未见本体样本效率	人形, 形态 / 动作空间都不同; 基线也要跑同样比例点
4	VLA-Arena	L0→L1/L2 外推 + 安全代价	与”表示能否支撑结构外推”一致
5	RoboDojo	第三方裁判 + 多维诊断	唯一带 Memory / Precision 拆分的榜单; 适合最终报告
不建议	LIBERO 标准版、SimplerEnv、MetaWorld、CALVIN D→D、BEHAVIOR	-	饱和、方差大、或评测成本极高

报告协议：固定下游预算并写明 checkpoint 规则; ≥ 3 seeds; 区分见过 / held-out 本体 (VLAct 只有 GR1 与 ARX X5 是真 held-out); RoboTwin 四个数都给; 附表示层诊断 (跨头迁移矩阵)。**没有好基**

准的维度：Memory (RoboDojo 6 任务几乎人人接近零)、中等长程分步计分、跨本体零样本、动态场景 (只有 DOMINO)。

研究路线图：六类 18 个方向

类别	方向	出发点的证据
A 表征诊断	A1 骨干可复用性探针套件; A2 自动化”哪层该冻”	decoder lock-in 只能间接观察; 冻结只有 3 档消融
B 预训练目标	B1 头多样性推广 (FAST / 未来帧 / 空间 QA 头); B2 辅助数据调度; B3 潜动作 vs 多头; B4 世界模型辅助头	三头同头 +1.6~4.3; 全混合被稀释; ”广义 VLA 视角”
C 动作空间	C1 可学习的部分统一布局; C2 几何一致参数化 ($SO(3)$); C3 零样本本体迁移	20 维手工表; wrap loss +5; GR1 20% 才 49.5
D 能力短板	D1 记忆与长程; D2 语言泛化; D3 低数据下生成式头落后	Memory 0.66; Language -5.5; Random 下 OFT 41.5 vs 22.9
E 系统 scaling	E1 规模曲线; E2 三头开销与降本; E3 数据 $\times$ 配方 Pareto	只有 4B; 开销未量化
F 评测方法	F1 骨干基准协议; F2 generalist $\times$ 持续预训练; F3 真机统计功效	只换骨干未标准化; 两条线未合并; n=10

详细的做法、代码落点、评测方案与风险见 `reports/07_research_roadmap.md`。

优先级与六个月计划 (16 GPU)

影响 × 成本

方向	影响	成本
A1 诊断套件	高	低
F1 骨干基准	高	低
E2 三头开销	中	低
B1 头多样性	高	中
D1 记忆	高	中
C1 可学习动作空间	高	中
B4 世界模型辅助头	高	高
E1 规模曲线	高	很高

执行计划

月	目标与交付
1	复现 VLAct; 探针 + 骨干基准脚本; 三头开销表
2	A2 自动冻结; B1 头组合因子实验 → 跨头迁移矩阵
3	D1 记忆三路线小规模验证; D3 步数曲线
4	C1 可学习布局, 加 GR1 做三本体预训练
5	B2 调度器; B4 特征预测辅助头 (DOMINO / Random)
6	整合最优组合, 全基准评测 + RoboDojo 提交, 成文并向 StarVLA 提 PR

每月实验都遵守 F1 协议 (只换骨干); 同时报告“同头”与“跨头”两组数字。

- ① **VLM 骨干是 VLA 的一阶设计变量。**只换骨干权重就能拿到 7.6~21.4 个点；朴素动作拟合会把它变成负资产 (GR1 9.8 $\rightarrow$ 1.2)，保护先验 + 多头 + 统一动作空间把它变成净收益 (20% 数据超全量 GR00T-N1.6)。
- ② **头多样性是一种廉价的正则化。**单头预训练造成 decoder lock-in (PI 60.5 $\rightarrow$ 55.1)，加一个头就翻正，三头对同头也涨 1.6~4.3。这个原则可以推到非动作头。
- ③ **StarVLA 让“只改一个变量”成为默认工作方式。**两条契约 + 13 个基准 + 79% 的 256 卡扩展效率；下一步最值钱的是诊断工具、骨干基准协议，以及所有人都接近零的 Memory 维度。

回到开场的问题：预训练不是双刃剑，配方决定符号。

References

-  S. Yang, C. Wang, et al. *Beyond Data Scaling: Representation-Centric Continued Pre-training for Vision-Language-Action Models*. arXiv:2608.27550, 2026.
-  J. Ye, N. Gao, S. Yang, et al. *StarVLA- α : Reducing Complexity in Vision-Language-Action Systems*. arXiv:2604.11757, ECCV 2026.
-  StarVLA Community. *StarVLA: A Lego-like Codebase for Vision-Language-Action Model Developing*. arXiv:2604.05014, 2026. github.com/starVLA/starVLA
-  M. J. Kim, C. Finn, P. Liang. *Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success (OpenVLA-OFT)*. arXiv:2502.19645, 2025.
-  K. Black et al. π_0 : *A Vision-Language-Action Flow Model for General Robot Control*. arXiv:2410.24164, 2024.
-  J. Bjorck et al. *GR00T N1: An Open Foundation Model for Generalist Humanoid Robots*. arXiv:2503.14734, 2025.
-  S. Fei et al. *LIBERO-Plus: In-depth Robustness Analysis of Vision-Language-Action Models*. arXiv:2510.13626, 2025.
-  T. Chen et al. *RoboDojo: A Unified Sim-and-Real Benchmark for Generalist Robot Manipulation Policies*. arXiv:2607.04434, 2026.

谢谢

仓库: https://github.com/asimfish/awesome_starvla

3 篇论文中英 PDF · 7 份精读报告 · 文献编目 · 本 PPT 源码

备份页

- 本体与动作空间: Franka 7 维 (6 delta EE + 1 夹爪); AgileX 14 维 (12 关节角 + 2 夹爪)
- 删无效任务名: unknown_task / n/a / none / 空白
- delta EE: 按 FPS 换成每秒量; 平移速度 > 0.5 或旋转速度 > 1.0 的步标记无效
- **按步 mask 而非丢整条轨迹**: chunk 内无效比例 $r_c > 0.5$ 才丢弃; 之后平移 / 旋转分别除以 $0.5 / 1.0$
- 关节角: 先删 $[-2\pi, 2\pi]$ 之外的值, 再 wrap 到 $[-\pi, \pi]$, 不再额外归一化
- 夹爪: 去极值后逐数据集 min-max 到 $[0, 1]$
- 辅助数据: LLaVA-ReCap-CC3M、LLaVA-OneVision (caption); RefCOCO、COCO-ReM (BBBox-QA); PixMo-Points、RoboPoint (Point-QA); SenseNova-SI-800K (Spatial-QA); Nemotron-SFT (纯文本)

设置

- Franka Research 3 7-DoF (单臂 / 双臂各一模型)
- 外部 RealSense D435 + 腕部 D405, 图像 224×224
- GELLO 遥操作采集; 单臂任务 50 条、双臂 100 条示教
- 50k 步, $8 \times H800$; 每任务 10 次 rollout, 初始状态固定共享
- 长程任务按步计分 (table cleaning 3 步各 0.33)

任务组	VLAct	基线 OFT
单臂短程 ID (4 任务)	92.5	77.5
短程 OOD: pot 新物体	90.0	73.3
短程 OOD: cup 新物体	90.0	65.0
长程: table cleaning	86.6	73.3
长程: scoop beans	80.0	33.3
长程 OOD: 扩展 / 全替换	82.5 / 83.3	47.5 / 46.6
双臂协调 (5 任务)	72.0	44.0

基线常见失败: 立方体位置超出训练分布时冻住; scoop beans 跳过舀取直接空勺倒; 叠毛巾双臂速度不匹配导致滑落。

场景	建议	理由
单本体、数据充足、求简单 低数据 (≤ 50 条/任务) 或强扰动 需要多模态动作分布 需要状态条件、独立运动模块 只能改 LLM 输出层 做持续预训练供他人复用	OFT OFT PI / GR00T GR00T FAST ≥ 2 个连续头共监督	与生成式头持平, 一次前向 RoboTwin Base/Random 领先 18 点 回归头是点估计 状态与本体标识进 System 1 唯一不改架构, 接受 15~30 点代价 单头造成 decoder lock-in
多本体训练	零填充 + 夹爪对齐 + mask	α 表 6 与 VLAct 表 12 叠加
关节角控制	wrap + wrap loss	+5 点, 零成本